

Tema 0.

Regex: patrones en el texto

Nuevo encargo en LinguaAdapt: detectar patrones lingüísticos en corpus reales mediante expresiones regulares

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

LinguaAdapt te encarga una tanda de encargos breves para su equipo de tratamiento de corpus: clientes distintos, cada uno con un texto real y un problema concreto que solo puede resolverse reconociendo un patrón formal en la cadena de caracteres, no memorizando casos sueltos. Te llegan seis encargos independientes, cada uno con su propio texto de partida.

Tu papel

Actúas como analista de texto de LinguaAdapt. En cada actividad recibes una situación profesional, un texto de ejemplo y una tarea concreta que resolver con una expresión regular. Antes de escribir código, identifica qué patrón formal describe lo que buscas (una terminación, una clase de carácter, una posición dentro de la cadena); la pista de cada actividad apunta a ese patrón, pero la solución final es tuya.

EJERCICIOS PROPUESTOS PARA LA UNIDAD REGEX

1. Busquemos verbos para un glosario de traducción

Conocimientos aplicados: Coincidencia de sufijos con alternancia (-ar|-er|-ir).

Instrucciones:

- Situación: Estás colaborando con un equipo que está traduciendo manuales técnicos. Tu tarea es localizar todos los verbos en infinitivo que terminan en “-ar”, “-er” o “-ir” para crear un glosario bilingüe.
- texto = “Instalar, encender, apagar, medir y escribir son acciones básicas del sistema.”
- Tu tarea: Usa una expresión regular que encuentre todos los verbos en infinitivo.
- Pista: Busca palabras que terminen en -ar, -er o -ir.

2. Limpiemos los datos de un corpus literario

Conocimientos aplicados: Clases de caracteres negadas ([^\\w\\s]).

Instrucciones:

- Situación: Estás preparando un corpus literario para hacer un análisis estilístico. El texto viene con mucha puntuación y necesitas limpiarlo para poder contar las palabras correctamente.
- texto = “¡Oh, cielos!” exclamó el personaje. Luego añadió: “¿Qué haré ahora?”
- Tu tarea: Elimina toda la puntuación del texto usando una expresión regular.
- Pista: Puedes usar [^\\w\\s] para eliminar todo lo que no sea letra, número o espacio.

3. Extraigamos correos de una encuesta lingüística

Conocimientos aplicados: Patrones compuestos con escape del punto (\\w+@\\w+\\.\\w+).

Instrucciones:

- Situación: Has recogido respuestas a una encuesta online y necesitas extraer los correos electrónicos de los participantes para enviarles los resultados.
- texto = "Participantes: luis23@gmail.com, maria-traduce@yahoo.es, info@linguistica.org"
- Tu tarea: Extrae todos los correos electrónicos del texto con una expresión regular.
- Pista: Usa `\w+@\w+\.\w+` (recuerda que es para emails simples).

4. Contemos palabras en un resumen de traducción

Conocimientos aplicados: Límites de palabra (`\b\w+\b`) y `re.findall()`.

Instrucciones:

- Situación: Estás revisando un resumen y necesitas contar las palabras que aparecen en él para ver si cumple con el límite del encargo.
- texto = "La traducción automática está mejorando gracias a la inteligencia artificial."
- Tu tarea: Encuentra todas las palabras del texto y cuenta cuántas hay.
- Pista: Usa `\b\w+\b` para capturar cada palabra.

5. Detectemos nombres propios en una noticia

Conocimientos aplicados: Clases de caracteres con rango (`[A-Z]`).

Instrucciones:

- Situación: Estás etiquetando entidades nombradas (como personas o lugares) en una noticia para entrenar un sistema de reconocimiento de nombres.
- texto = "El presidente Pedro Sánchez viajó a Bruselas para reunirse con Ursula von der Leyen."
- Tu tarea: Extrae las palabras que empiezan con mayúscula.
- Pista: Usa `\b[A-Z]\w+` (muy básico, pero funciona como ejemplo).

6. Comprobemos saludos en un chatbot

Conocimientos aplicados: Anclas de inicio (`^`) y `re.match()`.

Instrucciones:

- Situación: Estás diseñando un asistente virtual que debe responder si el usuario empieza su frase con un saludo como "Hola".
- texto = "Hola, ¿puedes traducirme esto al inglés?"
- Tu tarea: Comprueba si la frase empieza por "Hola" usando `re.match()`.
- Pista: Usa `^Hola` para detectar esa palabra al inicio.

Rúbrica de evaluación

Esta práctica es de autoevaluación, sin entrega ni calificación asociada. La rúbrica sirve como referencia para valorar tu propio nivel de dominio antes de pasar a las actividades evaluables.

Criterio	Excelente	Adecuado	En proceso
Identificación del patrón	Reconoce sin ayuda qué construcción regex describe cada situación (alternancia, clase negada, ancla, límite de palabra).	Identifica el patrón con apoyo de la pista.	Necesita más de una pista o revisar la teoría antes de identificar el patrón.
Construcción de la expresión	Escribe expresiones regulares correctas y ajustadas al problema, sin patrones innecesariamente amplios.	Construye expresiones funcionales, aunque más generales de lo necesario.	La expresión no captura el patrón pedido o produce errores.
Verificación del resultado	Comprueba el resultado de cada expresión sobre el texto de ejemplo y detecta coincidencias inesperadas.	Comprueba el resultado, pero no revisa casos límite.	No verifica si el resultado obtenido es el esperado.