

Del texto como dato al índice de legibilidad: un recorrido con Python

Explicación del proceso de transformar un texto en una medida cuantitativa de legibilidad, destacando las decisiones lingüísticas en cada paso técnico.

El punto de partida - El texto como dato



El texto como cadena de caracteres (str)

```
texto1 = "Esto es una prueba.  
¿Funciona? ¡Sí, claro!"
```




```
1 texto (  
2     'Esto',  
3     'es',  
4     'una',  
5     'prueba.',  
6     '¿funciona?',  
7     '¡sí',  
8     'claro!')  
9 )
```

De la lectura experta a la regla operativa

Analizar computacionalmente exige explicitar decisiones intuitivas: qué cuenta como palabra, oración o rasgo de dificultad.

Descomposición y conteo (Tokenización y Limpieza)

Segmentación básica con .split()



Divide la cadena por espacios en blanco; una técnica simple que no separa la puntuación pegada.

Identificación de signos con string.punctuation



Se recorre el texto carácter por carácter para filtrar y contar los signos.


Medir con la función len()

['Esto', 'es', 'una', 'prueba.']	7
"Esto es una prueba. ¡Sí, claro!"	41

Permite convertir propiedades textuales en variables comparables, contando elementos en listas o caracteres en cadenas.


Estimaciones lingüísticas complejas

Contar oraciones exige decisiones



No basta con dividir por puntos; se usa .replace(";",".") y .strip() para evitar contar fragmentos vacíos.

Aproximación de sílabas con re.findall()



Se buscan patrones de núcleos vocálicos para estimar la longitud fonológica; reconoce que no resuelve hiatos o sinalefas.

El resultado y la mirada crítica

Construcción del índice de legibilidad

$$\frac{\text{Silabas}}{\text{Palabras}} + \frac{\text{Palabras}}{\text{Oraciones}} = \text{Índice Orientativo}$$
$$\frac{150}{100} + \frac{100}{8} = 14.0$$

Se combinan promedios para obtener un número que oriente sobre la dificultad léxica y sintáctica.

Interpretación crítica y límites

El número no es una sentencia: El índice es un prototipo didáctico y aproximado; no mide la cohesión, la ambigüedad ni el conocimiento previo.

El código no sustituye a la lingüista: El resultado debe ser reproducible y siempre contrastado con una lectura cualitativa experta.