

Tema 2.

Patrones léxicos y detección de falsos amigos

Prácticas de control de calidad léxica en traducción automática biomédica

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

El equipo de calidad de la empresa tecnológica de traducción biomédica ha detectado que algunos segmentos bilingües parecen correctos, pero esconden errores léxicos de alto impacto: falsos amigos, traducciones literales, unidades técnicas mal localizadas o patrones que requieren una revisión experta.

Tu tarea es construir una primera capa automática de vigilancia lingüística. No vas a sustituir a la persona revisora: vas a preparar señales de alerta que permitan localizar antes los segmentos sospechosos y concentrar la revisión humana donde más criterio hace falta.

Estas prácticas continúan el marco de la unidad: convertir conocimiento lingüístico sobre traducción, terminología y falsos amigos en patrones de búsqueda, recuentos, sustituciones y pequeños pipelines con expresiones regulares.

Tu papel

Actúa como lingüista computacional en un flujo de posesición biomédica. El objetivo no es producir una herramienta perfecta, sino un prototipo claro, verificable y útil para priorizar la revisión de traducciones automáticas.

EJERCICIOS PROPUESTOS PARA LA UNIDAD 2

Ejercicio 1. Exploración inicial de un texto multilingüe

Objetivo: Familiarizarse con el corpus de análisis.

Instrucciones:

- Carga en una variable `texto` el texto multilingüe de la sección «Textos para las actividades 1 y 2» del material de trabajo `textos_y_diccionarios_practicas.md` (se descarga desde la web, en la sección de Prácticas del Tema 2). Copia el texto y pégalo en tu código, con un renglón por cada segmento EN-ES.
- Imprime el contenido y obsérvalo visualmente.
- Comenta en una celda de texto (markdown) qué errores o irregularidades detectas.

Ejercicio 2. Patrón simple con `findall()`

Objetivo: Usar expresiones básicas para extraer estructuras.

Instrucciones:

- Define un patrón para capturar palabras terminadas en «-mente».
- Usa `re.findall()` sobre el texto del Ejercicio 1 y muestra los resultados.
- Analiza si todas las coincidencias tienen valor adverbial.

Ejercicio 3. Falsos amigos

Objetivo: Detectar falsos amigos entre inglés y español.

Instrucciones:

- Define un diccionario EN-ES de posibles falsos amigos (palabra inglesa → falso amigo en español; ej. library → librería) y otro diccionario con el mismo vocabulario inglés y su traducción correcta (ej. library → biblioteca). Tómalos del «Diccionario de falsos amigos y propuestas correctas» del material de trabajo textos_y_diccionarios_practicas.md.
- Crea un patrón que identifique en el texto del Ejercicio 1 únicamente los segmentos bilingües que contengan la palabra inglesa «peligrosa» y en cuya traducción se haya cometido el falso amigo.
- Crea otro patrón que identifique en cada oración la palabra inglesa «peligrosa» y proponga, en consecuencia, la traducción correcta de esa palabra.

Ejercicio 4. Sustitución con `re.sub()`

Objetivo: Corregir automáticamente estructuras sospechosas.

Instrucciones:

- Usa `re.sub()` para corregir automáticamente estas tres frases en inglés:

```
frases = [  
    "He is very sensible to criticism.",  
    "This is an actual miracle.",  
    "Eventually, she got the job."  
]
```

- Aplica estas tres sustituciones: very sensible → very sensitive; actual → real; eventually → finally. Muestra cada frase antes y después de la corrección y evalúa el resultado.

Ejercicio 5. Extracción de secuencias numéricas

Objetivo: Identificar patrones numéricos con unidades (ej. «50 mg», «3.2%»).

Instrucciones:

- Trabaja con este texto:

```
texto_medico = """  
The dosage was 50 mg every 8 hours. The solution contains 3.2% of sodium chloride.  
También se administraron 250ml y 100 ML de solución salina al 2,5 %.  
"""
```

- Escribe una expresión que identifique cantidades + unidades.
- Extrae todas las coincidencias y clasifícalas tú personalmente.

Ejercicio 6 (Avanzado): Pipeline de análisis con expresiones regulares

Objetivo: Integrar detección, extracción y corrección en un pipeline.

Instrucciones:

- Define una función `analizar_traduccion(texto)` que:
- Detecte falsos amigos
- Extraiga unidades técnicas
- Identifique frases con posible traducción literal
- Prueba la función con el texto del Ejercicio 1 y con el texto médico del Ejercicio 5.

Ejercicio Reflexivo

Objetivo: Relacionar el análisis lingüístico con entornos reales de traducción.

Instrucciones:

- Reflexiona: ¿qué tipo de errores afectan más la comprensión en una traducción automática?

- ¿Cuál es el valor de automatizar parte de la revisión lingüística?
- ¿Qué límites tienen las expresiones regulares frente a otros métodos (ej. aprendizaje automático)?

Rúbrica de evaluación

Se valora que el código funcione, que los patrones estén bien planteados y que las decisiones se expliquen desde el control de calidad léxica en traducción.

Criterio	Excelente	Adecuado	En proceso
Exploración del corpus	Carga, observa y comenta el texto multilingüe con atención a errores o irregularidades relevantes.	Explora el texto y comenta algunos aspectos, aunque la observación es parcial.	No muestra comprensión suficiente del corpus ni de sus problemas lingüísticos.
Uso de expresiones regulares	Define patrones adecuados con <code>re.findall()</code> para extraer formas léxicas y valorar sus coincidencias.	Usa regex de forma básica, con algún patrón mejorable o análisis incompleto.	No consigue formular patrones funcionales para las búsquedas solicitadas.
Detección de falsos amigos	Identifica coincidencias sospechosas, las vincula con el par inglés-español y propone correcciones.	Detecta algunos casos, aunque faltan justificación o correcciones precisas.	No distingue con claridad falsos amigos, riesgo léxico y corrección.
Sustitución y extracción técnica	Aplica <code>re.sub()</code> y extrae secuencias numéricas con unidades, evaluando el resultado obtenido.	Resuelve parte de la sustitución o extracción, con errores puntuales.	No aplica correctamente sustituciones ni patrones numéricos.
Pipeline avanzado	Integra detección, extracción y corrección en una función clara y reutilizable.	La función existe y combina algunas tareas, aunque falta integración o claridad.	No construye un pipeline funcional de análisis.
Reflexión profesional	Relaciona la práctica con revisión humana, traducción automática y límites de las regex.	Incluye una reflexión útil, aunque poco desarrollada o con límites incompletos.	La reflexión no conecta la actividad con un flujo real de control de calidad.