

Tema 3.

Preprocesamiento y análisis morfosintáctico con spaCy

Prácticas I: Preparación de corpus técnicos para traducción automática

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

La empresa internacional de traducción automática médica y farmacéutica de esta unidad ha recibido un corpus técnico extenso. El material contiene terminología especializada, estructuras largas, ruido textual y decisiones lingüísticas que no pueden resolverse solo mirando palabras aisladas.

Tu trabajo consiste en preparar ese corpus para que pueda alimentar un sistema de traducción automática neuronal con más garantías. Antes de entrenar o evaluar modelos, el equipo necesita tokenizar, etiquetar morfosintácticamente, detectar sustantivos técnicos, limpiar palabras vacías y comparar qué información se conserva o se pierde en cada paso.

Estas prácticas trasladan el relato del cuaderno principal a una tarea concreta: construir una mirada lingüística operativa con spaCy. El objetivo no es limpiar por limpiar, sino tomar decisiones justificadas sobre qué elementos del texto técnico son ruido y cuáles son esenciales para la precisión terminológica.

Tu papel

Actúa como lingüista computacional junior dentro del proyecto. Tu entrega debe mostrar código funcional, pero también criterio profesional: qué etiquetas PoS observas, qué sustantivos pueden alimentar un glosario y cómo afectan las stopwords y la lematización al corpus final.

EJERCICIOS PROPUESTOS PARA LA UNIDAD 3

Texto de trabajo para todos los ejercicios

Texto técnico:

La traducción automática neuronal ha revolucionado la industria de la traducción.

Los modelos aprenden a partir de grandes corpus paralelos y pueden manejar terminología especializada. Sin embargo, la eficacia de estos sistemas depende en gran medida de la calidad y representatividad de los datos utilizados durante el entrenamiento. Los corpus ruidosos, con inconsistencias terminológicas o errores de alineación, pueden afectar significativamente la precisión del modelo, especialmente en dominios altamente técnicos como el biomédico, el jurídico o el financiero.

Una de las principales ventajas de la traducción automática neuronal (NMT, por sus siglas en inglés) es su capacidad para captar dependencias contextuales a largo plazo y generar traducciones más naturales en comparación con los sistemas estadísticos anteriores. A través de arquitecturas basadas en transformers, como las implementadas en modelos del tipo BERT, GPT o MarianMT, el sistema puede representar el significado de las palabras dentro de su contexto y generar equivalencias más fluidas. Esto resulta particularmente útil para traducir frases con ambigüedades léxicas o estructuras sintácticas complejas.

A pesar de estos avances, persisten desafíos significativos. La NMT tiende a ser menos fiable en contextos donde el corpus de entrenamiento es limitado o poco especializado. Por ejemplo, en textos técnicos que incluyen nomenclatura química, unidades de medida o términos propios de un campo concreto, el modelo puede producir errores de sustitución o simplificación que comprometen la precisión terminológica. Para mitigar este problema, los investigadores han desarrollado estrategias de adaptación de dominio (domain adaptation), que consisten en reentrenar o ajustar el modelo con corpus específicos del ámbito profesional al que se dirige la traducción.

Otro aspecto crítico es la gestión de la terminología controlada. En entornos industriales, donde la coherencia terminológica es esencial, se recurre a glosarios y bases de datos terminológicas que pueden integrarse dentro del proceso de traducción automática. Los sistemas modernos permiten la imposición de términos preferidos mediante mecanismos de constrained decoding, garantizando que ciertos términos se traduzcan de manera consistente a lo largo de todo el texto. Esta técnica se ha vuelto indispensable en sectores como el farmacéutico o el de ingeniería, donde un error terminológico puede alterar el significado técnico del documento.

Además, la evaluación de la calidad en traducción automática continúa siendo un área de intensa investigación. Las métricas tradicionales como BLEU, METEOR o TER ofrecen una aproximación cuantitativa, pero no siempre reflejan la adecuación semántica o la naturalidad estilística de las traducciones. Por ello, cada vez se emplean más enfoques basados en Quality Estimation (QE), que utilizan redes neuronales para predecir la calidad de una traducción sin necesidad de una referencia humana. Estas herramientas son especialmente útiles en flujos de trabajo industriales, donde el volumen de texto traducido es demasiado grande para ser revisado manualmente.

Finalmente, el papel del traductor humano ha evolucionado hacia un perfil más técnico, orientado al post-edition y a la gestión de recursos lingüísticos. En lugar de reemplazar al profesional, la traducción automática neuronal lo complementa, permitiéndole concentrarse en tareas de revisión, adaptación cultural y control terminológico. De esta forma, la sinergia entre inteligencia artificial y conocimiento lingüístico humano está configurando un nuevo paradigma en los servicios de traducción, caracterizado por la eficiencia, la personalización y la escalabilidad.

Ejercicio 1. Instalación y carga del modelo spaCy en español

Objetivo: Configurar el entorno y cargar el modelo lingüístico.

Instrucciones:

- Instala spaCy y descarga el modelo `es_core_news_sm`.
- Carga el siguiente texto técnico y crea un objeto `doc`.
- Imprime las primeras 10 palabras con sus etiquetas PoS.

Ejercicio 2. Tokenización y etiquetado morfosintáctico

Objetivo: Comprender y manipular etiquetas PoS.

Instrucciones:

- Tokeniza el texto.
- Extrae y lista todas las etiquetas PoS distintas.
- Cuenta cuántas palabras hay de cada categoría gramatical.

Ejercicio 3. Extracción y frecuencia de sustantivos técnicos

Objetivo: Identificar términos relevantes para el glosario.

Instrucciones:

- Filtra solo los sustantivos del texto.
- Convierte a minúsculas y calcula frecuencias.
- Presenta los 15 sustantivos más frecuentes.

Ejercicio 4. Limpieza de texto y eliminación de stopwords

Objetivo: Mejorar la calidad del corpus para NMT.

Instrucciones:

- Aplica un filtro para eliminar stopwords.
- Lematiza las palabras restantes.
- Compara la frecuencia antes y después de la limpieza.

Preguntas adicionales:

- Hasta ahora hemos utilizado la lista de palabras vacías de NLTK. Sin embargo, spaCy también incorpora su propio conjunto de stopwords para cada lengua. En este caso, podemos usar las stopwords del modelo de español que ya hemos cargado con spaCy. ¿Te animarías a intentar hacer este ejercicio con la función de stopwords de librería de SpaCy en lugar de con la de NLTK?
- Échale un vistazo a los resultados con cada una de las librerías. ¿Salen las mismas cantidades? ¿Qué crees que ha podido pasar?

Rúbrica de evaluación

Se valora que el procesamiento funcione y que las decisiones técnicas estén justificadas desde la preparación de corpus técnicos para traducción automática médica y farmacéutica.

Criterio	Excelente	Adecuado	En proceso
Configuración de spaCy	Instala/carga correctamente <code>es_core_news_sm</code> , crea el objeto <code>doc</code> y muestra tokens con etiquetas PoS.	Carga el modelo y procesa el texto, aunque falta algún detalle en la salida.	No consigue configurar spaCy o no genera un objeto lingüístico utilizable.
Tokenización y PoS	Tokeniza el texto, identifica etiquetas distintas y cuenta categorías gramaticales con precisión.	Extrae etiquetas y recuentos básicos, con algún error menor.	No interpreta correctamente las etiquetas PoS o los recuentos.
Sustantivos técnicos	Filtra sustantivos, normaliza formas y presenta los 15 más frecuentes de forma clara.	Obtiene sustantivos y frecuencias, aunque la selección o presentación puede mejorar.	No logra aislar sustantivos técnicos ni calcular frecuencias útiles.
Stopwords y lematización	Elimina stopwords, lematiza y compara frecuencias antes y después con criterio lingüístico.	Aplica limpieza y lematización, pero la comparación queda parcial.	No conecta limpieza, lematización y calidad del corpus.
Comparación NLTK/spaCy	Analiza diferencias entre listas de stopwords y explica su impacto en textos técnicos.	Compara resultados, aunque la explicación es breve o poco precisa.	No reflexiona sobre las diferencias entre recursos lingüísticos.
Claridad profesional	El código y los comentarios permiten entender cada decisión dentro del proyecto de traducción automática.	La solución se entiende, aunque podría mejorar nombres, orden o explicación de salidas.	La entrega es difícil de seguir o no justifica las decisiones de preprocesamiento.