

Tema 3.

Preprocesamiento y análisis morfosintáctico con spaCy

Prácticas II: Pipeline de preprocesamiento y glosario técnico

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

El equipo de traducción automática médica y farmacéutica ya ha probado los pasos básicos de preprocesamiento: cargar spaCy, crear objetos `doc`, observar etiquetas PoS, eliminar stopwords y extraer términos relevantes. Ahora necesita convertir esos pasos en un flujo reutilizable.

En esta segunda parte, el corpus cambia de dominio técnico: trabajarás con un texto especializado sobre cercosporosis de la zanahoria. Aunque el ámbito sea fitosanitario, el reto profesional es el mismo: preparar texto técnico denso sin destruir la información terminológica que un sistema de traducción automática necesita conservar.

Tu misión es integrar limpieza, tokenización, lematización, etiquetado y extracción de glosario en un pipeline claro. Además, deberás reflexionar sobre el equilibrio entre reducir ruido y preservar términos críticos, porque una limpieza agresiva puede mejorar algunos recuentos y, al mismo tiempo, empobrecer la traducción automática.

Tu papel

Actúa como lingüista computacional junior responsable de empaquetar una práctica repetible para el equipo. Tu solución debe ser funcional, exportable y explicable: no basta con obtener tokens, hay que justificar qué se conserva, qué se elimina y por qué.

EJERCICIOS PROPUESTOS PARA LA UNIDAD 3.

Texto de trabajo para el ejercicio 5

La cercosporosis de la zanahoria, causada por el hongo *Cercospora carotae* (sin. *Passalora carotae*), constituye una de las principales enfermedades foliares que afectan los cultivos de *Daucus carota* L., especialmente en regiones templadas y subtropicales con alta humedad relativa. Este patógeno fitoparásito de naturaleza necrotrófica se caracteriza por inducir lesiones foliares de tipo necrótico clorótico, que reducen significativamente la capacidad fotosintética de las hojas, provocando pérdidas de rendimiento y afectando la calidad comercial de las raíces.

Desde el punto de vista etiológico, *C. carotae* pertenece al filo Ascomycota, clase Dothideomycetes, orden Capnodiales y familia Mycosphaerellaceae. El micelio del hongo es hialino a ligeramente pigmentado, septado, y se desarrolla de forma predominantemente subestomática. Los conidióforos emergen a través de los estomas o directamente de la epidermis, agrupándose en fascículos compactos. Los conidios, que constituyen las unidades de diseminación asexual, son cilíndricos o fusiformes, multiseptados, hialinos en estadios jóvenes y oliváceos al madurar. Su longitud y grado de septación son parámetros taxonómicos relevantes para la identificación morfológica del patógeno en laboratorio.

La sintomatología típica se manifiesta inicialmente en hojas viejas mediante pequeñas lesiones circulares o irregulares de color pardo claro con bordes oscuros bien definidos. A medida que la infección progresa, las lesiones se expanden y pueden confluir, generando necrosis extensas y defoliación prematura. En infecciones severas, el daño puede extenderse al pecíolo y al tallo, comprometiendo el vigor de la planta y, en casos extremos, el calibre y contenido de materia seca de la raíz. La pérdida foliar conlleva una reducción de la interceptación lumínica, afectando la translocación de fotoasimilados hacia los órganos reservantes.

La epidemiología de la cercosporosis está fuertemente influenciada por factores microclimáticos. El desarrollo óptimo del hongo ocurre entre 25 y 30 °C, con una humedad relativa superior al 90 % y presencia de películas de agua libre sobre el follaje durante más de 10 horas. Estas condiciones favorecen la germinación de conidios y la penetración directa o a través de los estomas. El inóculo primario suele provenir de residuos infectados del cultivo anterior o de semillas contaminadas, aunque se ha demostrado que los conidios pueden dispersarse por salpicadura o por corrientes de aire a corta distancia.

El manejo integrado de la cercosporosis de la zanahoria se basa en estrategias combinadas de tipo preventivo, cultural, químico y genético. Entre las medidas culturales más efectivas destacan la rotación de cultivos con especies no hospedantes durante al menos tres años, la eliminación de restos de cosecha, y la optimización de la densidad de siembra para favorecer la aireación del follaje. El riego por aspersión incrementa la incidencia, mientras que el riego localizado por goteo contribuye a reducir la humedad foliar.

En cuanto al control químico, los fungicidas del grupo de los triazoles (inhibidores de la biosíntesis de ergosterol, FRAC 3) y las estrobilurinas (inhibidores de la respiración mitocondrial, FRAC 11) son los más empleados, generalmente en programas de rotación para evitar la selección de cepas resistentes. También se han evaluado productos a base de cobre y extractos vegetales con actividad antifúngica, aunque su eficacia es variable según las condiciones del ensayo y el estadio fenológico del cultivo.

El control genético mediante el uso de variedades tolerantes constituye una línea de investigación prioritaria. Estudios recientes de genómica funcional y transcriptómica comparada han identificado genes candidatos asociados a la resistencia parcial, incluyendo proteínas tipo NBS-LRR y quinasa receptora-like, involucradas en la detección de patrones moleculares asociados a patógenos (PAMPs). La integración de herramientas de marcadores moleculares (SNPs y microsatélites) ha permitido mapear loci de resistencia y avanzar en programas de mejora asistida por marcadores.

En el ámbito del diagnóstico, se emplean técnicas moleculares basadas en PCR con cebadores específicos para *C. carotae*, permitiendo la detección temprana del patógeno incluso en tejidos asintomáticos. Asimismo, la espectroscopía infrarroja cercana (NIR) y los enfoques de fenotipado digital están siendo explorados como métodos no destructivos para la detección de síntomas incipientes y la cuantificación de severidad en campo.

En conclusión, la cercosporosis de la zanahoria representa un desafío fitosanitario de relevancia económica. El éxito en su manejo depende de la implementación coordinada de prácticas agronómicas sostenibles, la vigilancia epidemiológica y la innovación biotecnológica, orientadas a reducir la dependencia de fungicidas y garantizar la productividad y sanidad del cultivo en sistemas intensivos y de producción ecológica.

Ejercicio 5. Creación de un pipeline completo de preprocesamiento

Objetivo: Integrar todos los pasos en una función reutilizable.

Instrucciones:

- Define una función que reciba texto y devuelva tokens limpios, lematizados y etiquetados.
- Aplica esta función al siguiente nuevo texto.

Actividad adicional: Extrae el glosario técnico y guárdalo en un archivo CSV o TXT. Para esta acción tendrás que consultar con un asistente de IA (recuerda que el prompt es esencial; debes trasladar la información de manera clara y directa, y proporcionarle todo el contexto).

Se recomienda que antes de realizar esta parte adicional de exportación el alumnado lea con detenimiento la explicación sobre la librería Pandas, en la documentación teórica de referencia de la unidad.

Ejercicio 6 (Reflexivo): Impacto del preprocesamiento en NMT

Objetivo: Vincular teoría y práctica.

Instrucciones:

- Analiza cómo la eliminación de ruido y la selección léxica afectan los resultados de traducción automática.
- Explica por qué preservar términos técnicos es crítico en textos médicos.
- ¿Qué riesgos conlleva un preprocesamiento inapropiado en traducción médica?
- ¿Cómo puede el conocimiento lingüístico mejorar la calidad de sistemas automáticos?
- ¿Qué balance debe encontrarse entre limpieza y preservación de información?

Rúbrica de evaluación

Se valora la integración técnica del pipeline, la calidad del glosario y la reflexión lingüística sobre el impacto del preprocesamiento en sistemas de NMT.

Criterio	Excelente	Adecuado	En proceso
Pipeline reutilizable	Define una función clara que recibe texto y devuelve tokens limpios, lemas y etiquetas.	La función integra varios pasos, aunque falta algún elemento o la salida no es del todo clara.	No construye un pipeline funcional o reutilizable.
Aplicación al texto técnico	Aplica el pipeline al texto de cercosporosis y respeta la terminología especializada.	Procesa el texto, aunque con pérdidas o decisiones poco justificadas.	No aplica correctamente el análisis al corpus propuesto.
Glosario técnico	Extrae términos técnicos relevantes y los prepara para guardarlos en CSV o TXT.	Extrae un glosario básico, aunque la selección o exportación puede mejorar.	No obtiene un glosario útil para revisión terminológica.
Uso de IA y documentación	Formula un prompt claro, aporta contexto y documenta el apoyo recibido para la exportación.	Consulta un asistente, pero el contexto o la integración son parciales.	No traslada la información necesaria o no integra la ayuda de forma crítica.
Reflexión sobre NMT	Explica con precisión cómo limpieza, ruido y selección léxica afectan a la traducción automática.	Relaciona preprocesamiento y NMT, aunque la reflexión es algo general.	No conecta las decisiones de limpieza con la calidad de la traducción.
Preservación terminológica	Argumenta por qué conservar términos técnicos es crítico y propone un equilibrio razonado.	Reconoce la importancia de los términos técnicos, con justificación limitada.	No identifica el riesgo de eliminar información especializada.