

Tema 3.

Preprocesamiento y análisis morfosintáctico con spaCy

Las stopwords de SpaCy y NLTK: Diferencias en el preprocesamiento textual

Material complementario | Programación para PLN | Universidad Pontificia Comillas

1. Las *stopwords* como recurso de preprocesamiento lingüístico

En el procesamiento del lenguaje natural, las *stopwords* o palabras vacías son unidades léxicas de alta frecuencia que suelen desempeñar funciones gramaticales o discursivas, pero que, en determinadas tareas computacionales, aportan poca información temática o discriminativa. Entre ellas suelen encontrarse artículos, preposiciones, conjunciones, pronombres y algunos verbos auxiliares o formas muy frecuentes. Su eliminación ha sido una operación clásica en tareas de recuperación de información, clasificación textual, análisis de frecuencias, modelado temático y construcción de representaciones vectoriales basadas en conteos (Manning *et al.*, 2008).

No obstante, la eliminación de *stopwords* no debe entenderse como una operación neutra ni universal. La decisión de retirar ciertas palabras depende del objetivo de análisis, del género textual, de la lengua, del dominio especializado y de la tarea computacional. En textos técnicos, científicos o biomédicos, por ejemplo, algunas palabras frecuentes pueden adquirir valor terminológico o funcional dentro del dominio, mientras que otras unidades no incluidas en listas generales pueden comportarse como palabras poco informativas dentro de un corpus específico (Sarica y Luo, 2020).

Desde esta perspectiva, comparar las *stopwords* de NLTK y spaCy permite mostrar al alumnado que el preprocesamiento textual no es solo una operación mecánica, sino una decisión metodológica que afecta directamente al corpus resultante y, por tanto, a las frecuencias, los lemas conservados y las conclusiones posteriores del análisis.

2. NLTK: una aproximación orientada a la docencia y al trabajo con corpus

NLTK (*Natural Language Toolkit*) es una biblioteca ampliamente utilizada en docencia e investigación introductoria en PLN. Su diseño histórico está vinculado al aprendizaje de conceptos fundamentales de lingüística computacional, procesamiento simbólico, corpus lingüísticos y análisis textual programado (Bird *et al.*, 2009; Loper y Bird, 2002).

En relación con las *stopwords*, NLTK proporciona acceso al corpus stopwords, que contiene listas de palabras vacías para distintas lenguas. En español, el procedimiento habitual consiste en importar el recurso desde nltk.corpus y obtener la lista mediante:

```
from nltk.corpus import stopwords
stopwords_es = set(stopwords.words("spanish"))
```

Esta forma de trabajo es especialmente útil desde el punto de vista didáctico porque separa con claridad cada fase del preprocesamiento: carga del recurso, conversión en conjunto, comparación con los tokens del texto y filtrado. Además, permite explicar de manera transparente que las *stopwords* proceden de una lista externa predefinida y que el analista puede inspeccionarla, modificarla o ampliarla según las necesidades del corpus.

Por ello, NLTK resulta adecuado cuando se quiere que el alumnado comprenda explícitamente qué es una lista de palabras vacías y cómo se aplica en una operación de filtrado. Su principal ventaja pedagógica es la claridad del proceso: la lista se carga, se consulta y se aplica de forma visible.

3. spaCy: integración de las *stopwords* en un pipeline lingüístico

spaCy, por su parte, está orientado a la construcción de pipelines de PLN eficientes y aplicables a proyectos reales. La biblioteca integra tokenización, lematización, etiquetado morfosintáctico, análisis de dependencias, reconocimiento de entidades y otros componentes lingüísticos en un flujo de procesamiento unificado. La propia documentación define spaCy como una biblioteca de PLN de código abierto preparada para tareas aplicadas y con modelos entrenados para múltiples lenguas.

En spaCy, las *stopwords* forman parte de los datos lingüísticos asociados a cada lengua o modelo. La documentación indica que cada lengua puede incluir un archivo `stop_words.py` con una lista de palabras frecuentes que pueden filtrarse, y que los tokens correspondientes devuelven `True` en el atributo `Token.is_stop`.

En la práctica, esto permite dos formas equivalentes de trabajo. La primera es usar explícitamente el conjunto de *stopwords* del modelo:

```
stopwords_es = nlp.Defaults.stop_words
```

La segunda es aprovechar directamente el atributo lingüístico del token:

```
if not token.is_stop:
```

Esta segunda opción refleja mejor la filosofía de spaCy: el token no es solo una cadena de texto, sino un objeto lingüísticamente anotado que contiene información sobre su forma, lema, categoría gramatical, dependencia sintáctica, entidad y pertenencia o no a la lista de *stopwords*. En términos didácticos, spaCy permite mostrar que la eliminación de palabras vacías puede integrarse dentro de un análisis lingüístico más amplio.

4. Diferencias prácticas entre las listas de NLTK y spaCy

Aunque NLTK y spaCy permiten realizar la misma operación general —eliminar palabras frecuentes o poco informativas—, no utilizan necesariamente la misma lista de *stopwords*. Cada biblioteca mantiene sus propios recursos, con criterios de inclusión distintos. Por ello, dos fragmentos de código formalmente equivalentes pueden producir resultados diferentes.

La diferencia está en el recurso léxico usado como referencia. Si la lista de spaCy contiene más formas frecuentes, variantes flexionadas, adverbios, pronombres o conectores que la lista de NLTK, el número final de tokens conservados será menor. Esta variación es esperable y constituye una buena oportunidad para demostrar que las decisiones de preprocesamiento modifican cuantitativa y cualitativamente el corpus resultante.

5. Implicaciones metodológicas para el análisis de textos especializados

En textos especializados, como los textos científicos, técnicos, médicos, jurídicos o sobre traducción automática, la elección de una lista general de *stopwords* debe realizarse con cautela. Las listas generales de NLTK o spaCy están diseñadas para cubrir palabras frecuentes de una lengua, pero no necesariamente responden a las necesidades de un dominio concreto.

Por ejemplo, en un corpus sobre traducción automática, palabras como «sistema», «modelo», «lengua», «traducción» o «neuronal» pueden tener un alto valor terminológico. En cambio, en un corpus muy homogéneo, ciertas palabras técnicas muy frecuentes podrían dejar de ser

discriminativas para una tarea concreta. Sarica y Luo (2020) señalan precisamente que los lenguajes técnicos pueden requerir listas de *stopwords* específicas del dominio, ya que las listas generales no siempre capturan las palabras no informativas de los textos especializados.

Por tanto, la elección entre NLTK y spaCy no debería interpretarse como una cuestión de cuál es «mejor» de forma absoluta, sino como una decisión dependiente de la finalidad del análisis. Para una práctica docente inicial, NLTK ofrece mayor transparencia; para un pipeline lingüístico más integrado, spaCy resulta más coherente; para una investigación especializada, lo más riguroso puede ser partir de una lista general y después revisarla, adaptarla y documentar los criterios de inclusión o exclusión.

6. Relevancia para la práctica profesional

Desde el punto de vista didáctico, comparar ambos métodos resulta especialmente productivo porque permite trabajar tres ideas fundamentales del PLN:

En primer lugar, que el preprocesamiento no es una fase puramente técnica, sino una fase interpretativa. El investigador decide qué unidades conservar y cuáles eliminar.

Por otro lado, que los recursos lingüísticos incorporados en las bibliotecas no son idénticos. NLTK y spaCy pueden aplicar el mismo concepto de *stopword*, pero operacionalizarlo mediante listas distintas.

Las listas de *stopwords* no son universales. Aunque ambas bibliotecas permiten eliminar palabras frecuentes de escaso valor informativo, cada una utiliza un recurso léxico propio. Por ello, si se llevan a cabo análisis con diferentes herramientas, sus resultados debe ndocumentarse en cualquier análisis reproducible, ya que afecta al conjunto final de tokens, a las frecuencias léxicas y a la interpretación posterior de los resultados.

7. Conclusión

El uso de *stopwords* de NLTK y spaCy responde al mismo objetivo general: reducir el ruido léxico y conservar unidades potencialmente más informativas para el análisis. Sin embargo, ambas bibliotecas difieren en su orientación, su integración y sus recursos internos. NLTK ofrece una aproximación más explícita y pedagógica, adecuada para enseñar el funcionamiento básico del filtrado. spaCy, en cambio, integra las *stopwords* dentro de un pipeline lingüístico más amplio, en el que cada token posee atributos como `is_alpha`, `lemma_`, `pos_` e `is_stop`.

En términos metodológicos, ninguna de las dos listas debe asumirse como universalmente correcta. La elección debe justificarse según el objetivo del análisis, el tipo de corpus y el nivel de control requerido. En una práctica universitaria, comparar ambas salidas permite mostrar de forma empírica cómo una decisión de preprocesamiento puede modificar el corpus resultante y, por tanto, las conclusiones del análisis textual.

Referencias

- Bird, S., Klein, E. y Loper, E. (2009). *Natural language processing with Python: Analyzing text with the Natural Language Toolkit*. O'Reilly Media.
- Loper, E. y Bird, S. (2002). NLTK: The Natural Language Toolkit. *Proceedings of the ACL Workshop on Effective Tools and Methodologies for Teaching Natural Language Processing and Computational Linguistics* (pp. 63-70). Association for Computational Linguistics. <https://aclanthology.org/W02-0109/>
- Manning, C. D., Raghavan, P. y Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- Natural Language Toolkit Project. (2026). *Natural Language Toolkit*. NLTK. <https://www.nltk.org/>
- Sarica, S. y Luo, J. (2020). Stopwords in technical language processing. *PLOS ONE*, 15(8), Article e0234937. <https://doi.org/10.1371/journal.pone.0254937>