

Unidad 4: Análisis automático de textos para revisión lingüística

Cuando entregues tu cuaderno, debes nombrar el fichero (.ipynb) de la siguiente manera:

(3 últimos dígitos del alumno 1)_(3 últimos dígitos del alumno 2)_(UD+número)

Por ejemplo:

- Dos alumnos entregan las actividades evaluables de la Unidad 4
- Identificador alumno 1: 200800331
- Identificador alumno 2: 200800229

Nombre del fichero: `331_229_UD4.ipynb`

Normas generales de la actividad

-  **Está prohibido resolver los ejercicios, o apoyarse para ello, en ninguna herramienta de IA.** La única excepción son las actividades en las que se autorice expresamente el uso de una herramienta específica para el objetivo de esa actividad: solo se puede usar en ese momento concreto y únicamente la(s) herramienta(s) permitida(s).
-  **El código debe ser el enseñado en el aula.** Aunque muchas actividades pueden resolverse de distintas formas (hay muchas maneras de llegar a un resultado solicitado), el código que emplees para resolver cada una de las actividades solicitadas tiene que ser el mismo que hemos aprendido en clase.
-  **Las preguntas de reflexión** debes responderlas **con tus propias palabras, sin ayuda alguna.**
-  **Cuaderno de entrega:** trabaja sobre la plantilla `Plantilla_Evaluable_PLN4.ipynb` (contiene solo los títulos de cada actividad y una celda vacía del tipo que necesitas: de código y/o de texto). Respetar esa estructura al entregar.



Actividad propuesta

Instrucciones

1. Con ayuda de un asistente de LLM (ChatGPT, Deepseek, Gemini...), crea 3 textos de temática institucional y similar, de entre 300 y 400 palabras que contengan:
 - Varias veces en el texto la palabra "resiliencia".
 - Varios dobles espacios.
 - Varias ausencias incorrectas de espacio antes de coma o punto.
 - Varias estructuras "sustantivo + preposición 'a' + verbo en infinitivo"

- Varios gerundios con uso de posterioridad y/o con valor de adjetivo (es decir, gerundios con usos no aceptados por la RAE).
- En el texto 1 se debe emplear una o varias veces la palabra 'adquirir'; en el texto 2 se debe emplear una o varias veces la palabra 'obtener'; en el texto 3 se debe emplear una o varias veces la palabra 'conseguir'.
- En el texto 1 se debe emplear una o varias veces la palabra 'trabajador'; en el texto 2 se debe emplear una o varias veces la palabra 'empleado'; en el texto 3 se debe emplear una o varias veces la palabra 'asalariado'.

Es importante que vayas generando un buen prompt para que el asistente cree textos coherentes y gramaticalmente correctos en español, pero con las solicitudes de contenido indicadas anteriormente. Si es necesario, deberás explicarle o ponerle ejemplos para que entienda lo que necesitas (por ejemplo, quizá tengas que investigar y explicarle lo que es un gerundio con uso de posterioridad, agramatical según la RAE).

Además, deberás explicarle al asistente que no quieres que aplique cada norma anterior una sola vez por cada código, sino de manera anárquica (más veces en un texto que en otro).

2. Una vez hayas obtenido los textos, deberás copiarlos y pegarlos como texto sin formato (.txt), y nombrarlos con la nomenclatura: discurso1.txt; discurso2.txt; discurso3.txt.
3. Comienza el ejercicio buscando esos ficheros .txt e imprimiéndolos por pantalla, como hicimos en el aula. Puedes emplear el entorno de Google Colab o bien en local (con VSC o similar). En clase vimos las dos formas de ejecutar código de ficheros que estén en nuestro ordenador.
4. Realiza con el código aprendido en este tema un análisis automático en los 3 textos para averiguar:
 - Frecuencia de aparición de la palabra "resiliencia".
 - Frecuencia y lugar de aparición de los dobles espacios.
 - Frecuencia y lugar de aparición de ausencia indebida de espacios (antes de coma o punto).
 - Casos de estructura "a + infinitivo".
 - Casos de gerundio.
 - Comparación entre el uso de los tripletes de palabras (adquirir vs. obtener vs. conseguir / trabajador vs. empleado vs. asalariado).

Nota: las variables de esta actividad ya no serán 'text', sino 'discurso', ni 'texto1', 'texto2', sino que deberán nombrarse 'discurso1', 'discurso2', 'discurso3', etc.

Puedes emplear el código más sencillo (para 3 textos, en lugar de las alternativas que también hemos enseñado para un número ilimitado de textos).

Ve trabajando todos los códigos en orden en las celdas de código siguientes según estas instrucciones.

Consejo: cuando elabores la tabla comparativa de términos entre discursos, te recomiendo que cambies el tabulador de '8' puntos a '10' puntos, y los guiones de '50' a '60'.

Tarea opcional de la actividad: Elabora automáticamente un informe final con los resultados de todas las acciones solicitadas gracias al uso de funciones definidas.

Preguntas de reflexión

Responde en una celda de Markdown:

- ¿Qué tipo de errores gramaticales son más frecuentes en los textos institucionales que has procesado?
- ¿Qué ventajas y límites ves en la automatización de tareas como la detección de dobles espacios o usos indebidos del gerundio?
- ¿Cómo influye el contexto en la interpretación de estructuras como “a + infinitivo”?
- ¿En qué casos la corrección automática puede generar falsos positivos?
- ¿Qué función poseen las reglas lingüísticas frente al análisis basado en datos?

Objetivo: Valorar críticamente el papel de las herramientas lingüísticas automáticas en tareas de revisión, corrección y análisis de texto.

Rúbrica de evaluación

 **Peso de esta actividad en la nota final:** actividad práctica **60 %** · preguntas de reflexión **40 %**

 **Cómo se evalúa:** se valora **el procedimiento, no solo el resultado**. Resuelve la actividad con el método trabajado en el cuaderno principal de la unidad. Organizar el código a tu manera, usar otros nombres de variables o resolverlo de forma más breve **no penaliza**, siempre que se reconozca ese método. Lo que sí penaliza es sustituirlo por librerías o herramientas que no hemos trabajado y que no explicas.

Criterio de evaluación	Excelente (9-10)	Notable (7-8)	Aprobado (5-6)	Insuficiente (0-4)
Detección y análisis de errores gramaticales	Se han identificado varios tipos de errores con explicación y corrección adecuada.	Se identifican errores con ejemplos claros, aunque no siempre completos.	Se detectan algunos errores, pero sin análisis detallado.	Poca o nula identificación de errores relevantes.
Uso de expresiones regulares y estructuras	Se aplican patrones adecuados para detectar estructuras complejas de forma eficaz.	Se aplican patrones útiles aunque con algunos errores o limitaciones.	Se usan expresiones simples o con errores frecuentes.	No se usan expresiones regulares correctamente o están ausentes.
Reflexión lingüística argumentada	Las decisiones sobre la gramática y su tratamiento automático están bien justificadas.	Las decisiones están bien razonadas, aunque con cierta generalidad.	Las reflexiones son superficiales o muy técnicas sin contexto lingüístico.	No hay reflexión o esta es incoherente.
Presentación y organización del cuaderno	El trabajo está limpio, ordenado, con celdas bien documentadas y comprensibles.	Presentación clara aunque mejorable en formato o claridad en algunas partes.	Presentación desordenada pero funcional.	Desorganización, errores formales o dificultad para seguir el contenido.