

Tema 4.

Análisis automático de textos para revisión lingüística

Informe automático de divergencias en textos paralelos monolingües

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

Una institución que trabaja con varios proveedores de traducción ha recibido distintas versiones de un conjunto de documentos. Antes de validar una versión o consolidar un glosario, el equipo necesita detectar señales objetivas de calidad lingüística: términos recurrentes, incoherencias, errores de espaciado y estructuras que conviene revisar.

En esta práctica actuarás como lingüista computacional encargada de construir una primera capa de control automático sobre un corpus textual de seis ficheros. El objetivo no es sustituir la revisión profesional, sino preparar un informe preliminar que señale dónde mirar antes.

El marco de la unidad se mantiene: usar Python para transformar una revisión lenta y manual en un análisis reproducible. Vas a aplicar búsquedas, recuentos y reglas lingüísticas para localizar palabras clave, dobles espacios, fallos tras puntuación, estructuras «a + infinitivo» y posibles gerundios problemáticos.

Tu papel

Actúa como analista lingüística en un flujo de control de calidad. Tu entrega debe ser clara, trazable y útil para otra persona del equipo: cada patrón encontrado debe poder interpretarse como una señal de revisión, no como una verdad automática.

EJERCICIOS PROPUESTOS PARA LA UNIDAD 4

Ejercicio 1. Trabajo de detección lingüística sobre un corpus textual

Objetivo: Detectar patrones y errores lingüísticos en un corpus con muchos textos.

Instrucciones:

- Carga los 6 ficheros de texto que conforman el corpus (texto1.txt a texto6.txt). Se descargan desde la web, en la sección de Prácticas del Tema 4, con el botón «Descargar los 6 textos del corpus».
- Aplica los códigos vistos en clase para obtener:
- Frecuencia de uso de la palabra "implementación".
- Dobles espacios incorrectos.
- Ausencia indebida de espacios tras signo de puntuación.
- Identificación de palabras clave: compara en una tabla cuántas veces aparece cada palabra de estos cuatro pares en cada uno de los 6 textos: equipo / grupo; compañía / empresa; gerente / director; procesos / procedimientos.
- Identificación de estructuras «a + infinitivo».
- Identificación de posibles gerundios incorrectos.

Rúbrica de evaluación

Se valora la carga del corpus, la precisión de los patrones y la utilidad del informe para apoyar una revisión lingüística profesional.

Criterio	Excelente	Adecuado	En proceso
Carga del corpus	Carga correctamente los 6 textos y organiza el corpus para aplicar análisis repetibles.	Carga la mayoría de textos, aunque la estructura del corpus puede mejorar.	No consigue cargar o manejar el corpus de forma fiable.
Recuentos y palabras clave	Calcula la frecuencia de «implementación» e identifica palabras clave con salidas claras.	Obtiene recuentos básicos, con alguna imprecisión o presentación limitada.	No produce recuentos útiles para el análisis lingüístico.
Errores de espaciado	Detecta dobles espacios y ausencia indebida de espacios tras puntuación con patrones adecuados.	Detecta parte de los errores, aunque los patrones generan ruido o pierden casos.	No identifica correctamente los problemas de espaciado.
Estructuras lingüísticas	Localiza estructuras «a + infinitivo» y posibles gerundios incorrectos con criterio de revisión.	Localiza algunas estructuras, pero la interpretación lingüística es parcial.	No distingue los patrones lingüísticos solicitados.
Informe de calidad	Presenta resultados ordenados, comparables y útiles para una revisión profesional del corpus.	Presenta resultados comprensibles, aunque falta síntesis o jerarquía.	La salida es difícil de interpretar o no ayuda a tomar decisiones.
Criterio profesional	Explica límites del análisis automático y conecta los hallazgos con control de calidad lingüística.	Reconoce algunos límites, aunque la explicación es general.	No contextualiza los resultados ni sus límites.