

# Tema 5.

## Evaluación automática de traducciones

*Métricas léxicas, BLEU, chrF, METEOR y métricas neuronales: cálculo e interpretación de resultados para PLN*

---

Material teórico | Programación para PLN | Universidad Pontificia Comillas

Dr.<sup>a</sup> Blanca Hernández Pardo

# Índice de contenidos

|                                                                            |    |
|----------------------------------------------------------------------------|----|
| Contexto profesional.....                                                  | 1  |
| Encargo: auditoría rápida de traducción automática.....                    | 1  |
| El caso de trabajo.....                                                    | 1  |
| Qué vas a aprender en esta unidad.....                                     | 3  |
| Mapa conceptual de la unidad.....                                          | 3  |
| 1. Marco teórico.....                                                      | 4  |
| 1.1. Por qué necesitamos métricas automáticas.....                         | 4  |
| 1.2. Texto fuente, hipótesis y referencia.....                             | 4  |
| 1.3. Qué tipos de similitud puede observar una métrica.....                | 6  |
| 1.4. Matrices de confusión: base conceptual de precision, recall y F1..... | 7  |
| 1.5. Métricas léxicas basadas en palabras.....                             | 8  |
| 1.5.1. Precisión léxica.....                                               | 8  |
| 1.5.2. Recall léxico.....                                                  | 9  |
| 1.5.3. F1-score léxico.....                                                | 10 |
| 1.5.4. Exact Match.....                                                    | 10 |
| 1.5.5. Índice Jaccard.....                                                 | 10 |
| 1.6. De palabras aisladas a secuencias: n-gramas.....                      | 11 |
| 1.7. BLEU: la métrica clásica basada en n-gramas.....                      | 11 |
| 1.8. chrF y chrF++.....                                                    | 13 |
| 1.9. METEOR: coincidencias flexibles y penalización por desorden.....      | 14 |
| 1.10. Comparación general de métricas clásicas.....                        | 17 |
| 1.11. Métricas semánticas o neuronales.....                                | 18 |
| 1.11.1. BERTScore.....                                                     | 18 |
| 1.11.2. BLEURT.....                                                        | 20 |
| 1.11.3. COMET.....                                                         | 21 |
| 1.12. Cómo interpretar las métricas.....                                   | 22 |
| 2. Evaluación automática con Python.....                                   | 24 |
| 2.1. Preparar los textos antes de medir.....                               | 24 |
| 2.2. Precision léxica con Python.....                                      | 25 |
| 2.3. Traducción automática con deep-translator.....                        | 26 |
| 2.4. Recall léxico.....                                                    | 26 |
| 2.5. F1-score.....                                                         | 27 |
| 2.6. Exact Match.....                                                      | 27 |
| 2.7. Índice Jaccard.....                                                   | 28 |
| 2.8. Informe de métricas léxicas.....                                      | 28 |
| 2.9. BLEU con NLTK.....                                                    | 29 |
| 2.10. chrF con evaluate.....                                               | 29 |
| 2.11. METEOR con NLTK.....                                                 | 30 |
| 2.12. Todas las métricas en un mismo informe.....                          | 31 |
| 2.13. Cómo leer casos con sinónimos y reformulación.....                   | 32 |

|                                                          |    |
|----------------------------------------------------------|----|
| 2.14. Buenas prácticas para interpretar resultados.....  | 33 |
| 2.15. Qué aporta Python a la evaluación lingüística..... | 33 |
| Errores frecuentes de aprendizaje.....                   | 34 |
| Síntesis final.....                                      | 34 |
| Cierre narrativo.....                                    | 34 |
| Referencias.....                                         | 35 |

## Título narrativo

Evaluación automática de traducciones: medir, interpretar y decidir con criterio lingüístico.

## Contexto profesional

### Encargo: auditoría rápida de traducción automática

Imagina que te incorporas al equipo de evaluación lingüística de **NexaLingua Quality Lab**, una consultora especializada en control de calidad lingüística, evaluación de traducción automática y diseño de flujos de revisión para organizaciones multilingües. La empresa trabaja con instituciones públicas, editoriales científicas y departamentos de comunicación internacional que necesitan publicar textos fiables en varias lenguas.

NexaLingua se presenta como un laboratorio de evaluación aplicada, y no como una agencia que sustituya a traductores y revisores: su trabajo consiste en medir, comparar y explicar la calidad de distintas salidas lingüísticas para que los equipos humanos puedan tomar mejores decisiones. En esta unidad, la empresa recibe un encargo concreto: un cliente institucional quiere explorar un flujo mixto de traducción automática más revisión humana.

El cliente no pide una respuesta abstracta sobre si la traducción automática es «buena» o «mala»; necesita una decisión operativa:

- Qué motor de traducción parece producir resultados más próximos a la referencia humana.
- Qué tipos de errores se detectan con métricas automáticas.
- Qué puntuaciones son útiles para priorizar la revisión.
- Qué limitaciones tienen esas puntuaciones.
- Qué casos siguen necesitando evaluación humana.

Tu tarea consiste en construir un pequeño informe de evaluación. El equipo te proporciona un texto fuente, una traducción humana de referencia y una traducción automática, y a partir de ahí debes calcular varias métricas y, sobre todo, interpretarlas.

El valor profesional de este trabajo reside menos en obtener números que en saber leerlos. Una precisión de 0.75 no significa automáticamente «traducción excelente», del mismo modo que un BLEU de 0.40 no significa «traducción inútil»: cada métrica mide una dimensión concreta y deja fuera otras.

### El caso de trabajo

El caso inicial es deliberadamente sencillo:

**Tabla 1.** *Caso inicial: texto fuente, referencia y traducción automática*

| Papel                 | Texto                      |
|-----------------------|----------------------------|
| Texto fuente          | Those trees were big.      |
| Referencia humana     | Esos árboles eran enormes. |
| Traducción automática | Esos árboles eran grandes. |

La traducción automática no es absurda: *grandes* y *enormes* están relacionadas semánticamente, aunque no sean idénticas. Por eso este caso sirve tan bien para aprender evaluación automática, porque las métricas basadas en coincidencia formal detectarán una diferencia, pero una lingüista deberá interpretar si esa diferencia es grave, aceptable o dependiente del contexto.



La simulación se puede formular como una pregunta profesional:

Si una traducción automática se parece mucho a la referencia, pero cambia una palabra por otra próxima, ¿cómo reaccionan las métricas automáticas?

Esta pregunta recorre toda la unidad.

## Qué vas a aprender en esta unidad

Al terminar este tema, deberías poder explicar y aplicar los siguientes conocimientos:

1. Qué es una traducción automática y por qué hay que evaluarla.
2. Qué diferencia hay entre texto fuente, hipótesis y referencia.
3. Por qué una traducción puede ser correcta aunque no coincida exactamente con una referencia.
4. Cómo limpiar textos antes de compararlos.
5. Cómo convertir una frase en una lista de palabras procesadas.
6. Cómo calcular precisión léxica con Python.
7. Cómo calcular *recall* léxico.
8. Cómo combinar *precision* y *recall* mediante el F1-score.
9. Cómo comprobar Exact Match.
10. Cómo calcular el índice Jaccard con conjuntos.
11. Cómo interpretar un conjunto de métricas léxicas.
12. Qué mide BLEU y por qué utiliza n-gramas.
13. Por qué BLEU puede bajar mucho en frases cortas.
14. Para qué sirve el suavizado (*smoothing*) en BLEU.
15. Qué mide chrF y por qué compara caracteres.
16. Por qué chrF puede complementar a BLEU.
17. Qué mide METEOR y por qué su resultado depende de recursos lingüísticos.
18. Cómo usar bibliotecas como `deep-translator`, `nlk` y `evaluate`.
19. Cómo redactar una interpretación argumentada de resultados automáticos.

## Mapa conceptual de la unidad

Tabla 2. Mapa conceptual de la unidad: conceptos, Python y evaluación lingüística

| Concepto            | En Python                                                                 | En evaluación lingüística              |
|---------------------|---------------------------------------------------------------------------|----------------------------------------|
| Referencia          | Variable con traducción humana                                            | Punto de comparación                   |
| Hipótesis           | Variable con traducción automática                                        | Salida que queremos evaluar            |
| Limpieza            | <code>.lower()</code> , <code>.strip()</code> , eliminación de puntuación | Evita diferencias irrelevantes         |
| Tokenización básica | <code>.split()</code>                                                     | Divide el texto en palabras            |
| <i>Precision</i>    | Coincidencias sobre total generado                                        | Exactitud léxica de lo producido       |
| <i>Recall</i>       | Coincidencias sobre total de referencia                                   | Cobertura respecto a lo esperado       |
| F1-score            | Fórmula con <i>precision</i> y <i>recall</i>                              | Equilibrio entre exactitud y cobertura |
| Exact Match         | <code>==</code>                                                           | Coincidencia total palabra por palabra |
| Jaccard             | Intersección sobre unión de conjuntos                                     | Solapamiento léxico                    |
| BLEU                | <code>sentence_bleu()</code>                                              | Coincidencia de n-gramas               |
| chrF                | <code>evaluate.load("chrF")</code>                                        | Similitud formal por caracteres        |
| METEOR              | <code>meteor_score()</code>                                               | Coincidencias flexibles y orden        |

|                |                   |                                           |
|----------------|-------------------|-------------------------------------------|
| Interpretación | Texto argumentado | Juicio lingüístico sobre las puntuaciones |
|----------------|-------------------|-------------------------------------------|

## 1. Marco teórico

### 1.1. Por qué necesitamos métricas automáticas

En procesamiento del lenguaje natural y, muy en particular, en traducción automática, necesitamos valorar hasta qué punto la salida producida por un sistema se parece a una traducción humana de calidad. Cuando un motor traduce una frase, no basta con comprobar que haya generado una secuencia gramatical: también debemos preguntarnos si conserva el contenido del texto fuente, si respeta la estructura informativa, si utiliza un vocabulario adecuado, si mantiene la terminología esperada y si resulta natural en la lengua de llegada.

La evaluación ideal sería siempre una evaluación humana realizada por traductores, lingüistas o anotadores expertos, porque una persona puede detectar matices que una fórmula no ve: ambigüedad, ironía, estilo, adecuación pragmática, errores de sentido o problemas terminológicos. Pero la evaluación humana tiene límites prácticos: es costosa, requiere tiempo, puede variar según el criterio de cada evaluador y no siempre resulta viable cuando se comparan muchos sistemas o grandes volúmenes de traducciones.

Por esa razón se utilizan **métricas automáticas**: procedimientos que asignan una puntuación cuantitativa a una traducción de forma rápida, reproducible y relativamente barata. Estas métricas permiten comparar sistemas, detectar tendencias, analizar experimentos y decidir qué traducciones necesitan más revisión humana.

Ahora bien, una métrica automática no debe confundirse con una verdad absoluta: una puntuación es un indicador, no una explicación completa de la calidad, y la competencia lingüística sigue siendo necesaria para interpretar qué mide, qué deja fuera y en qué contexto puede utilizarse con sentido.

### 1.2. Texto fuente, hipótesis y referencia

En evaluación automática de traducción se suelen comparar tres elementos:

**Tabla 3. Elementos que se comparan en la evaluación automática**

| Elemento                         | Definición                            | Ejemplo                      |
|----------------------------------|---------------------------------------|------------------------------|
| Texto fuente                     | Texto original que se quería traducir | The child opened the window. |
| Hipótesis o traducción candidata | Traducción generada por el sistema    | El menor abrió la ventana.   |
| Referencia                       | Traducción humana considerada válida  | El niño abrió la ventana.    |

Muchas métricas clásicas comparan únicamente la hipótesis con la referencia; es decir, en lugar de evaluar directamente si la hipótesis expresa bien el texto fuente, miden si se parece a una traducción humana disponible. La idea pesa mucho, porque la traducción es una tarea abierta y una misma frase puede traducirse de varias formas aceptables.

Por ejemplo:

**Tabla 4. Hipótesis adecuada que no coincide con la referencia**

| Texto fuente                 | Referencia                | Hipótesis                  |
|------------------------------|---------------------------|----------------------------|
| The child opened the window. | El niño abrió la ventana. | El menor abrió la ventana. |

Desde el punto de vista lingüístico, la hipótesis puede ser adecuada en muchos contextos, pero una métrica basada en coincidencias exactas de palabras penalizará la diferencia entre *niño* y *menor*. El

ejemplo muestra uno de los problemas de fondo de la evaluación automática: las métricas son útiles, pero no «entienden» la traducción del mismo modo que una persona.

Tener varias referencias humanas suele mejorar la evaluación, porque permite reconocer más de una traducción válida:

**Tabla 5. Dos referencias válidas para un mismo texto fuente**


| Texto fuente        | Referencia 1           | Referencia 2                     |
|---------------------|------------------------|----------------------------------|
| The trees are tall. | Los árboles son altos. | Los árboles tienen mucha altura. |

Si solo existe la primera referencia, una hipótesis como *Los árboles tienen mucha altura* podría salir penalizada aunque sea correcta. Por eso la dependencia de una única referencia es una de las grandes limitaciones de muchas métricas clásicas.

### 1.3. Qué tipos de similitud puede observar una métrica

No todas las métricas observan lo mismo: algunas comparan palabras exactas; otras, secuencias; otras se fijan en caracteres, y otras intentan aproximarse al significado mediante modelos neuronales.

**Figura 1. Métricas de evaluación según el tipo de similitud que observan**



Métricas clásicas: sobre todo similitud superficial y estructural · Métricas neuronales: se aproximan mejor a la similitud semántica

*Nota.* Elaboración propia a partir de los apartados 1.5 a 1.11.

**Tabla 6. Tipos de similitud que puede observar una métrica**

| Tipo de similitud         | Qué observa                           | Ejemplo                          |
|---------------------------|---------------------------------------|----------------------------------|
| Similitud superficial     | Coincidencia de palabras o caracteres | altos = altos                    |
| Similitud estructural     | Coincidencia de secuencias u orden    | los árboles son                  |
| Similitud semántica       | Coincidencia de significado           | coche ≈ automóvil                |
| Adecuación traductológica | Fidelidad al texto fuente             | ¿La traducción expresa lo mismo? |
| Fluidez                   | Naturalidad en la lengua meta         | ¿Suena bien en español?          |

Las métricas clásicas suelen medir sobre todo similitud superficial y estructural. Las métricas neuronales intentan aproximarse mejor a la similitud semántica y, en algunos casos, a la adecuación respecto al texto fuente.

De ahí una primera conclusión sencilla: ninguna métrica evalúa por sí sola todos los aspectos de una traducción, y por eso conviene combinar varias e interpretarlas con prudencia.

## 1.4. Matrices de confusión: base conceptual de *precision*, *recall* y *F1*

Las matrices de confusión se usan sobre todo en tareas de clasificación, pero son muy útiles para entender tres conceptos que aparecerán continuamente en evaluación: ***precision***, ***recall*** y ***F1-score***.

En una tarea de clasificación, un sistema puede acertar o equivocarse de varias maneras:

**Tabla 7.** Casos de una matriz de confusión

| Caso                 | Significado                                                   |
|----------------------|---------------------------------------------------------------|
| TP — True Positives  | El sistema predice «positivo» y acierta                       |
| FP — False Positives | El sistema predice «positivo», pero se equivoca               |
| FN — False Negatives | El sistema debería haber predicho «positivo», pero no lo hace |
| TN — True Negatives  | El sistema predice correctamente «negativo»                   |

**Figura 2.** Matriz de confusión y medidas derivadas: *precision*, *recall* y *F1*

### Matriz de confusión

Tabla básica para entender *precision*, *recall* y *F1*

|            |          | Predicción del sistema                                                                                                                               |                                                                                                                                                                |
|------------|----------|------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------|
|            |          | Positivo                                                                                                                                             | Negativo                                                                                                                                                       |
| Valor real | Positivo |  <b>TP (Verdaderos positivos)</b><br>Predice positivo y acierta.    |  <b>FN (Falsos negativos)</b><br>Debería ser positivo, pero predice negativo. |
|            | Negativo |  <b>FP (Falsos positivos)</b><br>Predice positivo, pero es error. |  <b>TN (Verdaderos negativos)</b><br>Predice negativo y acierta.            |

A partir de esta tabla



**Precision** =  $TP / (TP + FP)$



**Recall** =  $TP / (TP + FN)$



**F1** =  $2 \cdot (Precision \cdot Recall) / (Precision + Recall)$

Veámoslo con un ejemplo cercano al Tema 2. Un detector automático de falsos amigos revisa 100 segmentos de una traducción. Según la revisión humana, 20 de ellos contienen realmente un falso amigo y los 80 restantes, no. El sistema marca 25 segmentos como sospechosos: acierta en 15, se equivoca en 10 y deja escapar 5 de los que sí contenían el error. La matriz de confusión ordena estos resultados cruzando lo que ocurre realmente (filas) con lo que predice el sistema (columnas):

**Tabla 8.** Matriz de confusión de un detector de falsos amigos aplicado a 100 segmentos

|                           | Predicción: con falso amigo | Predicción: sin falso amigo |
|---------------------------|-----------------------------|-----------------------------|
| Realidad: con falso amigo | 15 (TP)                     | 5 (FN)                      |
| Realidad: sin falso amigo | 10 (FP)                     | 70 (TN)                     |

Cada celda se lee cruzando su fila y su columna. Los 15 verdaderos positivos (TP) son segmentos con falso amigo que el sistema ha marcado; los 10 falsos positivos (FP), segmentos correctos que ha marcado por error; los 5 falsos negativos (FN), errores reales que no ha visto, y los 70 verdaderos negativos (TN), segmentos correctos que ha dejado pasar con razón. La diagonal (15 y 70) recoge los aciertos, y las otras dos celdas, los dos tipos de error.

A partir de estos valores se calculan medidas como:

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

La **precision** responde a la pregunta: de todo lo que el sistema ha marcado como positivo, ¿cuánto era realmente correcto?

El **recall** responde a otra pregunta: de todo lo que debería haber encontrado, ¿cuánto ha encontrado realmente?

El **F1-score** combina *precision* y *recall* mediante una media armónica. Se utiliza cuando queremos una sola medida que tenga en cuenta tanto los aciertos producidos como los elementos que faltan.

Con los datos del ejemplo, la *precision* es  $15 / (15 + 10) = 0.60$ : de cada diez segmentos que el sistema marca, seis contienen realmente un falso amigo. El *recall* es  $15 / (15 + 5) = 0.75$ : el sistema encuentra tres de cada cuatro falsos amigos reales. El F1 combina ambos valores:  $2 \times 0.60 \times 0.75 / (0.60 + 0.75) \approx 0.67$ . La matriz explica también por qué conviene desconfiar de la exactitud global, es decir, de la proporción de aciertos sobre el total: aquí vale  $(15 + 70) / 100 = 0.85$ , una cifra que parece alta porque la mayoría de los segmentos no tienen error, aunque al sistema se le escape uno de cada cuatro falsos amigos.

En traducción automática no hablamos de verdaderos positivos y falsos positivos exactamente igual que en clasificación, pero podemos trasladar la intuición: una traducción puede producir palabras correctas, omitir palabras importantes o añadir palabras innecesarias.

## 1.5. Métricas léxicas basadas en palabras

Las métricas léxicas comparan la traducción candidata con la referencia a partir de las palabras que aparecen en cada una. Son fáciles de interpretar, pero tienen una limitación importante: normalmente no comprenden el significado, se limitan a contar coincidencias.

### 1.5.1. Precisión léxica

La precisión léxica mide qué proporción de las palabras producidas por el sistema aparecen también en la referencia.

$$Precision = \frac{\text{palabras coincidentes}}{\text{palabras producidas por el sistema}}$$

Ejemplo:

Tabla 9. Ejemplo de cálculo de la precisión léxica

| Referencia            | Hipótesis               |
|-----------------------|-------------------------|
| los árboles son altos | los árboles son grandes |

Coinciden *los*, *árboles* y *son*, y la hipótesis tiene cuatro palabras. Por tanto:

$$Precision = \frac{3}{4} = 0.75$$

La precisión indica que el 75 % de las palabras producidas por el sistema coincide con la referencia, pero no dice si la palabra diferente cambia mucho o poco el significado. En este caso, *grandes* se parece parcialmente a *altos*, aunque no son equivalentes en todos los contextos.

La precisión puede ser engañosa cuando la hipótesis es demasiado corta:

**Tabla 10. Precisión engañosa en una hipótesis demasiado corta**

| Referencia            | Hipótesis   |
|-----------------------|-------------|
| los árboles son altos | los árboles |

Todas las palabras de la hipótesis aparecen en la referencia, pero la traducción está incompleta, y por eso necesitamos también el *recall*.

### 1.5.2. Recall léxico

El *recall* léxico mide qué proporción de las palabras de la referencia recupera la hipótesis.

$$Recall = \frac{\text{palabras coincidentes}}{\text{palabras de la referencia}}$$

Si la referencia es *los árboles son altos* y la hipótesis es *los árboles*, el *recall* es:

$$Recall = \frac{2}{4} = 0.50$$

El *recall* muestra que la hipótesis solo cubre la mitad de la referencia. Esta métrica ayuda a detectar omisiones, porque si el sistema deja sin traducir información importante, el *recall* baja.

La diferencia entre *precision* y *recall* puede explicarse así:

**Tabla 11. Comportamiento de precision y recall según el tipo de traducción**

| Situación                                   | Precisión                         | Recall                           |
|---------------------------------------------|-----------------------------------|----------------------------------|
| Traducción muy breve con palabras correctas | Puede ser alta                    | Suele ser bajo                   |
| Traducción larga con información añadida    | Puede bajar                       | Puede ser alto                   |
| Traducción equilibrada                      | Refleja exactitud de lo producido | Refleja cobertura de lo esperado |

Es decir:

**Tabla 12. Pregunta principal de precision y recall**

| Métrica          | Pregunta principal                                                 |
|------------------|--------------------------------------------------------------------|
| <i>Precision</i> | De lo que ha dicho el sistema, ¿cuánto coincide con la referencia? |
| <i>Recall</i>    | De lo que decía la referencia, ¿cuánto ha recuperado el sistema?   |

### 1.5.3. F1-score léxico

El F1-score combina *precision* y *recall* en una sola puntuación:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

La media armónica penaliza los desequilibrios: si una traducción tiene una precisión muy alta pero un *recall* muy bajo, el F1 no será alto, y por eso resulta útil cuando queremos una medida equilibrada.

Si *precision* y *recall* valen 0.75, entonces:

$$Precision = \frac{3}{4} = 0.75$$

$$Recall = \frac{3}{4} = 0.75$$

$$F1 = 0.75$$

El F1 léxico es más informativo que la *precision* o el *recall* por separado, pero sigue dependiendo de coincidencias de palabras y no entiende de sinonimia, paráfrasis, estilo ni adecuación contextual.

### 1.5.4. Exact Match

Exact Match comprueba si la hipótesis coincide exactamente con la referencia. Es una métrica booleana:

$$Exact Match = \begin{cases} 1, & \text{si la hipótesis es idéntica a la referencia} \\ 0, & \text{si hay cualquier diferencia} \end{cases}$$

Tabla 13. Ejemplos de Exact Match

| Referencia            | Hipótesis                      | Exact Match |
|-----------------------|--------------------------------|-------------|
| los árboles son altos | los árboles son altos          | 1           |
| los árboles son altos | los árboles son muy altos      | 0           |
| los árboles son altos | los árboles tienen gran altura | 0           |

Exact Match es muy fácil de entender, pero demasiado estricta para la traducción automática, porque en las tareas abiertas una respuesta puede ser válida aunque no coincida palabra por palabra con la referencia. Por eso solo suele ser adecuada en tareas cerradas, en las que se espera una respuesta exacta, breve y normalizada.

### 1.5.5. Índice Jaccard

El índice Jaccard mide la similitud entre dos conjuntos. Si consideramos el conjunto de palabras de la referencia y el conjunto de palabras de la hipótesis, Jaccard se calcula así:

$$Jaccard = \frac{|A \cap B|}{|A \cup B|}$$

Donde:

- A es el conjunto de palabras de la referencia.
- B es el conjunto de palabras de la hipótesis.
- $A \cap B$  es la intersección: las palabras compartidas.
- $A \cup B$  es la unión: todas las palabras distintas que aparecen en uno u otro texto.

Ejemplo:

**Tabla 14. Ejemplo de cálculo del índice Jaccard**

| Referencia            | Hipótesis               |
|-----------------------|-------------------------|
| los árboles son altos | los árboles son grandes |

```
Referencia = {los, árboles, son, altos}
Hipótesis = {los, árboles, son, grandes}
Intersección = {los, árboles, son} -> 3
Unión = {los, árboles, son, altos, grandes} -> 5
```

$$\text{Jaccard} = \frac{3}{5} = 0.60$$

Jaccard es intuitivo porque mide el solapamiento léxico, pero ignora el orden y las repeticiones, de modo que no distingue bien entre una frase gramaticalmente correcta y una secuencia desordenada que contenga las mismas palabras.

## 1.6. De palabras aisladas a secuencias: n-gramas

Para evaluar traducción automática no basta con saber si aparecen las mismas palabras; también importa el orden. La frase *el perro muerde al hombre* no significa lo mismo que *el hombre muerde al perro*, aunque contenga casi las mismas palabras.

Un **n-grama** es una secuencia de  $n$  elementos consecutivos, que en evaluación de traducción suelen ser palabras, aunque también pueden ser caracteres.

Con la frase *el gato duerme* obtenemos:

**Tabla 15. N-gramas de la frase *el gato duerme***

| Tipo      | N-gramas              |
|-----------|-----------------------|
| Unigramas | el / gato / duerme    |
| Bigramas  | el gato / gato duerme |
| Trigrama  | el gato duerme        |

Cuanto mayor es el valor de  $n$ , más información sobre el orden se incorpora: los unigramas miran palabras individuales; los bigramas, pares consecutivos, y los trigramas y 4-gramas captan fragmentos más largos de estructura.

Los n-gramas se utilizan en muchas áreas del PLN: modelado de lenguaje, análisis estadístico, detección de patrones, corrección ortográfica, clasificación textual y evaluación automática. En traducción automática tienen mucho peso, porque permiten medir qué palabras aparecen y, además, si aparecen en una secuencia parecida a la de la referencia.

## 1.7. BLEU: la métrica clásica basada en n-gramas

BLEU, sigla de **Bilingual Evaluation Understudy**, es una de las métricas más influyentes en la historia de la traducción automática. La propusieron Papineni *et al.* (2002) como una forma automática, rápida y económica de evaluar sistemas de traducción mediante la comparación entre traducciones generadas y traducciones humanas de referencia.

BLEU parte de una idea sencilla: una buena traducción automática debería compartir muchos n-gramas con una o varias traducciones humanas de referencia. Por eso calcula coincidencias de n-gramas, normalmente desde unigramas hasta 4-gramas.

Ahora bien, BLEU no cuenta sin más todas las coincidencias: utiliza una forma de **precisión modificada**, que evita que un sistema obtenga una puntuación artificialmente alta repitiendo muchas veces una palabra que aparece en la referencia.

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

Ejemplo:

**Tabla 16. Hipótesis que repite una palabra de la referencia**

| Referencia             | Hipótesis mala |
|------------------------|----------------|
| el gato duerme en casa | el el el el el |

Si contáramos coincidencias de forma ingenua, la palabra *el* aparecería muchas veces en la hipótesis y podría producir una puntuación engañosa; BLEU limita las coincidencias según la frecuencia máxima observada en las referencias.

BLEU incorpora además una **penalización por brevedad**, que evita que una traducción demasiado corta obtenga una puntuación alta solo porque las pocas palabras que contiene coinciden con la referencia.

**Tabla 17. Hipótesis afectada por la penalización por brevedad**

| Referencia                        | Hipótesis   |
|-----------------------------------|-------------|
| los árboles son altos y frondosos | los árboles |

La hipótesis contiene palabras correctas, pero omite información. Sin penalización por brevedad podría recibir una precisión relativamente alta, y por eso BLEU reduce la puntuación cuando la hipótesis es mucho más corta que la referencia.

Un ejemplo conceptual:

**Tabla 18. Coincidencias de n-gramas entre referencia e hipótesis**

| Tipo de n-grama | Referencia: esos árboles eran enormes    | Hipótesis: esos árboles eran grandes     | Coincidencias |
|-----------------|------------------------------------------|------------------------------------------|---------------|
| Unigramas       | esos, árboles, eran, enormes             | esos, árboles, eran, grandes             | 3 de 4        |
| Bigramas        | esos árboles, árboles eran, eran enormes | esos árboles, árboles eran, eran grandes | 2 de 3        |
| Trigramas       | esos árboles eran, árboles eran enormes  | esos árboles eran, árboles eran grandes  | 1 de 2        |
| 4-gramas        | esos árboles eran enormes                | esos árboles eran grandes                | 0 de 1        |

Este ejemplo muestra un rasgo esencial de BLEU: un solo cambio léxico puede afectar a varios n-gramas. La sustitución de *enormes* por *grandes* afecta al unigrama, al bigrama, al trigramas y al 4-grama que contienen esa posición.

BLEU tiene ventajas claras:

**Tabla 19. Ventajas de BLEU**

| Ventaja               | Explicación                                                       |
|-----------------------|-------------------------------------------------------------------|
| Es rápida             | Puede calcularse automáticamente sobre grandes corpus             |
| Es reproducible       | Permite comparar sistemas bajo las mismas condiciones             |
| Es sensible al orden  | Los n-gramas captan parte de la secuencia de palabras             |
| Ha sido muy utilizada | Durante años fue una referencia estándar en traducción automática |

Pero también presenta limitaciones importantes:

**Tabla 20. Limitaciones de BLEU**

| Limitación                      | Explicación                                                                |
|---------------------------------|----------------------------------------------------------------------------|
| No entiende el significado      | Solo compara coincidencias superficiales de n-gramas                       |
| Penaliza sinónimos y paráfrasis | Traducciones correctas pueden recibir puntuaciones bajas                   |
| Es poco fiable a nivel de frase | Funciona mejor como medida agregada sobre corpus                           |
| Depende de la referencia        | Si solo hay una referencia, muchas traducciones válidas quedan penalizadas |
| Puede ocultar errores graves    | Una traducción puede compartir n-gramas y aun así alterar el sentido       |

BLEU debe entenderse como una herramienta útil para comparar sistemas en condiciones controladas, y no como una medida absoluta de «buena traducción».

La investigación posterior ha mostrado que la relación entre las métricas automáticas y la evaluación humana puede ser sensible a los datos, al dominio, al tipo de sistema evaluado y a la presencia de valores atípicos. Mathur *et al.* (2020), por ejemplo, subrayan que la comparación entre métricas automáticas y juicios humanos no debe reducirse a una conclusión simple del tipo «esta métrica siempre es mejor». Para un uso responsable, BLEU debe interpretarse como una señal cuantitativa agregada, nunca como un veredicto completo sobre cada frase individual.

### 1.8. chrF y chrF++

chrF es una métrica propuesta por Popović (2015) que evalúa traducciones mediante n-gramas de caracteres en lugar de n-gramas de palabras, una diferencia que importa porque permite detectar similitudes parciales entre palabras.

Mientras BLEU compara palabras o secuencias de palabras completas, chrF compara fragmentos de caracteres. Por ejemplo, entre *traducir*, *traducción* y *traducido* hay diferencias léxicas, pero también una raíz formal compartida, y una métrica basada en caracteres puede captar parte de esa relación.

Ejemplo:

**Tabla 21. Similitud formal por caracteres ante una tilde ausente**

| Referencia           | Hipótesis            |
|----------------------|----------------------|
| internacionalización | internacionalizacion |

Aunque falta la tilde, las dos formas comparten casi todos sus caracteres. Una métrica basada en palabras podría tratarlas como *tokens* distintos, mientras que chrF reconocería una alta similitud formal.

chrF resulta muy interesante para las lenguas con variación morfológica, porque las palabras pueden cambiar por género, número, caso, persona, tiempo verbal o derivación.

**Tabla 22. Variación morfológica entre referencia e hipótesis**

| Referencia                                   | Hipótesis                                  |
|----------------------------------------------|--------------------------------------------|
| los investigadores analizaron los resultados | las investigadoras analizaron el resultado |

Hay diferencias de género y número, pero también mucho solapamiento formal entre *investigadores* e *investigadoras*, y entre *resultados* y *resultado*. chrF puede captar parte de esa proximidad formal, aunque no determine por sí sola si la traducción es correcta.

Sus ventajas principales son:

**Tabla 23. Ventajas de chrF**

| Ventaja | Explicación |
|---------|-------------|
|---------|-------------|

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

|                                                            |                                                 |
|------------------------------------------------------------|-------------------------------------------------|
| Capta similitudes parciales                                | No exige que las palabras coincidan exactamente |
| Es menos dependiente de la tokenización                    | Trabaja con caracteres                          |
| Puede funcionar bien en lenguas morfológicamente complejas | Reconoce parentescos formales entre variantes   |
| Es fácil de aplicar                                        | No requiere entrenamiento de modelos neuronales |

También tiene límites:

**Tabla 24. Limitaciones de chrF**

| Limitación                                                                 | Explicación                                                                    |
|----------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| Sigue siendo superficial                                                   | No comprende realmente el significado                                          |
| Puede premiar palabras formalmente parecidas pero semánticamente distintas | La forma parecida no garantiza equivalencia                                    |
| No evalúa adecuación respecto al texto fuente                              | Como muchas métricas con referencia, compara sobre todo hipótesis y referencia |

chrF++ incorpora también n-gramas de palabras, de modo que mira tanto fragmentos de caracteres como secuencias léxicas. Puede resultar útil cuando queremos añadir algo de sensibilidad al orden de palabras, pero para una introducción es menos transparente, porque mezcla dos niveles: caracteres y palabras.

### 1.9. METEOR: coincidencias flexibles y penalización por desorden

Banerjee y Lavie (2005) propusieron METEOR, sigla de **Metric for Evaluation of Translation with Explicit ORdering**, con el objetivo de mejorar la correlación con los juicios humanos respecto a las métricas basadas exclusivamente en la precisión de n-gramas.

La idea principal de METEOR es comparar hipótesis y referencia mediante correspondencias más flexibles que la coincidencia exacta. En su formulación clásica, METEOR puede considerar:

- coincidencias exactas;
- coincidencias por raíz (*stemming*);
- coincidencias mediante sinónimos;
- penalizaciones cuando las palabras coincidentes aparecen en un orden muy fragmentado.

Esto la acerca a la forma en que una persona podría comparar dos frases: además de preguntar «¿son iguales las palabras?», pregunta «¿hay palabras relacionadas?» y «¿aparecen en un orden razonable?».

METEOR se inspira en la *precision* y el *recall*, pero no los utiliza de forma tan simple como las métricas léxicas básicas: da más peso al *recall*, porque en traducción es fundamental que no se pierda información relevante.

El cálculo de METEOR puede entenderse en tres pasos:

- **Alineación.** Se emparejan las palabras de la hipótesis con las de la referencia: primero las idénticas, después las que comparten raíz y, por último, los sinónimos. Cada palabra solo puede emparejarse una vez.
- **Media ponderada de precision y recall.** Con las palabras emparejadas se calculan *precision* y *recall* y se combinan dando más peso al *recall*.
- **Penalización por fragmentación.** Se comprueba si las palabras emparejadas aparecen agrupadas y en el mismo orden que en la referencia, o dispersas.

La media ponderada se denomina *Fmean*:

$$F_{mean} = \frac{Precision \times Recall}{\alpha \times Precision + (1 - \alpha) \times Recall}$$

El parámetro  $\alpha$  controla el equilibrio entre *precision* y *recall*. En la formulación original y en NLTK,  $\alpha = 0.9$ , de modo que el *recall* pesa nueve veces más que la *precision*. Por eso la fórmula clásica se escribe a veces como  $10 \cdot P \cdot R / (R + 9 \cdot P)$ .

Para medir el desorden, METEOR cuenta **fragmentos** (*chunks*): grupos de palabras emparejadas que aparecen contiguas y en el mismo orden en la hipótesis y en la referencia. Si todas las coincidencias forman un solo bloque, hay un fragmento; si están completamente dispersas, hay tantos fragmentos como coincidencias.

$$\text{Penalización} = \gamma \times \left( \frac{\text{fragmentos}}{\text{coincidencias}} \right)^\beta$$

Con los valores habituales,  $\gamma = 0.5$  y  $\beta = 3$ , la penalización nunca supera 0.5. La puntuación final combina ambos elementos y se expresa en escala 0–1:

$$\text{METEOR} = F_{\text{mean}} \times (1 - \text{Penalización})$$

Veamos el cálculo con el ejemplo de *recall* del apartado 1.5.2:

**Tabla 25. Ejemplo de cálculo de METEOR**

| Referencia            | Hipótesis   |
|-----------------------|-------------|
| los árboles son altos | los árboles |

Hay dos coincidencias (*los* y *árboles*), que forman un único fragmento:

$$\begin{aligned} \text{Precision} &= \frac{2}{2} = 1 & \text{Recall} &= \frac{2}{4} = 0.50 \\ F_{\text{mean}} &= \frac{1 \times 0.50}{0.9 \times 1 + 0.1 \times 0.50} = \frac{0.50}{0.95} \approx 0.526 \\ \text{Penalización} &= 0.5 \times \left( \frac{1}{2} \right)^3 = 0.0625 \\ \text{METEOR} &= 0.526 \times (1 - 0.0625) \approx 0.49 \end{aligned}$$

El F1 léxico de esta misma pareja sería 0.67. METEOR baja hasta 0.49 porque da mucho más peso al *recall*: la hipótesis es correcta en lo que dice, pero omite la mitad de la referencia.

Ejemplo de coincidencia por sinónimos:

**Tabla 26. Coincidencia por sinónimos en METEOR**

| Referencia                      | Hipótesis                          |
|---------------------------------|------------------------------------|
| the doctor examined the patient | the physician examined the patient |

Una métrica estrictamente léxica penalizaría *doctor* frente a *physician*, mientras que METEOR puede reconocer esa relación si dispone del recurso léxico adecuado, como WordNet para el inglés.

Con la implementación de NLTK, que usa WordNet, la hipótesis con *physician* obtiene 0.996, exactamente lo mismo que una hipótesis idéntica a la referencia: el emparejamiento por sinónimo cuenta como coincidencia completa.

Además, METEOR penaliza el desorden:

**Tabla 27. Penalización por desorden en METEOR**

| Referencia                  | Hipótesis A                 | Hipótesis B                 |
|-----------------------------|-----------------------------|-----------------------------|
| the child opened the window | the child opened the window | window the opened child the |

Las dos hipótesis pueden compartir palabras con la referencia, pero solo la primera respeta el orden sintáctico. Desde un punto de vista lingüístico, esta penalización es relevante porque el orden de palabras afecta a la gramaticalidad, a la interpretación semántica y a la estructura informativa.

En números, la hipótesis A obtiene 0.996: sus cinco coincidencias forman un único fragmento y la penalización es mínima,  $0.5 \times (1/5)^3 = 0.004$ . La hipótesis B tiene las mismas cinco coincidencias, pero ninguna aparece contigua y en el orden de la referencia: cinco fragmentos, penalización  $0.5 \times (5/5)^3 = 0.5$  y METEOR = 0.50.

Este ejemplo también muestra que METEOR casi nunca llega exactamente a 1: incluso una hipótesis idéntica a la referencia recibe una pequeña penalización, porque siempre hay al menos un fragmento.

Conviene tener en cuenta que muchas implementaciones de METEOR se han desarrollado sobre todo para el inglés, entre otras razones por la disponibilidad de recursos como WordNet. Eso no impide aplicar la idea a otras lenguas, pero su rendimiento depende de los recursos lingüísticos disponibles.

En la práctica, la configuración por defecto de NLTK usa el *stemmer* de Porter, diseñado para inglés, y el WordNet inglés para los sinónimos. En textos en español, METEOR se apoya casi solo en coincidencias exactas y en la penalización por orden. En el apartado 2.11 se verá cómo sustituir el *stemmer* por uno para español.

Para estudiantes con perfil lingüístico, esta observación resulta muy útil. Una métrica es algo más que una fórmula matemática: depende también de decisiones lingüísticas previas, como la lematización, el *stemming*, la sinonimia o la disponibilidad de bases léxicas. Por eso dos implementaciones de una misma métrica pueden comportarse de forma distinta en función de la lengua, del dominio y de los recursos que utilicen.

Las ventajas principales de METEOR pueden resumirse así:

**Tabla 28. Ventajas de METEOR**

| Ventaja                                     | Explicación                                                                           |
|---------------------------------------------|---------------------------------------------------------------------------------------|
| Es más flexible que una coincidencia exacta | Puede reconocer raíces o sinónimos si dispone de recursos adecuados                   |
| Combina <i>precision</i> y <i>recall</i>    | Además de lo que produce la hipótesis, mira lo que recupera de la referencia          |
| Penaliza el desorden                        | Tiene en cuenta si las coincidencias aparecen fragmentadas o en un orden poco natural |
| Se aproxima mejor a ciertos juicios humanos | Su diseño intenta reflejar mejor diferencias lingüísticas relevantes                  |

Sus limitaciones también son importantes:

**Tabla 29. Limitaciones de METEOR**

| Limitación                                     | Explicación                                                                               |
|------------------------------------------------|-------------------------------------------------------------------------------------------|
| Depende de recursos lingüísticos               | Funciona mejor cuando hay analizadores, listas de raíces o bases de sinónimos disponibles |
| Puede estar sesgada hacia determinadas lenguas | Muchas versiones se desarrollaron sobre todo para inglés                                  |
| Sigue sin comprender plenamente el significado | Reconoce correspondencias más flexibles, pero no interpreta como una persona              |
| Es menos inmediata que BLEU o Jaccard          | Requiere más explicación y más decisiones de configuración                                |

## 1.10. Comparación general de métricas clásicas

Las métricas clásicas pueden organizarse en varios grupos:

**Tabla 30. Grupos de métricas clásicas**

| Grupo                                                       | Métricas                                                    | Qué comparan principalmente                   |
|-------------------------------------------------------------|-------------------------------------------------------------|-----------------------------------------------|
| Métricas léxicas simples                                    | <i>Precision</i> , <i>recall</i> , F1, Exact Match, Jaccard | Palabras individuales o conjuntos de palabras |
| Métricas basadas en n-gramas                                | BLEU                                                        | Secuencias de palabras                        |
| Métricas basadas en caracteres o correspondencias flexibles | chrF, METEOR                                                | Caracteres, raíces, sinónimos y orden         |

Cada grupo responde a una pregunta diferente:

**Tabla 31. Pregunta a la que responde cada métrica clásica**

| Pregunta                                                       | Métrica adecuada                      |
|----------------------------------------------------------------|---------------------------------------|
| ¿Cuántas palabras coinciden?                                   | <i>Precision</i> , <i>recall</i> , F1 |
| ¿La traducción es exactamente igual a la referencia?           | Exact Match                           |
| ¿Cuánto solapamiento léxico hay?                               | Jaccard                               |
| ¿Coinciden secuencias de palabras?                             | BLEU                                  |
| ¿Hay similitud formal entre palabras?                          | chrF                                  |
| ¿Hay coincidencias exactas, morfológicas o semánticas básicas? | METEOR                                |

Por tanto, ninguna métrica clásica cubre todos los aspectos de una traducción, y en investigación y desarrollo se recomienda interpretar varias conjuntamente y, cuando sea posible, complementarlas con evaluación humana.

### 1.11. Métricas semánticas o neuronales

Las métricas clásicas se diseñaron en una época en la que la evaluación automática dependía principalmente de coincidencias superficiales. La traducción automática neuronal ha cambiado el escenario: los sistemas actuales pueden producir paráfrasis más fluidas, reformular estructuras y alejarse de la referencia sin ser necesariamente incorrectos.

Ejemplo:

**Tabla 32. Paráfrasis y cambio de sentido frente a una misma referencia**

| Referencia                      | Hipótesis A                       | Hipótesis B                               | Hipótesis C                    |
|---------------------------------|-----------------------------------|-------------------------------------------|--------------------------------|
| El comité rechazó la propuesta. | El comité no aceptó la propuesta. | La propuesta fue rechazada por el comité. | El comité aprobó la propuesta. |

Una métrica basada en n-gramas puede penalizar la hipótesis B porque cambia la estructura sintáctica, aunque sea semánticamente equivalente. En cambio, la hipótesis C comparte varias palabras con la referencia, pero cambia el sentido principal: *rechazó* frente a *aprobó*.

Ejemplos como estos motivaron el desarrollo de métricas que, en lugar de limitarse a contar palabras, utilizaran representaciones semánticas aprendidas por modelos neuronales. BERTScore, BLEURT y COMET pertenecen a esta familia.

Una métrica semántica o neuronal utiliza modelos de lenguaje entrenados con grandes cantidades de texto para representar palabras, frases o documentos como vectores, conocidos como *embeddings* o representaciones distribucionales. La idea básica es que, si dos palabras o frases tienen significados parecidos, sus representaciones vectoriales deberían estar relativamente próximas en el espacio semántico aprendido por el modelo.

No obstante, conviene presentar estas métricas con prudencia. Que una métrica utilice un modelo neuronal no significa que «entienda» el texto como una persona. Sus puntuaciones dependen del modelo utilizado, de los datos de entrenamiento, de las lenguas disponibles, de la tarea y de la forma en que se haya ajustado la métrica a juicios humanos.

#### 1.11.1. BERTScore

BERTScore, propuesta por Zhang *et al.* (2020), evalúa la generación textual con representaciones contextuales de modelos tipo BERT: en lugar de comprobar si dos palabras son exactamente iguales, compara la similitud entre los *embeddings* contextuales de los *tokens* de la hipótesis y los de la referencia.

La palabra **contextual** es fundamental. En modelos como BERT, una palabra no tiene siempre la misma representación, porque su vector cambia según el contexto: *banco* no se representa igual en *me senté en el banco* que en *fui al banco a sacar dinero*.

BERTScore puede explicarse en tres pasos:

Codifica la hipótesis y la referencia con un modelo de lenguaje preentrenado.

Compara cada *token* de la hipótesis con los *tokens* de la referencia mediante similitud vectorial.

Calcula puntuaciones análogas a *precision*, *recall* y F1, pero basadas en similitud semántica.

Ejemplo:

**Tabla 33. Ejemplo para BERTScore**

| Referencia                     | Hipótesis                     |
|--------------------------------|-------------------------------|
| El médico examinó al paciente. | El doctor revisó al paciente. |

Una métrica léxica solo reconocerá coincidencias como *el*, *al* y *paciente*, mientras que BERTScore puede asignar una similitud alta entre *médico* y *doctor*, y cierta similitud entre *examinó* y *revisó*.

Ventajas:

**Tabla 34. Ventajas de BERTScore**

| Ventaja                                                        | Explicación                                           |
|----------------------------------------------------------------|-------------------------------------------------------|
| Reconoce similitud semántica                                   | Puede valorar palabras distintas pero relacionadas    |
| Usa contexto                                                   | La representación de cada palabra depende de la frase |
| Mantiene la intuición de <i>precision</i> , <i>recall</i> y F1 | Conecta con métricas ya vistas                        |
| Es aplicable a varias tareas de generación textual             | No se limita a traducción automática                  |

Limitaciones:

**Tabla 35. Limitaciones de BERTScore**

| Limitación                                         | Explicación                                                   |
|----------------------------------------------------|---------------------------------------------------------------|
| Depende del modelo preentrenado                    | La calidad varía según lengua y modelo                        |
| No siempre detecta errores graves                  | Puede asignar similitud alta a frases parecidas pero opuestas |
| No evalúa necesariamente fidelidad al texto fuente | En su forma habitual compara hipótesis y referencia           |
| Es menos transparente que BLEU                     | La puntuación depende de representaciones internas            |

BERTScore puede presentarse como una métrica que sustituye la pregunta «¿coinciden las palabras?» por otra más flexible: «¿se parecen las palabras en contexto?». Esa transición ayuda a entender por qué las métricas modernas se alejan de la coincidencia literal y se acercan a representaciones semánticas. Aun así, BERTScore no equivale a una lectura humana del texto: es una comparación entre representaciones aprendidas por un modelo.

### 1.11.2. BLEURT

BLEURT, propuesta por Sellam *et al.* (2020), es una métrica aprendida basada en BERT. A diferencia de BERTScore, que se apoya principalmente en las similitudes entre *embeddings*, BLEURT se entrena expresamente para predecir juicios humanos de calidad.

La diferencia importa: además de utilizar un modelo neuronal para representar frases, BLEURT aprende a asignar una puntuación parecida a la que darían evaluadores humanos.

Puede explicarse así:

1. Se parte de un modelo de lenguaje preentrenado, como BERT.  
Se adapta el modelo a la tarea de evaluación.  
El sistema aprende patrones que suelen corresponderse con buenas o malas salidas.  
Ante una nueva hipótesis, produce una puntuación que intenta aproximar el juicio humano.

Ejemplo:

**Tabla 36. Ejemplo para BLEURT**

| Referencia                                  | Hipótesis A                                   | Hipótesis B                              |
|---------------------------------------------|-----------------------------------------------|------------------------------------------|
| La empresa anunció una reducción de costes. | La compañía comunicó una reducción de gastos. | La empresa anunció un aumento de costes. |

La hipótesis A cambia palabras, pero mantiene un significado parecido. La hipótesis B comparte más vocabulario superficial con la referencia, pero altera el sentido con *aumento* frente a *reducción*. BLEURT se diseñó para ser más sensible a este tipo de diferencias semánticas que una métrica puramente léxica.

Las ventajas de BLEURT son:

**Tabla 37. Ventajas de BLEURT**

| Ventaja                               | Explicación                                                       |
|---------------------------------------|-------------------------------------------------------------------|
| Aprende de juicios humanos            | Intenta aproximar cómo valorarían las personas la calidad textual |
| Capta relaciones semánticas complejas | No depende solo de coincidencias de palabras                      |
| Puede resistir bien las paráfrasis    | Penaliza menos algunas reformulaciones válidas                    |
| Es útil en generación textual         | Puede aplicarse a evaluación más allá de la traducción automática |

Sus limitaciones son:

**Tabla 38. Limitaciones de BLEURT**

| Limitación                            | Explicación                                                                |
|---------------------------------------|----------------------------------------------------------------------------|
| Es una métrica aprendida              | Su comportamiento depende de los datos de entrenamiento                    |
| Puede heredar sesgos de los datos     | Si los datos son limitados o sesgados, la métrica puede reflejarlo         |
| Es menos interpretable                | No siempre es fácil explicar por qué asigna una puntuación concreta        |
| Puede variar entre dominios y lenguas | Una métrica entrenada en ciertos datos no siempre generaliza igual de bien |

BLEURT sirve muy bien para explicar que una métrica automática puede ser también un modelo supervisado, que aprende a evaluar a partir de ejemplos en lugar de aplicar solo una fórmula.

### 1.11.3. COMET

COMET, sigla de **Crosslingual Optimized Metric for Evaluation of Translation**, es una métrica neuronal diseñada específicamente para la evaluación de la traducción automática. Rei *et al.* (2020) la presentaron como un marco neuronal multilingüe que puede aprovechar información del texto fuente, de la hipótesis y de la referencia.

En esto se diferencia de muchas métricas anteriores. BLEU, chrF, METEOR, BERTScore y BLEURT suelen centrarse principalmente en la comparación entre hipótesis y referencia, mientras que COMET puede incorporar también el texto fuente, algo muy relevante en traducción automática.

Ejemplo:

**Tabla 39. Error de negación que invierte el significado**

| Texto fuente                               | Referencia                             | Hipótesis                           |
|--------------------------------------------|----------------------------------------|-------------------------------------|
| The patient did not receive the treatment. | El paciente no recibió el tratamiento. | El paciente recibió el tratamiento. |

La hipótesis se parece mucho a la referencia, porque solo falta *no*, pero el error es grave: invierte el significado. Una métrica que observe el texto fuente puede estar en mejores condiciones para detectar problemas de adecuación.

COMET puede entenderse así:

1. Codifica el texto fuente, la hipótesis y la referencia mediante un modelo multilingüe.
2. Combina esas representaciones.
3. Predice una puntuación de calidad entrenada para correlacionar con juicios humanos.

Su interés didáctico reside en que muestra una evolución clara: de comparar palabras, pasamos a comparar significados; y de comparar solo hipótesis y referencia, pasamos a incorporar también el texto fuente.

Las ventajas de COMET son:

**Tabla 40. Ventajas de COMET**

| Ventaja                                  | Explicación                                                 |
|------------------------------------------|-------------------------------------------------------------|
| Está diseñada para traducción automática | Va más allá de una métrica general de generación textual    |
| Puede usar el texto fuente               | Ayuda a valorar la adecuación de la traducción              |
| Se entrena con juicios humanos           | Busca correlacionar con evaluaciones humanas de calidad     |
| Es multilingüe                           | Aprovecha modelos preentrenados multilingües o interlingües |

Sus limitaciones son:

**Tabla 41. Limitaciones de COMET**

| Limitación                            | Explicación                                                                       |
|---------------------------------------|-----------------------------------------------------------------------------------|
| Requiere modelos complejos            | Es más costosa computacionalmente que BLEU o chrF                                 |
| Es menos transparente                 | Su puntuación no se explica mediante simples coincidencias de n-gramas            |
| Depende de los datos de entrenamiento | Puede funcionar mejor en lenguas y dominios representados en sus datos            |
| No sustituye a la evaluación humana   | Puede fallar ante fenómenos pragmáticos, terminológicos o discursivos específicos |

Una forma sencilla de compararlas es formular la pregunta que parece hacerse cada métrica:

**Tabla 42. Pregunta intuitiva de cada métrica neuronal**

| Métrica   | Pregunta intuitiva                                                                                                   | Nivel recomendado en esta asignatura |
|-----------|----------------------------------------------------------------------------------------------------------------------|--------------------------------------|
| BERTScore | «¿Se parecen semánticamente las palabras de la hipótesis y la referencia en su contexto?»                            | Comprensión teórica                  |
| BLEURT    | «Según lo aprendido de evaluaciones humanas, ¿qué calidad parece tener esta salida?»                                 | Comprensión teórica                  |
| COMET     | «Teniendo en cuenta el texto fuente, la hipótesis y la referencia, ¿qué calidad traductológica tiene la traducción?» | Comprensión teórica                  |

También pueden compararse por el tipo de información que utilizan:

**Tabla 43. Información que utiliza cada métrica neuronal**

| Métrica   | Tipo                                             | Qué compara                    | Idea central                                                  |
|-----------|--------------------------------------------------|--------------------------------|---------------------------------------------------------------|
| BERTScore | Métrica basada en <i>embeddings</i> contextuales | Hipótesis y referencia         | Compara <i>tokens</i> mediante similitud semántica contextual |
| BLEURT    | Métrica neuronal aprendida                       | Hipótesis y referencia         | Aprende a predecir juicios humanos usando BERT                |
| COMET     | Métrica neuronal para traducción automática      | Fuente, hipótesis y referencia | Predice calidad traductológica con modelos multilingües       |

## 1.12. Cómo interpretar las métricas

Para el alumnado de segundo curso, la idea más importante es que las métricas no deben interpretarse como verdades absolutas. Toda métrica simplifica la realidad: la traducción abarca

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

significado, gramática, pragmática, estilo, terminología, adecuación al encargo y naturalidad, y ninguna puntuación numérica recoge todo eso por sí sola.

Conviene retener cuatro ideas:

1. Toda métrica simplifica la realidad.
2. Las métricas clásicas son más transparentes, pero menos semánticas.
3. Las métricas neuronales son más flexibles, pero menos interpretables.
4. La evaluación humana sigue siendo necesaria.

La evaluación automática de traducciones ha evolucionado desde métricas basadas en coincidencias superficiales hasta métricas neuronales entrenadas para aproximarse a los juicios humanos. Las métricas léxicas simples introducen los conceptos básicos de comparación textual; BLEU incorpora el orden mediante n-gramas; chrF añade flexibilidad al trabajar con caracteres; METEOR incorpora correspondencias más flexibles, y BERTScore, BLEURT y COMET representan una transición hacia la comparación semántica.

Para una estudiante de Tecnologías del Lenguaje, lo esencial es entender que evaluar traducciones va mucho más allá de calcular una puntuación: hay que saber qué aspecto de la calidad recoge cada métrica, qué se le escapa y para qué tipo de decisión sirve.

## 2. Evaluación automática con Python

### 2.1. Preparar los textos antes de medir

Antes de calcular métricas, necesitamos preparar los textos, porque si no lo hacemos, diferencias irrelevantes pueden contaminar los resultados.

Imagina estas dos frases:

**Tabla 44.** *Diferencias irrelevantes entre referencia e hipótesis*

| Referencia      | Hipótesis        |
|-----------------|------------------|
| Mi casa es azul | mi casa es azul. |

Desde el punto de vista lingüístico, son prácticamente iguales. Pero si Python compara las palabras de forma literal, puede considerar distintas *Mi* y *mi*, o «azul» y «azul.». Para evitarlo, se aplica una limpieza mínima:

- pasar todo a minúsculas;
- quitar signos de puntuación;
- dividir el texto en palabras.

Una función sencilla para limpiar palabras puede ser:

```
def limpiar_palabra(palabra):
    return palabra.strip('.,;:!?";'\'() [] {}')
```

Esta función recibe una palabra y elimina los signos de puntuación del principio o del final. Después podemos procesar una frase completa:

```
def procesar_texto(texto):
    texto = texto.lower()
    palabras = texto.split()
    palabras = [limpiar_palabra(p) for p in palabras]
    return palabras
```

Aquí aparecen varias ideas importantes:

**Tabla 45. Líneas de la función de procesamiento**

| Línea                                               | Qué hace                        |
|-----------------------------------------------------|---------------------------------|
| <code>texto.lower()</code>                          | Convierte todo a minúsculas     |
| <code>texto.split()</code>                          | Divide el texto por espacios    |
| <code>[limpiar_palabra(p) for p in palabras]</code> | Limpia cada palabra de la lista |
| <code>return palabras</code>                        | Devuelve la lista procesada     |

El resultado ya no es una frase en forma de `string`, sino una lista de *tokens*:

```
referencia = "Los árboles son altos."
traduccion_prueba = "Los arboles estan grandes"

referencia_proc = procesar_texto(referencia)
traduccion_prueba_proc = procesar_texto(traduccion_prueba)

print("Referencia:", referencia_proc)
print("Traducción:", traduccion_prueba_proc)
```

La limpieza no es una operación inocente: simplifica el texto para poder comparar. En una evaluación real habría que decidir si se quieren conservar tildes, signos, mayúsculas, puntuación o una segmentación más fina; en esta unidad usamos una limpieza básica porque permite entender la lógica de las métricas.

## 2.2. Precision léxica con Python

La precisión léxica pregunta: de todas las palabras que ha producido la traducción automática, ¿cuántas aparecen también en la referencia?

En Python se puede calcular así:

```
palabras_correctas = sum(
    1
    for palabra in traduccion_prueba_proc
    if palabra in referencia_proc
)

precision = palabras_correctas / len(traduccion_prueba_proc)

print(f"Precisión: {precision:.2f}")
```

La expresión `sum(1 for palabra in traduccion_prueba_proc if palabra in referencia_proc)` recorre cada palabra de la traducción automática y, si esa palabra está también en la referencia, suma 1.

En el caso:

**Tabla 46. Referencia e hipótesis procesadas**

| Referencia procesada                            | Hipótesis procesada                                 |
|-------------------------------------------------|-----------------------------------------------------|
| <code>['los', 'árboles', 'son', 'altos']</code> | <code>['los', 'arboles', 'estan', 'grandes']</code> |

solo coincide *los*, porque *árboles* y *arboles* no son idénticas por la tilde, *son* y *estan* son diferentes, y *altos* y *grandes* no coinciden. La precisión sería:

```
Precision = 1 / 4 = 0.25
```

Este resultado enseña algo importante: la métrica no sabe que *árboles* y *arboles* son variantes casi idénticas salvo por la tilde, ni que *altos* y *grandes* pueden estar semánticamente relacionados. Solo compara formas.

### 2.3. Traducción automática con `deep-translator`

Para generar una traducción automática desde Python puede usarse la biblioteca `deep-translator`, que permite acceder a varios motores de traducción en línea, entre ellos Google Translate.

La instalación en un entorno interactivo puede hacerse así:

```
%pip install deep-translator
```

Después se importa la clase `GoogleTranslator`:

```
from deep_translator import GoogleTranslator
```

Y se genera la traducción:

```
original = "Those trees were big."

tradu_auto = GoogleTranslator(
    source="en",
    target="es"
).translate(original)

print("Traducción automática:", tradu_auto)
```

Los argumentos `source` y `target` indican la lengua de origen y la de destino: en este ejemplo, `source="en"` indica inglés y `target="es"`, español.

Una vez obtenida la traducción automática, se procesan los tres textos:

```
original_proc = procesar_texto(original)
tradu_humana_proc = procesar_texto(tradu_humana)
tradu_auto_proc = procesar_texto(tradu_auto)
```

Para las métricas léxicas, normalmente compararemos `tradu_auto_proc` con `tradu_humana_proc`. El texto fuente queda como contexto traductológico, aunque algunas métricas clásicas no lo usen directamente.

### 2.4. Recall léxico

El *recall* léxico pregunta: de todas las palabras que aparecen en la referencia humana, ¿cuántas ha recuperado la traducción automática?

En Python:

```
recall = sum(
    1
    for palabra in tradu_humana_proc
    if palabra in tradu_auto_proc
) / len(tradu_humana_proc)

print(f"Recall léxico: {recall:.2f}")
```

La estructura es muy parecida a la de la *precision*, pero cambia el punto de vista: en la *precision* recorremos la traducción automática; en el *recall*, la referencia.

Esta diferencia es lingüísticamente importante:

**Tabla 47. Punto de vista de *precision* y *recall***

| Métrica          | Punto de vista        | Pregunta                                       |
|------------------|-----------------------|------------------------------------------------|
| <i>Precision</i> | Traducción automática | ¿Cuánto de lo que produjo el sistema coincide? |
| <i>Recall</i>    | Referencia humana     | ¿Cuánto de lo esperado se ha recuperado?       |

Una traducción puede tener una *precision* alta y un *recall* bajo si produce pocas palabras, pero correctas, y también un *recall* relativamente alto y una *precision* más baja si produce muchas palabras añadidas.

## 2.5. F1-score

El F1-score combina *precision* y *recall*. Para evitar errores cuando ambas métricas valen cero, conviene comprobar antes que la suma sea mayor que cero:

```
if precision + recall > 0:
    f1 = 2 * (precision * recall) / (precision + recall)
else:
    f1 = 0

print(f"F1-score: {f1:.2f}")
```

La condición `if precision + recall > 0` evita una división entre cero. Este detalle técnico tiene una lectura metodológica: no siempre hay coincidencias entre hipótesis y referencia, y si no hay ninguna, el F1 debe ser cero.

El F1 resulta útil cuando queremos una medida equilibrada: si una traducción produce muchas palabras correctas, pero omite mucha información, el F1 no se disparará, y si recupera mucho vocabulario, pero introduce muchas palabras ausentes de la referencia, tampoco será perfecto.

## 2.6. Exact Match

Exact Match es la métrica más estricta. Comprueba si las listas procesadas son idénticas:

```
exact_match = tradu_auto_proc == tradu_humana_proc

print(f"Exact Match: {'Sí' if exact_match else 'No'}")
```

La expresión `tradu_auto_proc == tradu_humana_proc` devuelve `True` si ambas listas son exactamente iguales y `False` si hay cualquier diferencia.

Así, Exact Match será No si:

- cambia una palabra;
- falta una tilde que no se ha normalizado;
- cambia el orden;
- aparece una palabra adicional;
- se omite una palabra;
- se usa un sinónimo.

Por eso Exact Match es útil para enseñar la idea de coincidencia estricta, pero no suele ser una buena métrica para evaluar traducciones naturales, que admiten variación.

## 2.7. Índice Jaccard

El índice Jaccard compara conjuntos de palabras. En Python, los conjuntos se crean con `set()`:

```
set_auto = set(tradu_auto_proc)
set_humana = set(tradu_humana_proc)

jaccard = len(set_auto & set_humana) / len(set_auto | set_humana)

print(f"Índice Jaccard: {jaccard:.2f}")
```

Jaccard ignora el orden y las repeticiones, de modo que puede servir para medir el solapamiento de vocabulario, pero no para evaluar la estructura sintáctica.

En el ejemplo *Esos árboles eran enormes* frente a *Esos árboles eran grandes*, los conjuntos son:

```
Automática = {esos, árboles, eran, grandes}
Humana = {esos, árboles, eran, enormes}
Intersección = {esos, árboles, eran}
Unión = {esos, árboles, eran, grandes, enormes}
Jaccard = 3 / 5 = 0.60
```

La puntuación es inferior a *precision* y *recall* porque Jaccard compara el vocabulario compartido con todo el vocabulario distinto que aparece en ambas traducciones.

## 2.8. Informe de métricas léxicas

Cuando se calculan varias métricas, conviene presentarlas juntas:

```
print(f"Precisión léxica: {precision:.2f}")
print(f"Recall léxico: {recall:.2f}")
print(f"F1-score: {f1:.2f}")
print(f"Exact Match: {'Sí' if exact_match else 'No'}")
print(f"Índice Jaccard: {jaccard:.2f}")
```

Un conjunto de resultados puede ser:

**Tabla 48. Informe de métricas léxicas**

| Métrica          | Valor | Lectura                                                                  |
|------------------|-------|--------------------------------------------------------------------------|
| Precisión léxica | 0.75  | El 75 % de las palabras generadas coincide con la referencia             |
| Recall léxico    | 0.75  | Se recupera el 75 % de la referencia                                     |
| F1-score         | 0.75  | Hay equilibrio entre <i>precision</i> y <i>recall</i>                    |
| Jaccard          | 0.60  | El vocabulario compartido representa el 60 % del vocabulario total único |
| Exact Match      | No    | Las frases no son idénticas                                              |

La interpretación profesional sería esta: la traducción automática es bastante buena desde el punto de vista léxico, pero no idéntica, y cambiar una palabra por otra próxima puede hacer que Exact Match sea No, aunque otras métricas sigan siendo altas.

## 2.9. BLEU con NLTK

BLEU se puede calcular con `nltk`:

```
import nltk
from nltk.translate.bleu_score import sentence_bleu, SmoothingFunction
```

Para evaluar una frase, `sentence_bleu()` espera una lista de referencias y una candidata:

```
reference = [tradu_humana_proc]
candidate = tradu_auto_proc

bleu = sentence_bleu(
    reference,
    candidate,
    smoothing_function=SmoothingFunction().method1
)

print(f"BLEU: {bleu:.2f}")
```

Hay dos detalles importantes:

5. `reference = [tradu_humana_proc]` usa una lista de listas porque BLEU permite comparar una hipótesis con varias referencias.
6. `SmoothingFunction().method1` suaviza el cálculo para evitar que BLEU sea cero en frases cortas cuando no hay coincidencias de n-gramas largos.

En el caso *Esos árboles eran enormes* frente a *Esos árboles eran grandes*, el resultado puede sorprender, porque la puntuación BLEU puede rondar 0.40: las frases solo cambian en una palabra, pero esa palabra rompe varios n-gramas.

**Tabla 49.** *Coincidencias de n-gramas en el caso de los árboles*

| Nivel     | Coincidencias |
|-----------|---------------|
| Unigramas | 3 de 4        |
| Bigramas  | 2 de 3        |
| Trigramas | 1 de 2        |
| 4-gramas  | 0 de 1        |

BLEU combina estas precisiones mediante un promedio geométrico, de modo que, si un nivel tiene cero coincidencias, la puntuación baja mucho. El suavizado evita que el resultado sea cero, pero no elimina la penalización.

La lectura lingüística es clara: más que palabras sueltas, BLEU mide continuidad formal, y por eso una diferencia en la última palabra afecta a toda la secuencia final.

## 2.10. chrF con `evaluate`

Para calcular chrF puede usarse la biblioteca `evaluate`, junto con `sacrebleu`:

```
!pip install evaluate sacrebleu -q
```

Después se carga la métrica:

```
from evaluate import load

chrF_metric = load("chrF")
```

chrF trabaja con el texto completo, y no con listas de palabras procesadas, de modo que conviene usar las cadenas originales:

```
resultado_chrF = chrF_metric.compute(
    predictions=[tradu_auto],
    references=[tradu_humana]
)

print(f"chrF: {resultado_chrF['score']:.2f}")
```

El resultado de `compute()` es un diccionario cuya clave `score` contiene la puntuación principal.

Conviene recordar que BLEU y METEOR aparecen en escala 0–1 en NLTK, mientras que chrF en `evaluate` suele aparecer en escala 0–100. Por tanto, los números no deben compararse directamente sin mirar la escala.

**Tabla 50.** *Lectura orientativa de chrF*

| Valor de chrF | Lectura orientativa                                                  |
|---------------|----------------------------------------------------------------------|
| Bajo          | Hay poca similitud formal entre hipótesis y referencia               |
| Medio         | Hay coincidencias parciales, pero también diferencias                |
| Alto          | La hipótesis se parece mucho a la referencia en su forma lingüística |

chrF no comprende plenamente el significado ni la calidad estilística, pero complementa a BLEU cuando hay variaciones morfológicas o pequeñas diferencias formales.

## 2.11. METEOR con NLTK

METEOR también está disponible en `nltk`. Antes de usarlo hay que descargar WordNet, el recurso léxico que emplea para buscar sinónimos:

```
import nltk
from nltk.translate.meteor_score import meteor_score

nltk.download("wordnet")
nltk.download("omw-1.4")
```

Como `sentence_bleu()`, la función `meteor_score()` recibe una lista de referencias y una hipótesis, ambas ya tokenizadas:

```
meteor = meteor_score(
    [tradu_humana_proc],
    tradu_auto_proc
)

print(f"METEOR: {meteor:.2f}")
```

Hay dos detalles importantes:

- `[tradu_humana_proc]` es una lista de listas, igual que en BLEU. Si se proporcionan varias referencias, METEOR se queda con la puntuación más alta.
- Las entradas deben ser listas de palabras, no cadenas de texto: si se pasa una frase sin tokenizar, las versiones recientes de NLTK producen un error (`TypeError`).

En el caso *Esos árboles eran enormes* frente a *Esos árboles eran grandes*, METEOR da 0.74, mientras que BLEU se quedaba en torno a 0.40:

**Tabla 51. BLEU frente a METEOR en el caso de los árboles**

| Métrica | Valor | Por qué                                                                |
|---------|-------|------------------------------------------------------------------------|
| BLEU    | 0.40  | La sustitución de una palabra rompe bigramas, trigramas y el 4-grama   |
| METEOR  | 0.74  | Tres de cuatro palabras coinciden y forman un único fragmento ordenado |

El contraste es instructivo. METEOR alinea palabras individuales y solo después mira el orden, por lo que castiga menos una sustitución aislada; pero tampoco reconoce *grandes* y *enormes* como equivalentes, porque en español no dispone de sinónimos.

**METEOR en español.** Por defecto, `meteor_score()` utiliza el *stemmer* de Porter, pensado para inglés, y el WordNet inglés para los sinónimos. En español, la fase de sinónimos no actúa y la de raíces solo acierta por casualidad, aunque esta última puede mejorarse pasando un *stemmer* para español mediante el argumento `stemmer`:

```
from nltk.stem import SnowballStemmer

stemmer_es = SnowballStemmer("spanish")

referencia = "el informe muestra que la inflación baja".split()
hipotesis = "los informes muestran que la inflación bajó".split()

print(meteor_score([referencia], hipotesis))
print(meteor_score([referencia], hipotesis, stemmer=stemmer_es))
```

**Tabla 52. METEOR con distintos stemmers en español**

| Configuración                           | METEOR | Qué ocurre                                                                               |
|-----------------------------------------|--------|------------------------------------------------------------------------------------------|
| Por defecto (Porter)                    | 0.54   | Solo empareja <i>informe/informes</i> , que Porter reduce por casualidad a la misma raíz |
| <code>SnowballStemmer("spanish")</code> | 0.86   | Además empareja <i>muestra/muestran</i> y <i>baja/bajó</i>                               |

De ahí se desprende que METEOR es una familia de configuraciones, más que un número único, y al informar de un resultado conviene indicar qué *stemmer* y qué recurso de sinónimos se han usado.

Como con chrF, la escala orienta la lectura:

**Tabla 53. Lectura orientativa de METEOR**

| Valor de METEOR | Lectura orientativa                                                                    |
|-----------------|----------------------------------------------------------------------------------------|
| Bajo            | La hipótesis recupera pocas palabras de la referencia, o las recupera muy desordenadas |
| Medio           | Hay coincidencias, pero faltan palabras o el orden está fragmentado                    |
| Alto            | La hipótesis recupera casi toda la referencia en un orden parecido                     |

METEOR complementa a BLEU: es menos severo con las sustituciones aisladas y más sensible a las omisiones, porque prioriza el *recall*. El cuaderno de práctica sobre METEOR de esta unidad aplica la métrica a ejemplos en español de los ámbitos médico, jurídico y económico.

## 2.12. Todas las métricas en un mismo informe

Una salida de evaluación completa puede reunir las métricas principales:

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

```
print(f"Precisión: {precision:.2f}")
print(f"Recall: {recall:.2f}")
print(f"F1-score: {f1:.2f}")
print(f"Jaccard: {jaccard:.2f}")
print(f"BLEU: {bleu:.2f}")
print(f"chrF: {resultado_chrf['score']:.2f}")
print(f"METEOR: {meteor:.2f}")
print(f"Exact Match: {'Si' if exact_match else 'No'})")
```

El informe no debe limitarse a imprimir números; debe incluir una interpretación:

**Tabla 54. Pregunta interpretativa de cada métrica**

| Métrica          | Pregunta interpretativa                                                                               |
|------------------|-------------------------------------------------------------------------------------------------------|
| <i>Precision</i> | ¿Cuánto de lo producido por la máquina coincide?                                                      |
| <i>Recall</i>    | ¿Cuánto de la referencia se recupera?                                                                 |
| F1               | ¿Hay equilibrio entre exactitud y cobertura?                                                          |
| Jaccard          | ¿Cuánto vocabulario único comparten las versiones?                                                    |
| BLEU             | ¿Coinciden secuencias de palabras?                                                                    |
| chrF             | ¿Hay similitud formal por caracteres?                                                                 |
| METEOR           | ¿Se recuperan las palabras de la referencia, aunque sea por raíz o sinónimo, y en un orden razonable? |
| Exact Match      | ¿Son idénticas las versiones?                                                                         |

Esta interpretación es la parte lingüística del trabajo. Python calcula; la especialista explica.

## 2.13. Cómo leer casos con sinónimos y reformulación

Un caso de especial interés es aquel en que la traducción automática usa sinónimos:

**Tabla 55. Traducción con sinónimos y reformulación**

| Referencia                                                                                                | Hipótesis                                                                                                   |
|-----------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------|
| Los estudiantes escuchaban atentos mientras el profesor explicaba con calma los conceptos clave del tema. | Los alumnos prestaban atención mientras el docente exponía tranquilamente las ideas principales del asunto. |

Desde el punto de vista semántico, las frases pueden transmitir una idea parecida, pero las métricas basadas en coincidencias literales bajarán mucho:

- *estudiantes* y *alumnos* no son la misma cadena;
- *profesor* y *docente* no coinciden formalmente;
- *explicaba* y *exponía* son diferentes;
- *con calma* y *tranquilamente* son expresiones distintas;
- *conceptos clave* e *ideas principales* son reformulaciones.

Exact Match será No. BLEU puede ser muy bajo, porque las secuencias de palabras no coinciden, y Jaccard también bajará, porque el vocabulario compartido es reducido. chrF puede conservar algo más de información si hay fragmentos de caracteres compartidos, pero tampoco reconocerá del todo la equivalencia semántica. METEOR, que en inglés podría emparejar sinónimos gracias a WordNet, se comporta en español casi como una métrica de coincidencia exacta: en este ejemplo se queda alrededor de 0.21.

La conclusión profesional no debe ser «la traducción es mala» solo porque las métricas bajen. Lo correcto es una conclusión más precisa: las métricas de coincidencia formal penalizan la sinonimia y la reformulación, y por tanto hace falta evaluación humana o métricas semánticas para valorar si el significado se conserva.

## 2.14. Buenas prácticas para interpretar resultados

Cuando se evalúan traducciones automáticas con Python, conviene seguir varias buenas prácticas:

- **No interpretar una métrica aislada.** Un solo número puede ser engañoso.
- **Mirar qué mide cada métrica.** *Precision* no mide lo mismo que BLEU, y BLEU no mide lo mismo que chrF.
- **Revisar la escala.** BLEU y METEOR en NLTK usan 0–1; chrF en `evaluate` usa 0–100.
- **Distinguir forma y significado.** Coincidencia formal no siempre equivale a calidad semántica.
- **Tener en cuenta la longitud.** BLEU puede comportarse de forma inestable en frases cortas.
- **Documentar la configuración.** METEOR cambia según el *stemmer* y los sinónimos disponibles; conviene indicar cuáles se han usado, sobre todo en lenguas distintas del inglés.
- **Explicar los resultados con ejemplos.** Una interpretación sin evidencia textual queda débil.
- **Recordar la referencia.** Si solo hay una traducción humana, muchas alternativas válidas pueden salir penalizadas.
- **Complementar con juicio lingüístico.** Las métricas orientan, pero no sustituyen la evaluación experta.

Una forma profesional de redactar una interpretación sería: *La traducción automática presenta una coincidencia léxica moderada-alta con la referencia, como muestran precision, recall y F1. Sin embargo, Exact Match es negativo porque existe al menos una diferencia formal. BLEU baja más que las métricas léxicas simples porque una sustitución léxica rompe varios n-gramas. chrF permite observar si, pese a las diferencias de palabra completa, existe similitud formal por caracteres. METEOR se mantiene más alto que BLEU porque alinea palabras individuales y solo penaliza el desorden, lo que confirma que la diferencia se concentra en una sola palabra. En conjunto, los resultados sugieren una traducción aceptable desde el punto de vista formal, pero la decisión final requiere revisar si la diferencia léxica afecta al significado y al encargo traductológico.*

## 2.15. Qué aporta Python a la evaluación lingüística

Python permite convertir una pregunta evaluativa en un procedimiento reproducible: en lugar de decir de forma vaga «esta traducción se parece bastante a la humana», podemos calcular varias medidas y justificar una interpretación.

La aportación de Python se resume en cuatro acciones:

**Tabla 56. Aportación de Python a la evaluación lingüística**

| Acción               | Resultado                                |
|----------------------|------------------------------------------|
| Limpiar textos       | Reduce ruido superficial                 |
| Tokenizar            | Convierte frases en unidades comparables |
| Calcular métricas    | Produce indicadores cuantitativos        |
| Presentar resultados | Facilita una interpretación argumentada  |

Pero Python no decide por sí solo si una traducción es adecuada. Una métrica puede señalar que dos frases se parecen poco en la forma, aunque sean equivalentes en significado, o que se parecen mucho, aunque una contenga un error semántico grave.

La competencia de una lingüista computacional consiste precisamente en ocupar ese espacio intermedio: entender el cálculo, conocer sus límites y traducir el número en una interpretación lingüística responsable.

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

## Errores frecuentes de aprendizaje

---

- Confundir una puntuación alta con una evaluación humana completa.
- Interpretar Exact Match = No como si la traducción fuera necesariamente incorrecta.
- Comparar BLEU, chrF y METEOR sin comprobar antes la escala de cada métrica.
- Olvidar que la limpieza previa del texto modifica los resultados.
- Usar una sola métrica para decidir la calidad global de una traducción.
- No distinguir entre texto fuente, hipótesis y referencia.
- Pasar por alto que los sinónimos y las paráfrasis pueden ser correctos aunque bajen las métricas formales.
- Aplicar METEOR a textos en español con la configuración por defecto de NLTK sin advertir que su *stemmer* y sus sinónimos están pensados para inglés.

## Síntesis final

---

La evaluación automática de traducciones permite comparar una hipótesis con una referencia y obtener puntuaciones reproducibles. Las métricas léxicas simples, como *precision*, *recall*, F1, Exact Match y Jaccard, introducen la lógica básica de coincidencia textual. BLEU añade n-gramas y penalización por brevedad. chrF compara caracteres y resulta más flexible ante variación morfológica. METEOR, BERTScore, BLEURT y COMET amplían la mirada hacia correspondencias más flexibles, similitud semántica y adecuación traductológica.

En Python, estas ideas se traducen en operaciones concretas: limpiar textos, dividirlos en palabras, contar coincidencias, usar conjuntos, calcular n-gramas y llamar a bibliotecas especializadas. Pero el aprendizaje de fondo es interpretativo: una métrica es una herramienta para formular mejores preguntas sobre la calidad de una traducción, y no una sentencia.

## Cierre narrativo

---

Volvamos al encargo de NexaLingua Quality Lab. El equipo ya tiene un pequeño sistema capaz de comparar una traducción automática con una referencia humana, y aunque el informe no sustituye a la revisión profesional, permite priorizar.

Si la *precision*, el *recall* y el F1 son altos, puede haber una coincidencia léxica notable. Si Jaccard es más bajo, puede haber variación de vocabulario. Si BLEU baja mucho, quizá las secuencias no coinciden aunque el contenido sea próximo. Si chrF es alto, puede haber similitud formal incluso cuando no todas las palabras coinciden. Si METEOR se mantiene alto aunque BLEU baje, las palabras de la referencia están presentes y en un orden razonable, aunque no formen secuencias largas idénticas. Y si Exact Match es No, eso solo indica que no hay identidad total, lo que no equivale a una mala traducción.

El equipo puede usar el informe para decidir:

- qué segmentos revisar primero;
- qué motor parece más regular;
- qué casos merecen evaluación humana detallada;
- qué métricas conviene usar en cada tipo de texto;
- qué limitaciones deben explicarse al cliente.

Calcular métricas es solo la parte visible de esta unidad; lo que de verdad se ejercita es una manera de pensar propia de una lingüista que trabaja con herramientas computacionales: precisión técnica, prudencia interpretativa y atención al significado.

Los derechos de este material pertenecen a la Dr.<sup>a</sup> Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

## Referencias

---

- Banerjee, S. y Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. En *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization* (pp. 65–72). Association for Computational Linguistics. <https://aclanthology.org/W05-0909/>
- Mathur, N., Baldwin, T. y Cohn, T. (2020). Tangled up in BLEU: Reevaluating the evaluation of automatic machine translation evaluation metrics. En *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 4984–4997). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.acl-main.448>
- Papineni, K., Roukos, S., Ward, T. y Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. En *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics* (pp. 311–318). Association for Computational Linguistics. <https://doi.org/10.3115/1073083.1073135>
- Popović, M. (2015). chrF: Character n-gram F-score for automatic MT evaluation. En *Proceedings of the Tenth Workshop on Statistical Machine Translation* (pp. 392–395). Association for Computational Linguistics. <https://doi.org/10.18653/v1/W15-3049>
- Rei, R., Stewart, C., Farinha, A. C. y Lavie, A. (2020). COMET: A neural framework for MT evaluation. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)* (pp. 2685–2702). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.emnlp-main.213>
- Sellam, T., Das, D. y Parikh, A. P. (2020). BLEURT: Learning robust metrics for text generation. En *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 7881–7892). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.acl-main.704>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q. y Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. En *International Conference on Learning Representations (ICLR 2020)*. <https://openreview.net/forum?id=SkeHuCVFDr>