

Tema 5.

Evaluación automática de traducciones

Métricas léxicas, BLEU, chrF, METEOR y métricas neuronales: cálculo e interpretación de resultados para PLN

Material teórico | Programación para PLN | Universidad Pontificia Comillas

Dr.^a Blanca Hernández Pardo

Índice de contenidos

Título narrativo.....	1
Contexto profesional.....	1
Encargo: auditoría rápida de traducción automática.....	1
El caso de trabajo.....	1
Qué vas a aprender en esta unidad.....	2
Mapa conceptual de la unidad.....	2
1. Marco teórico.....	3
1.1. Por qué necesitamos métricas automáticas.....	3
1.2. Texto fuente, hipótesis y referencia.....	3
1.3. Qué tipos de similitud puede observar una métrica.....	4
1.4. Matrices de confusión: base conceptual de <i>precision</i> , <i>recall</i> y <i>F1</i>	4
1.5. Métricas léxicas basadas en palabras.....	5
1.5.1. Precisión léxica.....	5
1.5.2. <i>Recall</i> léxico.....	6
1.5.3. F1-score léxico.....	7
1.5.4. Exact Match.....	7
1.5.5. Índice Jaccard.....	7
1.6. De palabras aisladas a secuencias: n-gramas.....	8
1.7. BLEU: la métrica clásica basada en n-gramas.....	8
1.8. chrF y chrF++.....	10
1.9. METEOR: coincidencias flexibles y penalización por desorden.....	11
1.10. Comparación general de métricas clásicas.....	13
1.11. Métricas semánticas o neuronales.....	13
1.11.1. BERTScore.....	14
1.11.2. BLEURT.....	15
1.11.3. COMET.....	16
1.12. Cómo interpretar las métricas.....	17
2. Evaluación automática con Python.....	18
2.1. Preparar los textos antes de medir.....	18
2.2. <i>Precision</i> léxica con Python.....	19

2.3. Traducción automática con deep-translator.....	20
2.4. <i>Recall</i> léxico.....	20
2.5. F1-score.....	21
2.6. Exact Match.....	21
2.7. Índice Jaccard.....	22
2.8. Informe de métricas léxicas.....	22
2.9. BLEU con NLTK.....	23
2.10. chrF con evaluate.....	23
2.11. METEOR con NLTK.....	24
2.12. Todas las métricas en un mismo informe.....	25
2.13. Cómo leer casos con sinónimos y reformulación.....	26
2.14. Buenas prácticas para interpretar resultados.....	26
2.15. Qué aporta Python a la evaluación lingüística.....	27
Errores frecuentes de aprendizaje.....	27
Síntesis final.....	28
Cierre narrativo.....	28
Referencias.....	28

Título narrativo

Evaluación automática de traducciones: medir, interpretar y decidir con criterio lingüístico.

Contexto profesional

Encargo: auditoría rápida de traducción automática

Imagina que te incorporas al equipo de evaluación lingüística de **NexaLingua Quality Lab**, una consultora especializada en control de calidad lingüística, evaluación de traducción automática y diseño de flujos de revisión para organizaciones multilingües. La empresa trabaja con instituciones públicas, editoriales científicas y departamentos de comunicación internacional que necesitan publicar textos fiables en varias lenguas.

NexaLingua no se presenta como una agencia que sustituye a traductores y revisores, sino como un laboratorio de evaluación aplicada: su trabajo consiste en medir, comparar y explicar la calidad de distintas salidas lingüísticas para que los equipos humanos puedan tomar mejores decisiones. En esta unidad, la empresa recibe un encargo concreto: un cliente institucional quiere explorar un flujo mixto de traducción automática más revisión humana.

El cliente no pide una respuesta abstracta sobre si la traducción automática es «buena» o «mala». Necesita una decisión operativa:

- Qué motor de traducción parece producir resultados más próximos a la referencia humana.
- Qué tipos de errores se detectan con métricas automáticas.
- Qué puntuaciones son útiles para priorizar la revisión.
- Qué limitaciones tienen esas puntuaciones.
- Qué casos siguen necesitando evaluación humana.

Tu tarea consiste en construir un pequeño informe de evaluación. El equipo te proporciona un texto fuente, una traducción humana de referencia y una traducción automática. A partir de ahí, debes calcular varias métricas y, sobre todo, interpretarlas.

El valor profesional de este trabajo no está solo en obtener números. Está en saber leerlos. Una precisión de 0.75 no significa automáticamente «traducción excelente». Un BLEU de 0.40 no significa automáticamente «traducción inútil». Cada métrica mide una dimensión concreta y deja fuera otras.

El caso de trabajo

El caso inicial es deliberadamente sencillo:

Papel	Texto
Texto fuente	Those trees were big.
Referencia humana	Esos árboles eran enormes.
Traducción automática	Esos árboles eran grandes.

La traducción automática no es absurda. Grandes y enormes están relacionadas semánticamente, aunque no sean idénticas. Por eso este caso es perfecto para aprender evaluación automática: las métricas basadas en coincidencia formal detectarán una diferencia, pero una lingüista deberá interpretar si esa diferencia es grave, aceptable o dependiente del contexto.

La simulación se puede formular como una pregunta profesional:

> Si una traducción automática se parece mucho a la referencia, pero cambia una palabra por otra próxima, ¿cómo reaccionan las métricas automáticas?

Esta pregunta acompaña toda la unidad.

Qué vas a aprender en esta unidad

Al terminar este tema, deberías poder explicar y aplicar los siguientes conocimientos:

1. Qué es una traducción automática y por qué hay que evaluarla.
2. Qué diferencia hay entre texto fuente, hipótesis y referencia.
3. Por qué una traducción puede ser correcta aunque no coincida exactamente con una referencia.
4. Cómo limpiar textos antes de compararlos.
5. Cómo convertir una frase en una lista de palabras procesadas.
6. Cómo calcular precisión léxica con Python.
7. Cómo calcular *recall* léxico.
8. Cómo combinar *precision* y *recall* mediante F1-score.
9. Cómo comprobar Exact Match.
10. Cómo calcular índice Jaccard con conjuntos.
11. Cómo interpretar un conjunto de métricas léxicas.
12. Qué mide BLEU y por qué utiliza n-gramas.
13. Por qué BLEU puede bajar mucho en frases cortas.
14. Para qué sirve el suavizado o smoothing en BLEU.
15. Qué mide chrF y por qué compara caracteres.
16. Por qué chrF puede complementar a BLEU.
17. Qué mide METEOR y por qué su resultado depende de recursos lingüísticos.
18. Cómo usar bibliotecas como deep-translator, nltk y evaluate.
19. Cómo redactar una interpretación crítica de resultados automáticos.

Mapa conceptual de la unidad

Concepto	En Python	En evaluación lingüística
Referencia	Variable con traducción humana	Punto de comparación
Hipótesis	Variable con traducción automática	Salida que queremos evaluar
Limpieza	.lower(), .strip(), eliminación de puntuación	Evita diferencias irrelevantes
Tokenización básica	.split()	Divide el texto en palabras
<i>Precision</i>	Coincidencias sobre total generado	Exactitud léxica de lo producido
<i>Recall</i>	Coincidencias sobre total de referencia	Cobertura respecto a lo esperado
F1-score	Fórmula con <i>precision</i> y <i>recall</i>	Equilibrio entre exactitud y cobertura
Exact Match	==	Coincidencia total palabra por palabra
Jaccard	Intersección sobre unión de conjuntos	Solapamiento léxico
BLEU	sentence_bleu()	Coincidencia de n-gramas
chrF	evaluate.load("chrF")	Similitud formal por caracteres
METEOR	meteor_score()	Coincidencias flexibles y orden
Interpretación	Texto argumentado	Juicio lingüístico sobre las puntuaciones

1. Marco teórico

1.1. Por qué necesitamos métricas automáticas

En procesamiento del lenguaje natural y, de forma muy especial, en traducción automática, necesitamos valorar hasta qué punto la salida producida por un sistema se parece a una traducción humana de calidad. Cuando un motor traduce una frase, no basta con comprobar que haya generado una secuencia gramatical. También debemos preguntarnos si conserva el contenido del texto fuente, si respeta la estructura informativa, si utiliza un vocabulario adecuado, si mantiene la terminología esperada y si resulta natural en la lengua de llegada.

La evaluación ideal sería siempre una evaluación humana realizada por traductores, lingüistas o anotadores expertos. Una persona puede detectar matices que una fórmula no ve: ambigüedad, ironía, estilo, adecuación pragmática, errores de sentido o problemas terminológicos. Sin embargo, la evaluación humana tiene límites prácticos. Es costosa, requiere tiempo, puede variar según el criterio de cada evaluador y no siempre resulta viable cuando se comparan muchos sistemas o grandes volúmenes de traducciones.

Por esa razón se utilizan **métricas automáticas**: procedimientos que asignan una puntuación cuantitativa a una traducción de forma rápida, reproducible y relativamente barata. Estas métricas permiten comparar sistemas, detectar tendencias, analizar experimentos y decidir qué traducciones necesitan más revisión humana.

Ahora bien, una métrica automática no debe confundirse con una verdad absoluta. Una puntuación es un indicador, no una explicación completa de la calidad. La competencia lingüística sigue siendo necesaria para interpretar qué mide esa puntuación, qué deja fuera y en qué contexto puede utilizarse con sentido.

1.2. Texto fuente, hipótesis y referencia

En evaluación automática de traducción se suelen comparar tres elementos:

Elemento	Definición	Ejemplo
Texto fuente	Texto original que se quería traducir	The child opened the window.
Hipótesis o traducción candidata	Traducción generada por el sistema	El menor abrió la ventana.
Referencia	Traducción humana considerada válida	El niño abrió la ventana.

Muchas métricas clásicas comparan únicamente la hipótesis con la referencia. Es decir, no evalúan directamente si la hipótesis expresa correctamente el texto fuente, sino si se parece a una traducción humana disponible. Esta idea es crucial, porque la traducción es una tarea abierta: una misma frase puede traducirse de varias formas aceptables.

Por ejemplo:

Texto fuente	Referencia	Hipótesis
The child opened the window.	El niño abrió la ventana.	El menor abrió la ventana.

Desde el punto de vista lingüístico, la hipótesis puede ser adecuada en muchos contextos. Sin embargo, una métrica basada en coincidencias exactas de palabras penalizará la diferencia entre niño y menor. El ejemplo muestra uno de los problemas centrales de la evaluación automática: las métricas son útiles, pero no «entienden» la traducción del mismo modo que una persona.

Tener varias referencias humanas suele mejorar la evaluación, porque permite reconocer más de una traducción válida:

Texto fuente	Referencia 1	Referencia 2
The trees are tall.	Los árboles son altos.	Los árboles tienen mucha altura.

Si solo existe la primera referencia, una hipótesis como Los árboles tienen mucha altura podría ser penalizada aunque sea correcta. Por eso la dependencia de una única referencia es una de las grandes limitaciones de muchas métricas clásicas.

1.3. Qué tipos de similitud puede observar una métrica

No todas las métricas observan lo mismo. Algunas comparan palabras exactas; otras comparan secuencias; otras se fijan en caracteres; otras intentan aproximarse al significado mediante modelos neuronales.

Tipo de similitud	Qué observa	Ejemplo
Similitud superficial	Coincidencia de palabras o caracteres	altos = altos
Similitud estructural	Coincidencia de secuencias u orden	los árboles son
Similitud semántica	Coincidencia de significado	coche ≈ automóvil
Adecuación traductológica	Fidelidad al texto fuente	¿La traducción expresa lo mismo?
Fluidez	Naturalidad en la lengua meta	¿Suena bien en español?

Las métricas clásicas suelen medir sobre todo similitud superficial y estructural. Las métricas neuronales intentan aproximarse mejor a la similitud semántica y, en algunos casos, a la adecuación respecto al texto fuente.

La conclusión inicial es sencilla: no existe una métrica que evalúe por sí sola todos los aspectos de una traducción. Por eso conviene combinar varias métricas e interpretarlas con prudencia.

1.4. Matrices de confusión: base conceptual de *precision*, *recall* y *F1*

Las matrices de confusión se usan sobre todo en tareas de clasificación, pero son muy útiles para entender tres conceptos que aparecerán continuamente en evaluación: ***precision***, ***recall*** y ***F1-score***.

En una tarea de clasificación, un sistema puede acertar o equivocarse de varias maneras:

Caso	Significado
TP — True Positives	El sistema predice «positivo» y acierta
FP — False Positives	El sistema predice «positivo», pero se equivoca
FN — False Negatives	El sistema debería haber predicho «positivo», pero no lo hace
TN — True Negatives	El sistema predice correctamente «negativo»

Matriz de confusión

Tabla básica para entender precision, recall y F1

		Predicción del sistema	
		Positivo	Negativo
Valor real	Positivo	 TP (Verdaderos positivos) Predice positivo y acierta.	 FN (Falsos negativos) Debería ser positivo, pero predice negativo.
	Negativo	 FP (Falsos positivos) Predice positivo, pero es error.	 TN (Verdaderos negativos) Predice negativo y acierta.

A partir de esta tabla



$$\text{Precision} = \frac{TP}{TP + FP}$$



$$\text{Recall} = \frac{TP}{TP + FN}$$



$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

A partir de estos valores se calculan medidas como:

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

La **precision** responde a la pregunta: de todo lo que el sistema ha marcado como positivo, ¿cuánto era realmente correcto?

El **recall** responde a otra pregunta: de todo lo que debería haber encontrado, ¿cuánto ha encontrado realmente?

El **F1-score** combina **precision** y **recall** mediante una media armónica. Se utiliza cuando queremos una sola medida que tenga en cuenta tanto los aciertos producidos como los elementos que faltan.

En traducción automática no hablamos de verdaderos positivos y falsos positivos exactamente igual que en clasificación. Sin embargo, podemos trasladar la intuición: una traducción puede producir palabras correctas, omitir palabras importantes o añadir palabras innecesarias.

1.5. Métricas léxicas basadas en palabras

Las métricas léxicas comparan la traducción candidata con la referencia a partir de las palabras que aparecen en cada una. Son fáciles de interpretar, pero tienen una limitación importante: normalmente no comprenden el significado. Cuentan coincidencias.

1.5.1. Precisión léxica

La precisión léxica mide qué proporción de las palabras producidas por el sistema aparecen también en la referencia.

$$\text{Precision} = \frac{\text{palabras coincidentes}}{\text{palabras producidas por el sistema}}$$

Ejemplo:

Referencia	Hipótesis
los árboles son altos	los árboles son grandes

Coinciden los, árboles y son. La hipótesis tiene cuatro palabras. Por tanto:

$$Precision = \frac{3}{4} = 0.75$$

La precisión indica que el 75 % de las palabras producidas por el sistema coincide con la referencia. Pero no nos dice si la palabra diferente cambia mucho o poco el significado. En este caso, grandes se parece parcialmente a altos, pero no son equivalentes en todos los contextos.

La precisión puede ser engañosa cuando la hipótesis es demasiado corta:

Referencia	Hipótesis
los árboles son altos	los árboles

Todas las palabras de la hipótesis aparecen en la referencia, pero la traducción está incompleta. Por eso necesitamos también *recall*.

1.5.2. Recall léxico

El *recall* léxico mide qué proporción de las palabras de la referencia han sido recuperadas por la hipótesis.

$$Recall = \frac{\text{palabras coincidentes}}{\text{palabras de la referencia}}$$

Si la referencia es los árboles son altos y la hipótesis es los árboles, el *recall* es:

$$Recall = \frac{2}{4} = 0.50$$

El *recall* muestra que la hipótesis solo cubre la mitad de la referencia. Esta métrica ayuda a detectar omisiones: si el sistema deja sin traducir información importante, el *recall* baja.

La diferencia entre *precision* y *recall* puede explicarse así:

Situación	Precision	Recall
Traducción muy breve con palabras correctas	Puede ser alta	Suele ser bajo
Traducción larga con información añadida	Puede bajar	Puede ser alto
Traducción equilibrada	Refleja exactitud de lo producido	Refleja cobertura de lo esperado

Es decir:

Métrica	Pregunta principal
<i>Precision</i>	De lo que ha dicho el sistema, ¿cuánto coincide con la referencia?
<i>Recall</i>	De lo que decía la referencia, ¿cuánto ha recuperado el sistema?

1.5.3. F1-score léxico

El F1-score combina *precision* y *recall* en una sola puntuación:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

La media armónica penaliza los desequilibrios. Si una traducción tiene una precisión muy alta pero un *recall* muy bajo, el F1 no será alto. Por eso resulta útil cuando queremos una medida equilibrada.

Si *precision* y *recall* valen 0.75, entonces:

$$Precision = \frac{3}{4} = 0.75$$

$$Recall = \frac{3}{4} = 0.75$$

$$F1 = 0.75$$

El F1 léxico es más informativo que *precision* o *recall* por separado, pero sigue dependiendo de coincidencias de palabras. No entiende sinonimia, paráfrasis, estilo ni adecuación contextual.

1.5.4. Exact Match

Exact Match comprueba si la hipótesis coincide exactamente con la referencia. Es una métrica booleana:

$$Exact\ Match = \begin{cases} 1, & \text{si la hipótesis es idéntica a la referencia} \\ 0, & \text{si hay cualquier diferencia} \end{cases}$$

Referencia	Hipótesis	Exact Match
los árboles son altos	los árboles son altos	1
los árboles son altos	los árboles son muy altos	0
los árboles son altos	los árboles tienen gran altura	0

Exact Match es muy fácil de entender, pero demasiado estricta para traducción automática. En tareas abiertas, una respuesta puede ser válida aunque no coincida palabra por palabra con la referencia. Por eso Exact Match solo suele ser adecuada en tareas cerradas, donde se espera una respuesta exacta, breve y normalizada.

1.5.5. Índice Jaccard

El índice Jaccard mide la similitud entre dos conjuntos. Si consideramos el conjunto de palabras de la referencia y el conjunto de palabras de la hipótesis, Jaccard se calcula así:

$$Jaccard = \frac{|A \cap B|}{|A \cup B|}$$

Donde:

- A es el conjunto de palabras de la referencia.
- B es el conjunto de palabras de la hipótesis.
- $A \cap B$ es la intersección: las palabras compartidas.
- $A \cup B$ es la unión: todas las palabras distintas que aparecen en uno u otro texto.

Ejemplo:

Referencia	Hipótesis
los árboles son altos	los árboles son grandes

```

Referencia = {los, árboles, son, altos}
Hipótesis = {los, árboles, son, grandes}
Intersección = {los, árboles, son} -> 3
Unión = {los, árboles, son, altos, grandes} -> 5

      3
Jaccard = ---- = 0.60
      5

```

Jaccard es intuitivo porque mide solapamiento léxico. Sin embargo, ignora el orden y las repeticiones. Por tanto, no distingue bien entre una frase gramaticalmente correcta y una secuencia desordenada que contenga las mismas palabras.

1.6. De palabras aisladas a secuencias: n-gramas

Para evaluar traducción automática no basta con saber si aparecen las mismas palabras. También importa el orden. La frase el perro muerde al hombre no significa lo mismo que el hombre muerde al perro, aunque contenga casi las mismas palabras.

Un **n-grama** es una secuencia de n elementos consecutivos. En evaluación de traducción, esos elementos suelen ser palabras, aunque también pueden ser caracteres.

Con la frase el gato duerme, obtenemos:

Tipo	N-gramas
Unigramas	el / gato / duerme
Bigramas	el gato / gato duerme
Trigrama	el gato duerme

Cuanto mayor es el valor de n , más información sobre el orden se incorpora. Los unigramas miran palabras individuales. Los bigramas observan pares consecutivos. Los trigramas y 4-gramas captan fragmentos más largos de estructura.

Los n-gramas se utilizan en muchas áreas del PLN: modelado de lenguaje, análisis estadístico, detección de patrones, corrección ortográfica, clasificación textual y evaluación automática. En traducción automática son especialmente importantes porque permiten medir no solo qué palabras aparecen, sino también si aparecen en una secuencia similar a la referencia.

1.7. BLEU: la métrica clásica basada en n-gramas

BLEU, sigla de **Bilingual Evaluation Understudy**, es una de las métricas más influyentes en la historia de la traducción automática. Fue propuesta por Papineni et al. (2002) como una forma automática, rápida y económica de evaluar sistemas de traducción mediante la comparación entre traducciones generadas y traducciones humanas de referencia.

BLEU se basa en una idea sencilla: una buena traducción automática debería compartir muchos n-gramas con una o varias traducciones humanas de referencia. Por eso BLEU calcula coincidencias de n-gramas, normalmente desde unigramas hasta 4-gramas.

Sin embargo, BLEU no cuenta simplemente todas las coincidencias. Utiliza una forma de **precisión modificada**, que evita que un sistema obtenga una puntuación artificialmente alta repitiendo muchas veces una palabra que aparece en la referencia.

Ejemplo:

Referencia	Hipótesis mala
el gato duerme en casa	el el el el el

Si contáramos coincidencias de forma ingenua, la palabra *el* aparecería muchas veces en la hipótesis y podría producir una puntuación engañosa. BLEU limita las coincidencias según la frecuencia máxima observada en las referencias.

BLEU incorpora además una **penalización por brevedad**. Esta penalización evita que una traducción demasiado corta obtenga una puntuación alta solo porque las pocas palabras que contiene coinciden con la referencia.

Referencia	Hipótesis
los árboles son altos y frondosos	los árboles

La hipótesis contiene palabras correctas, pero omite información. Sin penalización por brevedad, podría recibir una precisión relativamente alta. BLEU reduce la puntuación cuando la hipótesis es mucho más corta que la referencia.

Un ejemplo conceptual:

Tipo de n-grama	Referencia: esos árboles eran enormes	Hipótesis: esos árboles eran grandes	Coincidencias
Unigramas	esos, árboles, eran, enormes	esos, árboles, eran, grandes	3 de 4
Bigramas	esos árboles, árboles eran, eran enormes	esos árboles, árboles eran, eran grandes	2 de 3
Trigramas	esos árboles eran, árboles eran enormes	esos árboles eran, árboles eran grandes	1 de 2
4-gramas	esos árboles eran enormes	esos árboles eran grandes	0 de 1

Este ejemplo muestra un aspecto fundamental de BLEU: un solo cambio léxico puede afectar a varios n-gramas. La sustitución de *enormes* por *grandes* afecta al unigrama, al bigrama, al trigram y al 4-grama que contienen esa posición.

BLEU tiene ventajas claras:

Ventaja	Explicación
Es rápida	Puede calcularse automáticamente sobre grandes corpus
Es reproducible	Permite comparar sistemas bajo las mismas condiciones
Es sensible al orden	Los n-gramas captan parte de la secuencia de palabras
Ha sido muy utilizada	Durante años fue una referencia estándar en traducción automática

Pero también presenta limitaciones importantes:

Limitación	Explicación
No entiende el significado	Solo compara coincidencias superficiales de n-gramas
Penaliza sinónimos y paráfrasis	Traducciones correctas pueden recibir puntuaciones bajas
Es poco fiable a nivel de frase	Funciona mejor como medida agregada sobre corpus
Depende de la referencia	Si solo hay una referencia, muchas traducciones válidas quedan penalizadas
Puede ocultar errores graves	Una traducción puede compartir n-gramas y aun así alterar el sentido

BLEU debe entenderse como una herramienta útil para comparar sistemas en condiciones controladas, no como una medida absoluta de «buena traducción».

La investigación posterior ha mostrado que la relación entre métricas automáticas y evaluación humana puede ser sensible a los datos, al dominio, al tipo de sistema evaluado y a la presencia de

Los derechos de este material pertenecen a la Dr.^a Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

valores atípicos. Mathur et al. (2020), por ejemplo, subrayan que la comparación entre métricas automáticas y juicios humanos no debe reducirse a una conclusión simple del tipo «esta métrica siempre es mejor». Para un uso responsable, BLEU debe interpretarse como una señal cuantitativa agregada y no como un veredicto completo sobre cada frase individual.

1.8. chrF y chrF++

chrF es una métrica propuesta por Popović (2015) que evalúa traducciones mediante n-gramas de caracteres en lugar de n-gramas de palabras. Esta diferencia es importante porque permite detectar similitudes parciales entre palabras.

Mientras BLEU compara palabras o secuencias de palabras completas, chrF compara fragmentos de caracteres. Por ejemplo, entre traducir, traducción y traducido hay diferencias léxicas, pero también una raíz formal compartida. Una métrica basada en caracteres puede captar parte de esa relación.

Ejemplo:

Referencia	Hipótesis
internacionalización	internacionalizacion

Aunque falta la tilde, las dos formas comparten casi todos sus caracteres. Una métrica basada en palabras podría tratarlas como tokens distintos. chrF, en cambio, reconocería una alta similitud formal.

chrF resulta especialmente interesante para lenguas con variación morfológica, porque las palabras pueden cambiar por género, número, caso, persona, tiempo verbal o derivación.

Referencia	Hipótesis
los investigadores analizaron los resultados	las investigadoras analizaron el resultado

Hay diferencias de género y número, pero también mucho solapamiento formal entre investigadores e investigadoras, y entre resultados y resultado. chrF puede captar parte de esa proximidad formal, aunque no determine por sí sola si la traducción es correcta.

Sus ventajas principales son:

Ventaja	Explicación
Capta similitudes parciales	No exige que las palabras coincidan exactamente
Es menos dependiente de la tokenización	Trabaja con caracteres
Puede funcionar bien en lenguas morfológicamente complejas	Reconoce parentescos formales entre variantes
Es fácil de aplicar	No requiere entrenamiento de modelos neuronales

También tiene límites:

Limitación	Explicación
Sigue siendo superficial	No comprende realmente el significado
Puede premiar palabras formalmente parecidas pero semánticamente distintas	La forma parecida no garantiza equivalencia
No evalúa adecuación respecto al texto fuente	Como muchas métricas con referencia, compara sobre todo hipótesis y referencia

chrF++ incorpora también n-gramas de palabras. Es decir, no solo mira fragmentos de caracteres, sino también secuencias léxicas. Puede resultar útil cuando queremos añadir algo de sensibilidad al orden de palabras, pero para una introducción es menos transparente porque mezcla dos niveles: caracteres y palabras.

1.9. METEOR: coincidencias flexibles y penalización por desorden

METEOR, sigla de **Metric for Evaluation of Translation with Explicit ORdering**, fue propuesta por Banerjee y Lavie (2005). Su objetivo era mejorar la correlación con juicios humanos respecto a métricas basadas exclusivamente en precisión de n-gramas.

La idea principal de METEOR es comparar hipótesis y referencia mediante correspondencias más flexibles que la coincidencia exacta. En su formulación clásica, METEOR puede considerar:

- coincidencias exactas;
- coincidencias por raíz o stemming;
- coincidencias mediante sinónimos;
- penalizaciones cuando las palabras coincidentes aparecen en un orden muy fragmentado.

Esto la acerca más a la forma en que una persona podría comparar dos frases. No solo pregunta «¿son iguales las palabras?», sino también «¿hay palabras relacionadas?» y «¿aparecen en un orden razonable?».

METEOR se inspira en *precision* y *recall*, pero no los utiliza de forma tan simple como las métricas léxicas básicas. Da especial importancia al *recall*, porque en traducción es fundamental que no se pierda información relevante.

El cálculo de METEOR puede entenderse en tres pasos:

- **Alineación.** Se emparejan las palabras de la hipótesis con las de la referencia: primero las idénticas, después las que comparten raíz y, por último, los sinónimos. Cada palabra solo puede emparejarse una vez.
- **Media ponderada de precision y recall.** Con las palabras emparejadas se calculan *precision* y *recall* y se combinan dando más peso al *recall*.
- **Penalización por fragmentación.** Se comprueba si las palabras emparejadas aparecen agrupadas y en el mismo orden que en la referencia, o dispersas.

La media ponderada se denomina *Fmean*:

$$F_{mean} = \frac{Precision \times Recall}{\alpha \times Precision + (1 - \alpha) \times Recall}$$

El parámetro α controla el equilibrio entre *precision* y *recall*. En la formulación original y en NLTK, $\alpha = 0.9$, de modo que el *recall* pesa nueve veces más que la *precision*. Por eso la fórmula clásica se escribe a veces como $10 \cdot P \cdot R / (R + 9 \cdot P)$.

Para medir el desorden, METEOR cuenta **fragmentos** (*chunks*): grupos de palabras emparejadas que aparecen contiguas y en el mismo orden en la hipótesis y en la referencia. Si todas las coincidencias forman un solo bloque, hay un fragmento; si están completamente dispersas, hay tantos fragmentos como coincidencias.

$$Penalización = \gamma \times \left(\frac{fragmentos}{coincidencias} \right)^\beta$$

Con los valores habituales, $\gamma = 0.5$ y $\beta = 3$, la penalización nunca supera 0.5. La puntuación final combina ambos elementos y se expresa en escala 0–1:

$$METEOR = F_{mean} \times (1 - Penalización)$$

Veamos el cálculo con el ejemplo de *recall* del apartado 1.5.2:

Referencia	Hipótesis
los árboles son altos	los árboles

Hay dos coincidencias (*los* y *árboles*), que forman un único fragmento:

Los derechos de este material pertenecen a la Dr.^a Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

$$Precision = \frac{2}{2} = 1 \quad Recall = \frac{2}{4} = 0.50$$

$$F_{mean} = \frac{1 \times 0.50}{0.9 \times 1 + 0.1 \times 0.50} = \frac{0.50}{0.95} \approx 0.526$$

$$Penalización = 0.5 \times \left(\frac{1}{2}\right)^3 = 0.0625$$

$$METEOR = 0.526 \times (1 - 0.0625) \approx 0.49$$

El F1 léxico de esta misma pareja sería 0.67. METEOR baja hasta 0.49 porque da mucho más peso al *recall*: la hipótesis es correcta en lo que dice, pero omite la mitad de la referencia.

Ejemplo de coincidencia por sinónimos:

Referencia	Hipótesis
the doctor examined the patient	the physician examined the patient

Una métrica estrictamente léxica penalizaría doctor frente a physician. METEOR puede reconocer esa relación si dispone del recurso léxico adecuado, como WordNet para inglés.

Con la implementación de NLTK, que usa WordNet, la hipótesis con *physician* obtiene 0.996, exactamente lo mismo que una hipótesis idéntica a la referencia: el emparejamiento por sinónimo cuenta como coincidencia completa.

Además, METEOR penaliza el desorden:

Referencia	Hipótesis A	Hipótesis B
the child opened the window	the child opened the window	window the opened child the

Las dos hipótesis pueden compartir palabras con la referencia, pero solo la primera respeta el orden sintáctico. Desde un punto de vista lingüístico, esta penalización es relevante porque el orden de palabras afecta a la gramaticalidad, a la interpretación semántica y a la estructura informativa.

En números, la hipótesis A obtiene 0.996: sus cinco coincidencias forman un único fragmento y la penalización es mínima, $0.5 \times (1/5)^3 = 0.004$. La hipótesis B tiene las mismas cinco coincidencias, pero ninguna aparece contigua y en el orden de la referencia: cinco fragmentos, penalización $0.5 \times (5/5)^3 = 0.5$ y METEOR = 0.50.

Este ejemplo también muestra que METEOR casi nunca llega exactamente a 1: incluso una hipótesis idéntica a la referencia recibe una pequeña penalización, porque siempre hay al menos un fragmento.

Una cuestión importante es que muchas implementaciones de METEOR han estado especialmente desarrolladas para inglés, entre otras razones por la disponibilidad de recursos como WordNet. Esto no significa que la idea no sea aplicable a otras lenguas, sino que su rendimiento depende de los recursos lingüísticos disponibles.

En la práctica, la configuración por defecto de NLTK usa el *stemmer* de Porter, diseñado para inglés, y el WordNet inglés para los sinónimos. En textos en español, METEOR se apoya casi solo en coincidencias exactas y en la penalización por orden. En el apartado 2.11 se verá cómo sustituir el *stemmer* por uno para español.

Para estudiantes con perfil lingüístico, esta observación es especialmente útil. Una métrica no es solo una fórmula matemática; también depende de decisiones lingüísticas previas, como la lematización, el stemming, la sinonimia o la disponibilidad de bases léxicas. Por eso dos implementaciones de una misma métrica pueden comportarse de forma distinta en función de la lengua, del dominio y de los recursos que utilicen.

Las ventajas principales de METEOR pueden resumirse así:

Ventaja	Explicación
Es más flexible que una coincidencia exacta	Puede reconocer raíces o sinónimos si dispone de recursos adecuados
Combina <i>precision</i> y <i>recall</i>	No mira solo lo que produce la hipótesis, sino también lo que recupera de la referencia
Penaliza el desorden	Tiene en cuenta si las coincidencias aparecen fragmentadas o en un orden poco natural
Se aproxima mejor a ciertos juicios humanos	Su diseño intenta reflejar mejor diferencias lingüísticas relevantes

Sus limitaciones también son importantes:

Limitación	Explicación
Depende de recursos lingüísticos	Funciona mejor cuando hay analizadores, listas de raíces o bases de sinónimos disponibles
Puede estar sesgada hacia determinadas lenguas	Muchas versiones se desarrollaron especialmente para inglés
Sigue sin comprender plenamente el significado	Reconoce correspondencias más flexibles, pero no interpreta como una persona
Es menos inmediata que BLEU o Jaccard	Requiere más explicación y más decisiones de configuración

1.10. Comparación general de métricas clásicas

Las métricas clásicas pueden organizarse en varios grupos:

Grupo	Métricas	Qué comparan principalmente
Métricas léxicas simples	<i>Precision</i> , <i>recall</i> , F1, Exact Match, Jaccard	Palabras individuales o conjuntos de palabras
Métricas basadas en n-gramas	BLEU	Secuencias de palabras
Métricas basadas en caracteres o correspondencias flexibles	chrF, METEOR	Caracteres, raíces, sinónimos y orden

Cada grupo responde a una pregunta diferente:

Pregunta	Métrica adecuada
¿Cuántas palabras coinciden?	<i>Precision</i> , <i>recall</i> , F1
¿La traducción es exactamente igual a la referencia?	Exact Match
¿Cuánto solapamiento léxico hay?	Jaccard
¿Coinciden secuencias de palabras?	BLEU
¿Hay similitud formal entre palabras?	chrF
¿Hay coincidencias exactas, morfológicas o semánticas básicas?	METEOR

La conclusión principal es que ninguna métrica clásica evalúa por sí sola todos los aspectos de una traducción. En investigación y desarrollo se recomienda interpretar varias métricas conjuntamente y, cuando sea posible, complementarlas con evaluación humana.

1.11. Métricas semánticas o neuronales

Las métricas clásicas fueron diseñadas en una época en la que la evaluación automática dependía principalmente de coincidencias superficiales. La traducción automática neuronal ha cambiado el escenario: los sistemas actuales pueden producir paráfrasis más fluidas, reformular estructuras y alejarse de la referencia sin necesariamente ser incorrectos.

Ejemplo:

Referencia	Hipótesis A	Hipótesis B	Hipótesis C
El comité rechazó la propuesta.	El comité no aceptó la propuesta.	La propuesta fue rechazada por el comité.	El comité aprobó la propuesta.

Una métrica basada en n-gramas puede penalizar la hipótesis B porque cambia la estructura sintáctica, aunque sea semánticamente equivalente. En cambio, la hipótesis C comparte varias palabras con la referencia, pero cambia el sentido principal: rechazó frente a aprobó.

Este tipo de ejemplos motivó el desarrollo de métricas que no se limitaran a contar palabras, sino que utilizaran representaciones semánticas aprendidas por modelos neuronales. BERTScore, BLEURT y COMET pertenecen a esta familia.

Una métrica semántica o neuronal utiliza modelos de lenguaje entrenados con grandes cantidades de texto para representar palabras, frases o documentos como vectores. Estos vectores se conocen como embeddings o representaciones distribucionales. La idea básica es que si dos palabras o frases tienen significados parecidos, sus representaciones vectoriales deberían estar relativamente próximas en el espacio semántico aprendido por el modelo.

No obstante, conviene presentar estas métricas con prudencia. Que una métrica utilice un modelo neuronal no significa que «entienda» el texto como una persona. Sus puntuaciones dependen del modelo utilizado, de los datos de entrenamiento, de las lenguas disponibles, de la tarea y de la forma en que se haya ajustado la métrica a juicios humanos.

1.11.1. BERTScore

BERTScore, propuesta por Zhang et al. (2020), evalúa generación textual utilizando representaciones contextuales de modelos tipo BERT. En lugar de comprobar si dos palabras son exactamente iguales, compara la similitud entre los embeddings contextuales de los tokens de la hipótesis y los tokens de la referencia.

La palabra **contextual** es fundamental. En modelos como BERT, una palabra no tiene siempre la misma representación: su vector cambia según el contexto. Banco no se representa igual en me senté en el banco que en fui al banco a sacar dinero.

BERTScore puede explicarse en tres pasos:

Codifica la hipótesis y la referencia con un modelo de lenguaje preentrenado.

Compara cada token de la hipótesis con los tokens de la referencia mediante similitud vectorial.

Calcula puntuaciones análogas a *precision*, *recall* y F1, pero basadas en similitud semántica.

Ejemplo:

Referencia	Hipótesis
El médico examinó al paciente.	El doctor revisó al paciente.

Una métrica léxica solo reconocerá coincidencias como el, al y paciente. BERTScore puede asignar similitud alta entre médico y doctor, y cierta similitud entre examinó y revisó.

Ventajas:

Ventaja	Explicación
Reconoce similitud semántica	Puede valorar palabras distintas pero relacionadas
Usa contexto	La representación de cada palabra depende de la frase
Mantiene la intuición de <i>precision</i> , <i>recall</i> y F1	Conecta con métricas ya vistas
Es aplicable a varias tareas de generación textual	No se limita a traducción automática

Limitaciones:

Limitación	Explicación
Depende del modelo preentrenado	La calidad varía según lengua y modelo
No siempre detecta errores críticos	Puede asignar similitud alta a frases parecidas pero opuestas
No evalúa necesariamente fidelidad al texto fuente	En su forma habitual compara hipótesis y referencia
Es menos transparente que BLEU	La puntuación depende de representaciones internas

BERTScore puede presentarse como una métrica que sustituye la pregunta «¿coinciden las palabras?» por otra más flexible: «¿se parecen las palabras en contexto?». Esa transición es importante para entender por qué las métricas modernas se alejan de la coincidencia literal y se acercan a representaciones semánticas. Aun así, BERTScore no debe interpretarse como una lectura humana del texto, sino como una comparación entre representaciones aprendidas por un modelo.

1.11.2. BLEURT

BLEURT, propuesta por Sellam et al. (2020), es una métrica aprendida basada en BERT. A diferencia de BERTScore, que se basa principalmente en similitudes entre embeddings, BLEURT se entrena explícitamente para predecir juicios humanos de calidad.

Esta diferencia es importante: BLEURT no solo utiliza un modelo neuronal para representar frases, sino que aprende a asignar una puntuación que se parezca a la que darían evaluadores humanos.

Puede explicarse así:

1. Se parte de un modelo de lenguaje preentrenado, como BERT.
Se adapta el modelo a la tarea de evaluación.
El sistema aprende patrones que suelen corresponderse con buenas o malas salidas.
Ante una nueva hipótesis, produce una puntuación que intenta aproximar el juicio humano.

Ejemplo:

Referencia	Hipótesis A	Hipótesis B
La empresa anunció una reducción de costes.	La compañía comunicó una reducción de gastos.	La empresa anunció un aumento de costes.

La hipótesis A cambia palabras, pero mantiene un significado parecido. La hipótesis B comparte más vocabulario superficial con la referencia, pero altera el sentido mediante aumento frente a reducción. BLEURT está diseñada para ser más sensible a este tipo de diferencias semánticas que una métrica puramente léxica.

Las ventajas de BLEURT son:

Ventaja	Explicación
Aprende de juicios humanos	Intenta aproximar cómo valorarían las personas la calidad textual
Capta relaciones semánticas complejas	No depende solo de coincidencias de palabras
Puede ser robusta ante paráfrasis	Penaliza menos algunas reformulaciones válidas
Es útil en generación textual	Puede aplicarse a evaluación más allá de la traducción automática

Sus limitaciones son:

Limitación	Explicación
Es una métrica aprendida	Su comportamiento depende de los datos de entrenamiento
Puede heredar sesgos de los datos	Si los datos son limitados o sesgados, la métrica puede reflejarlo
Es menos interpretable	No siempre es fácil explicar por qué asigna una puntuación concreta
Puede variar entre dominios y lenguas	Una métrica entrenada en ciertos datos no siempre generaliza igual de bien

BLEURT es especialmente útil para explicar que una métrica automática puede ser también un modelo supervisado: no solo aplica una fórmula, sino que aprende a evaluar a partir de ejemplos.

1.11.3. COMET

COMET, sigla de **Crosslingual Optimized Metric for Evaluation of Translation**, es una métrica neuronal diseñada específicamente para evaluación de traducción automática. Fue presentada por Rei et al. (2020) como un marco neuronal multilingüe que puede explotar información del texto fuente, de la hipótesis y de la referencia.

Esta es una diferencia clave respecto a muchas métricas anteriores. BLEU, chrF, METEOR, BERTScore y BLEURT suelen centrarse principalmente en la comparación entre hipótesis y referencia. COMET puede incorporar también el texto fuente, lo que resulta muy relevante en traducción automática.

Ejemplo:

Texto fuente	Referencia	Hipótesis
The patient did not receive the treatment.	El paciente no recibió el tratamiento.	El paciente recibió el tratamiento.

La hipótesis se parece mucho a la referencia: solo falta no. Sin embargo, el error es grave porque invierte el significado. Una métrica que observe el texto fuente puede estar mejor situada para detectar problemas de adecuación.

COMET puede entenderse así:

1. Codifica el texto fuente, la hipótesis y la referencia mediante un modelo multilingüe.
2. Combina esas representaciones.
3. Predice una puntuación de calidad entrenada para correlacionar con juicios humanos.

Su interés didáctico reside en que muestra una evolución clara: de comparar palabras, pasamos a comparar significados; y de comparar solo hipótesis y referencia, pasamos a incorporar también el texto fuente.

Las ventajas de COMET son:

Ventaja	Explicación
---------	-------------

Los derechos de este material pertenecen a la Dr.^a Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

Está diseñada para traducción automática	No es solo una métrica general de generación textual
Puede usar el texto fuente	Ayuda a valorar la adecuación de la traducción
Se entrena con juicios humanos	Busca correlacionar con evaluaciones humanas de calidad
Es multilingüe	Aprovecha modelos preentrenados multilingües o interlingües

Sus limitaciones son:

Limitación	Explicación
Requiere modelos complejos	Es más costosa computacionalmente que BLEU o chrF
Es menos transparente	Su puntuación no se explica mediante simples coincidencias de n-gramas
Depende de los datos de entrenamiento	Puede funcionar mejor en lenguas y dominios representados en sus datos
No sustituye a la evaluación humana	Puede fallar ante fenómenos pragmáticos, terminológicos o discursivos específicos

Una forma sencilla de compararlas es formular la pregunta que parece hacerse cada métrica:

Métrica	Pregunta intuitiva	Nivel recomendado en esta asignatura
BERTScore	«¿Se parecen semánticamente las palabras de la hipótesis y la referencia en su contexto?»	Comprensión teórica
BLEURT	«Según lo aprendido de evaluaciones humanas, ¿qué calidad parece tener esta salida?»	Comprensión teórica
COMET	«Teniendo en cuenta el texto fuente, la hipótesis y la referencia, ¿qué calidad traductológica tiene la traducción?»	Comprensión teórica

También pueden compararse por el tipo de información que utilizan:

Métrica	Tipo	Qué compara	Idea central
BERTScore	Métrica basada en embeddings contextuales	Hipótesis y referencia	Compara tokens mediante similitud semántica contextual
BLEURT	Métrica neuronal aprendida	Hipótesis y referencia	Aprende a predecir juicios humanos usando BERT
COMET	Métrica neuronal para traducción automática	Fuente, hipótesis y referencia	Predice calidad traductológica con modelos multilingües

1.12. Cómo interpretar las métricas

Para alumnado de segundo curso, la idea más importante es que las métricas no deben interpretarse como verdades absolutas. Toda métrica simplifica la realidad. La traducción implica significado, gramática, pragmática, estilo, terminología, adecuación al encargo y naturalidad. Ninguna puntuación numérica recoge todo eso por sí sola.

Conviene retener cuatro ideas:

1. Toda métrica simplifica la realidad.
2. Las métricas clásicas son más transparentes, pero menos semánticas.
3. Las métricas neuronales son más flexibles, pero menos interpretables.
4. La evaluación humana sigue siendo necesaria.

La evaluación automática de traducciones ha evolucionado desde métricas basadas en coincidencias superficiales hasta métricas neuronales entrenadas para aproximarse a juicios humanos. Las métricas léxicas simples introducen conceptos básicos de comparación textual. BLEU incorpora el orden mediante n-gramas. chrF añade flexibilidad al trabajar con caracteres. METEOR incorpora correspondencias más flexibles. BERTScore, BLEURT y COMET representan una transición hacia la comparación semántica.

Para una estudiante de Tecnologías del Lenguaje, la idea esencial es esta: evaluar traducciones no consiste solo en calcular una puntuación, sino en entender qué aspecto de la calidad mide cada métrica, qué deja fuera y en qué contexto puede utilizarse con sentido.

2. Evaluación automática con Python

2.1. Preparar los textos antes de medir

Antes de calcular métricas, necesitamos preparar los textos. Si no lo hacemos, diferencias irrelevantes pueden contaminar los resultados.

Imagina estas dos frases:

Referencia	Hipótesis
Mi casa es azul	mi casa es azul.

Desde el punto de vista lingüístico, son prácticamente iguales. Pero si Python compara las palabras de forma literal, puede considerar distintas Mi y mi, o azul y azul.. Para evitarlo, se aplica una limpieza mínima:

- pasar todo a minúsculas;
- quitar signos de puntuación;
- dividir el texto en palabras.

Una función sencilla para limpiar palabras puede ser:

```
def limpiar_palabra(palabra):
    return palabra.strip('.,;:!?";'¿()[]{}')
```

Esta función recibe una palabra y elimina signos de puntuación al principio o al final. Después podemos procesar una frase completa:

```
def procesar_texto(texto):
    texto = texto.lower()
    palabras = texto.split()
    palabras = [limpiar_palabra(p) for p in palabras]
    return palabras
```

Aquí aparecen varias ideas importantes:

Línea	Qué hace
<code>texto.lower()</code>	Convierte todo a minúsculas
<code>texto.split()</code>	Divide el texto por espacios
<code>[limpiar_palabra(p) for p in palabras]</code>	Limpia cada palabra de la lista
<code>return palabras</code>	Devuelve la lista procesada

El resultado ya no es una frase como string, sino una lista de tokens:

```
referencia = "Los árboles son altos."
traduccion_prueba = "Los arboles estan grandes"

referencia_proc = procesar_texto(referencia)
traduccion_prueba_proc = procesar_texto(traduccion_prueba)

print("Referencia:", referencia_proc)
print("Traducción:", traduccion_prueba_proc)
```

La limpieza no es una operación inocente. Simplifica el texto para poder comparar. En una evaluación real, habría que decidir si se quieren conservar tildes, signos, mayúsculas, puntuación o segmentación más fina. En esta unidad usamos una limpieza básica porque permite entender la lógica de las métricas.

2.2. Precision léxica con Python

La precisión léxica pregunta: de todas las palabras que ha producido la traducción automática, ¿cuántas aparecen también en la referencia?

En Python se puede calcular así:

```
palabras_correctas = sum(
    1
    for palabra in traduccion_prueba_proc
    if palabra in referencia_proc
)

precision = palabras_correctas / len(traduccion_prueba_proc)

print(f"Precisión: {precision:.2f}")
```

La expresión `sum(1 for palabra in traduccion_prueba_proc if palabra in referencia_proc)` recorre cada palabra de la traducción automática. Si esa palabra está también en la referencia, suma 1.

En el caso:

Referencia procesada	Hipótesis procesada
<code>['los', 'árboles', 'son', 'altos']</code>	<code>['los', 'arboles', 'estan', 'grandes']</code>

solo coincide los, porque árboles y arboles no son idénticas por la tilde, son y estan son diferentes, y altos y grandes no coinciden. La precisión sería:

```
Precision = 1 / 4 = 0.25
```

Este resultado enseña algo importante: la métrica no sabe que árboles y arboles son variantes casi idénticas salvo por la tilde. Tampoco sabe que altos y grandes pueden estar semánticamente relacionados. Solo compara formas.

2.3. Traducción automática con deep-translator

Para generar una traducción automática desde Python puede usarse la biblioteca `deep-translator`, que permite acceder a varios motores de traducción online, entre ellos Google Translate.

La instalación en un entorno interactivo puede hacerse así:

```
%pip install deep-translator
```

Después se importa la clase `GoogleTranslator`:

```
from deep_translator import GoogleTranslator
```

Y se genera la traducción:

```
original = "Those trees were big."

tradu_auto = GoogleTranslator(
    source="en",
    target="es"
).translate(original)

print("Traducción automática:", tradu_auto)
```

Los argumentos `source` y `target` indican la lengua de origen y la lengua de destino. En este ejemplo, `source="en"` indica inglés y `target="es"` indica español.

Una vez obtenida la traducción automática, se procesan los tres textos:

```
original_proc = procesar_texto(original)
tradu_humana_proc = procesar_texto(tradu_humana)
tradu_auto_proc = procesar_texto(tradu_auto)
```

Para las métricas léxicas, normalmente compararemos `tradu_auto_proc` con `tradu_humana_proc`. El texto fuente queda como contexto traductológico, aunque algunas métricas clásicas no lo usen directamente.

2.4. Recall léxico

El *recall* léxico pregunta: de todas las palabras que aparecen en la referencia humana, ¿cuántas ha recuperado la traducción automática?

En Python:

```
recall = sum(
    1
    for palabra in tradu_humana_proc
    if palabra in tradu_auto_proc
) / len(tradu_humana_proc)

print(f"Recall léxico: {recall:.2f}")
```

La estructura es muy parecida a la de *precision*, pero cambia el punto de vista. En *precision* recorremos la traducción automática; en *recall* recorremos la referencia.

Esta diferencia es lingüísticamente importante:

Métrica	Punto de vista	Pregunta
<i>Precision</i>	Traducción automática	¿Cuánto de lo que produjo el sistema coincide?
<i>Recall</i>	Referencia humana	¿Cuánto de lo esperado fue recuperado?

Una traducción puede tener alta *precision* y bajo *recall* si produce pocas palabras, pero correctas. También puede tener *recall* relativamente alto y *precision* más baja si produce muchas palabras añadidas.

2.5. F1-score

El F1-score combina *precision* y *recall*. Para evitar errores cuando ambas métricas valen cero, conviene comprobar antes que la suma sea mayor que cero:

```
if precision + recall > 0:
    f1 = 2 * (precision * recall) / (precision + recall)
else:
    f1 = 0

print(f"F1-score: {f1:.2f}")
```

La condición `if precision + recall > 0` evita una división entre cero. Este detalle técnico tiene una lectura metodológica: no siempre hay coincidencias entre hipótesis y referencia. Si no hay ninguna coincidencia, el F1 debe ser cero.

F1 resulta útil cuando queremos una medida equilibrada. Si una traducción produce muchas palabras correctas, pero omite mucha información, el F1 no se disparará. Si recupera mucho vocabulario, pero introduce muchas palabras no presentes en la referencia, tampoco será perfecto.

2.6. Exact Match

Exact Match es la métrica más estricta. Comprueba si las listas procesadas son idénticas:

```
exact_match = tradu_auto_proc == tradu_humana_proc

print(f"Exact Match: {'Sí' if exact_match else 'No'}")
```

La expresión `tradu_auto_proc == tradu_humana_proc` devuelve `True` si ambas listas son exactamente iguales y `False` si hay cualquier diferencia.

Esto implica que Exact Match será No si:

- cambia una palabra;
- falta una tilde que no se ha normalizado;
- cambia el orden;
- aparece una palabra adicional;
- se omite una palabra;
- se usa un sinónimo.

Por eso Exact Match es útil para enseñar la idea de coincidencia estricta, pero no suele ser una buena métrica para evaluar traducciones naturales. La traducción admite variación.

2.7. Índice Jaccard

El índice Jaccard compara conjuntos de palabras. En Python, los conjuntos se crean con `set()`:

```
set_auto = set(tradu_auto_proc)
set_humana = set(tradu_humana_proc)

jaccard = len(set_auto & set_humana) / len(set_auto | set_humana)

print(f"Índice Jaccard: {jaccard:.2f}")
```

Jaccard ignora el orden y las repeticiones. Por eso puede ser útil para medir solapamiento de vocabulario, pero no para evaluar estructura sintáctica.

En el ejemplo Esos árboles eran enormes frente a Esos árboles eran grandes, los conjuntos son:

```
Automática = {esos, árboles, eran, grandes}
Humana = {esos, árboles, eran, enormes}
Intersección = {esos, árboles, eran}
Unión = {esos, árboles, eran, grandes, enormes}
Jaccard = 3 / 5 = 0.60
```

La puntuación es inferior a *precision* y *recall* porque Jaccard compara el vocabulario compartido con todo el vocabulario distinto que aparece en ambas traducciones.

2.8. Informe de métricas léxicas

Cuando se calculan varias métricas, conviene presentarlas juntas:

```
print(f"Precisión léxica: {precision:.2f}")
print(f"Recall léxico: {recall:.2f}")
print(f"F1-score: {f1:.2f}")
print(f"Exact Match: {'Sí' if exact_match else 'No'}")
print(f"Índice Jaccard: {jaccard:.2f}")
```

Un conjunto de resultados puede ser:

Métrica	Valor	Lectura
Precisión léxica	0.75	El 75 % de las palabras generadas coincide con la referencia
Recall léxico	0.75	El 75 % de la referencia fue recuperado
F1-score	0.75	Hay equilibrio entre <i>precision</i> y <i>recall</i>
Jaccard	0.60	El vocabulario compartido representa el 60 % del vocabulario total único
Exact Match	No	Las frases no son idénticas

La interpretación profesional sería: la traducción automática es bastante buena desde el punto de vista léxico, pero no idéntica. Cambiar una palabra por otra próxima puede hacer que Exact Match sea No, aunque otras métricas sigan siendo altas.

2.9. BLEU con NLTK

BLEU se puede calcular con nltk:

```
import nltk
from nltk.translate.bleu_score import sentence_bleu, SmoothingFunction
```

Para evaluar una frase, `sentence_bleu()` espera una lista de referencias y una candidata:

```
reference = [tradu_humana_proc]
candidate = tradu_auto_proc

bleu = sentence_bleu(
    reference,
    candidate,
    smoothing_function=SmoothingFunction().method1
)

print(f"BLEU: {bleu:.2f}")
```

Hay dos detalles importantes:

5. `reference = [tradu_humana_proc]` usa una lista de listas porque BLEU permite comparar una hipótesis con varias referencias.
6. `SmoothingFunction().method1` suaviza el cálculo para evitar que BLEU sea cero en frases cortas cuando no hay coincidencias de n-gramas largos.

En el caso Esos árboles eran enormes frente a Esos árboles eran grandes, el resultado puede sorprender porque la puntuación BLEU puede estar alrededor de 0.40. Las frases solo cambian en una palabra, pero esa palabra rompe varios n-gramas.

Nivel	Coincidencias
Unigramas	3 de 4
Bigramas	2 de 3
Trigramas	1 de 2
4-gramas	0 de 1

BLEU combina estas *precisiones* mediante un promedio geométrico. Si un nivel tiene cero coincidencias, la puntuación baja mucho. El smoothing evita que el resultado sea cero total, pero no elimina la penalización.

La lectura lingüística es clara: BLEU no solo mide palabras sueltas. Mide continuidad formal. Por eso una diferencia en la última palabra afecta a toda la secuencia final.

2.10. chrF con evaluate

Para calcular chrF puede usarse la biblioteca `evaluate`, junto con `sacrebleu`:

```
!pip install evaluate sacrebleu -q
```

Después se carga la métrica:

```
from evaluate import load

chrf_metric = load("chrf")
```

chrF trabaja con texto completo, no con listas de palabras procesadas. Por eso conviene usar las cadenas originales:

```
resultado_chrf = chrf_metric.compute(
    predictions=[tradu_auto],
    references=[tradu_humana]
)

print(f"chrF: {resultado_chrf['score']:.2f}")
```

El resultado de `compute()` es un diccionario. La clave `score` contiene la puntuación principal.

Es importante recordar que BLEU y METEOR aparecen en escala 0–1 en NLTK, mientras que chrF en `evaluate` suele aparecer en escala 0–100. Por tanto, no deben compararse los números de forma directa sin mirar la escala.

Valor de chrF	Lectura orientativa
Bajo	Hay poca similitud formal entre hipótesis y referencia
Medio	Hay coincidencias parciales, pero también diferencias
Alto	La hipótesis se parece mucho a la referencia en su forma lingüística

chrF no comprende plenamente el significado ni la calidad estilística, pero complementa a BLEU cuando hay variaciones morfológicas o pequeñas diferencias formales.

2.11. METEOR con NLTK

METEOR también está disponible en `nltk`. Antes de usarlo hay que descargar WordNet, el recurso léxico que emplea para buscar sinónimos:

```
import nltk
from nltk.translate.meteor_score import meteor_score

nltk.download("wordnet")
nltk.download("omw-1.4")
```

Como `sentence_bleu()`, la función `meteor_score()` recibe una lista de referencias y una hipótesis, ambas ya tokenizadas:

```
meteor = meteor_score(
    [tradu_humana_proc],
    tradu_auto_proc
)

print(f"METEOR: {meteor:.2f}")
```

Hay dos detalles importantes:

- `[tradu_humana_proc]` es una lista de listas, igual que en BLEU. Si se proporcionan varias referencias, METEOR se queda con la puntuación más alta.
- Las entradas deben ser listas de palabras, no cadenas de texto. Si se pasa una frase sin tokenizar, las versiones recientes de NLTK producen un error (`TypeError`).

En el caso *Esos árboles eran enormes* frente a *Esos árboles eran grandes*, METEOR da 0.74, mientras que BLEU se quedaba en torno a 0.40:

Los derechos de este material pertenecen a la Dr.^a Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

Métrica	Valor	Por qué
BLEU	0.40	La sustitución de una palabra rompe bigramas, trigramas y el 4-grama
METEOR	0.74	Tres de cuatro palabras coinciden y forman un único fragmento ordenado

El contraste es instructivo. METEOR alinea palabras individuales y solo después mira el orden; por eso castiga menos una sustitución aislada. Pero tampoco reconoce *grandes* y *enormes* como equivalentes: en español no dispone de sinónimos.

METEOR en español. Por defecto, `meteor_score()` utiliza el *stemmer* de Porter, pensado para inglés, y el WordNet inglés para los sinónimos. En español, la fase de sinónimos no actúa y la de raíces solo acierta por casualidad. La fase de raíces se puede mejorar pasando un *stemmer* para español mediante el argumento `stemmer`:

```
from nltk.stem import SnowballStemmer

stemmer_es = SnowballStemmer("spanish")

referencia = "el informe muestra que la inflación baja".split()
hipotesis = "los informes muestran que la inflación bajó".split()

print(meteor_score([referencia], hipotesis))
print(meteor_score([referencia], hipotesis, stemmer=stemmer_es))
```

Configuración	METEOR	Qué ocurre
Por defecto (Porter)	0.54	Solo empareja <i>informe/informes</i> , que Porter reduce por casualidad a la misma raíz
<code>SnowballStemmer("spanish")</code>	0.86	Además empareja <i>muestra/muestran</i> y <i>baja/bajó</i>

La lectura lingüística es clara: METEOR no es un número único, sino una familia de configuraciones. Al informar de un resultado conviene indicar qué *stemmer* y qué recurso de sinónimos se han usado.

Como con chrF, la escala orienta la lectura:

Valor de METEOR	Lectura orientativa
Bajo	La hipótesis recupera pocas palabras de la referencia, o las recupera muy desordenadas
Medio	Hay coincidencias, pero faltan palabras o el orden está fragmentado
Alto	La hipótesis recupera casi toda la referencia en un orden parecido

METEOR complementa a BLEU: es menos severo con las sustituciones aisladas y más sensible a las omisiones, porque prioriza el *recall*. El cuaderno de práctica sobre METEOR de esta unidad aplica la métrica a ejemplos en español de los ámbitos médico, jurídico y económico.

2.12. Todas las métricas en un mismo informe

Una salida de evaluación completa puede reunir las métricas principales:

```
print(f"Precisión: {precision:.2f}")
print(f"Recall: {recall:.2f}")
print(f"F1-score: {f1:.2f}")
print(f"Jaccard: {jaccard:.2f}")
print(f"BLEU: {bleu:.2f}")
print(f"chrF: {resultado_chrf['score']:.2f}")
print(f"METEOR: {meteor:.2f}")
print(f"Exact Match: {'Sí' if exact_match else 'No'})
```

El informe no debe limitarse a imprimir números. Debe incluir interpretación:

Métrica	Pregunta interpretativa
<i>Precision</i>	¿Cuánto de lo producido por la máquina coincide?
<i>Recall</i>	¿Cuánto de la referencia se recupera?
F1	¿Hay equilibrio entre exactitud y cobertura?
Jaccard	¿Cuánto vocabulario único comparten las versiones?
BLEU	¿Coinciden secuencias de palabras?
chrF	¿Hay similitud formal por caracteres?
METEOR	¿Se recuperan las palabras de la referencia, aunque sea por raíz o sinónimo, y en un orden razonable?
Exact Match	¿Son idénticas las versiones?

Esta interpretación es la parte lingüística del trabajo. Python calcula; la especialista explica.

2.13. Cómo leer casos con sinónimos y reformulación

Un caso especialmente interesante es aquel en que la traducción automática usa sinónimos:

Referencia	Hipótesis
Los estudiantes escuchaban atentos mientras el profesor explicaba con calma los conceptos clave del tema.	Los alumnos prestaban atención mientras el docente exponía tranquilamente las ideas principales del asunto.

Desde el punto de vista semántico, las frases pueden transmitir una idea parecida. Pero las métricas basadas en coincidencias literales bajarán mucho:

- estudiantes y alumnos no son la misma cadena;
- profesor y docente no coinciden formalmente;
- explicaba y exponía son diferentes;
- con calma y tranquilamente son expresiones distintas;
- conceptos clave e ideas principales son reformulaciones.

Exact Match será No. BLEU puede ser muy bajo porque las secuencias de palabras no coinciden. Jaccard también bajará porque el vocabulario compartido es reducido. chrF puede conservar algo más de información si hay fragmentos de caracteres compartidos, pero tampoco reconocerá completamente la equivalencia semántica. METEOR, que en inglés podría emparejar sinónimos gracias a WordNet, se comporta en español casi como una métrica de coincidencia exacta: en este ejemplo se queda alrededor de 0.21.

La conclusión profesional no debe ser «la traducción es mala» solo porque las métricas bajen. La conclusión correcta es más matizada: las métricas de coincidencia formal penalizan la sinonimia y la reformulación; por tanto, hace falta evaluación humana o métricas semánticas para valorar si el significado se conserva.

2.14. Buenas prácticas para interpretar resultados

Cuando se evalúan traducciones automáticas con Python, conviene seguir varias buenas prácticas:

- **No interpretar una métrica aislada.** Un solo número puede ser engañoso.
- **Mirar qué mide cada métrica.** *Precision* no mide lo mismo que BLEU, y BLEU no mide lo mismo que chrF.
- **Revisar la escala.** BLEU y METEOR en NLTK usan 0–1; chrF en evaluate usa 0–100.
- **Distinguir forma y significado.** Coincidencia formal no siempre equivale a calidad semántica.
- **Tener en cuenta la longitud.** BLEU puede comportarse de forma inestable en frases cortas.

Los derechos de este material pertenecen a la Dr.^a Blanca Hernández Pardo. Queda prohibida la difusión, distribución o reproducción total o parcial de este material sin autorización expresa de la autora.

- **Documentar la configuración.** METEOR cambia según el *stemmer* y los sinónimos disponibles; conviene indicar cuáles se han usado, sobre todo en lenguas distintas del inglés.
- **Explicar los resultados con ejemplos.** Una interpretación sin evidencia textual queda débil.
- **Recordar la referencia.** Si solo hay una traducción humana, muchas alternativas válidas pueden ser penalizadas.
- **Complementar con juicio lingüístico.** Las métricas orientan, pero no sustituyen la evaluación experta.

Una forma profesional de redactar una interpretación sería: *La traducción automática presenta una coincidencia léxica moderada-alta con la referencia, como muestran precision, recall y F1. Sin embargo, Exact Match es negativo porque existe al menos una diferencia formal. BLEU baja más que las métricas léxicas simples porque una sustitución léxica rompe varios n-gramas. chrF permite observar si, pese a las diferencias de palabra completa, existe similitud formal por caracteres. METEOR se mantiene más alto que BLEU porque alinea palabras individuales y solo penaliza el desorden, lo que confirma que la diferencia se concentra en una sola palabra. En conjunto, los resultados sugieren una traducción aceptable desde el punto de vista formal, pero la decisión final requiere revisar si la diferencia léxica afecta al significado y al encargo traductológico.*

2.15. Qué aporta Python a la evaluación lingüística

Python permite convertir una pregunta evaluativa en un procedimiento reproducible. En lugar de decir de forma vaga «esta traducción se parece bastante a la humana», podemos calcular varias medidas y justificar una interpretación.

La aportación de Python se resume en cuatro acciones:

Acción	Resultado
Limpiar textos	Reduce ruido superficial
Tokenizar	Convierte frases en unidades comparables
Calcular métricas	Produce indicadores cuantitativos
Presentar resultados	Facilita una interpretación argumentada

Pero Python no decide por sí solo si una traducción es adecuada. Una métrica puede señalar que dos frases se parecen poco en la forma, aunque sean equivalentes en significado. También puede señalar que dos frases se parecen mucho, aunque una contenga un error semántico grave.

La competencia de una lingüista computacional consiste precisamente en ocupar ese espacio intermedio: entender el cálculo, conocer sus límites y traducir el número en una interpretación lingüística responsable.

Errores frecuentes de aprendizaje

- Confundir una puntuación alta con una evaluación humana completa.
- Interpretar Exact Match = No como si la traducción fuera necesariamente incorrecta.
- Comparar BLEU, chrF y METEOR sin comprobar antes la escala de cada métrica.
- Olvidar que la limpieza previa del texto modifica los resultados.
- Usar una sola métrica para decidir la calidad global de una traducción.
- No distinguir entre texto fuente, hipótesis y referencia.
- Pasar por alto que los sinónimos y las paráfrasis pueden ser correctos aunque bajen las métricas formales.

- Aplicar METEOR a textos en español con la configuración por defecto de NLTK sin advertir que su *stemmer* y sus sinónimos están pensados para inglés.

Síntesis final

La evaluación automática de traducciones permite comparar una hipótesis con una referencia y obtener puntuaciones reproducibles. Las métricas léxicas simples, como *precision*, *recall*, F1, Exact Match y Jaccard, introducen la lógica básica de coincidencia textual. BLEU añade n-gramas y penalización por brevedad. chrF compara caracteres y resulta más flexible ante variación morfológica. METEOR, BERTScore, BLEURT y COMET amplían la mirada hacia correspondencias más flexibles, similitud semántica y adecuación traductológica.

En Python, estas ideas se traducen en operaciones concretas: limpiar textos, dividirlos en palabras, contar coincidencias, usar conjuntos, calcular n-gramas y llamar bibliotecas especializadas. Pero el aprendizaje central es interpretativo: una métrica no es una sentencia, sino una herramienta para formular mejores preguntas sobre la calidad de una traducción.

Cierre narrativo

Volvamos al encargo de NexaLingua Quality Lab. El equipo ya tiene un pequeño sistema capaz de comparar una traducción automática con una referencia humana. El informe no sustituye a la revisión profesional, pero permite priorizar.

Si *precision*, *recall* y F1 son altos, puede haber una coincidencia léxica sólida. Si Jaccard es más bajo, puede haber variación de vocabulario. Si BLEU baja mucho, quizá las secuencias no coinciden aunque el contenido sea próximo. Si chrF es alto, puede haber similitud formal incluso cuando no todas las palabras coinciden. Si METEOR se mantiene alto aunque BLEU baje, las palabras de la referencia están presentes y en un orden razonable, aunque no formen secuencias largas idénticas. Si Exact Match es No, eso solo indica que no hay identidad total; no implica automáticamente mala traducción.

El equipo puede usar el informe para decidir:

- qué segmentos revisar primero;
- qué motor parece más consistente;
- qué casos merecen evaluación humana detallada;
- qué métricas conviene usar en cada tipo de texto;
- qué limitaciones deben explicarse al cliente.

Esta unidad, por tanto, no enseña solo a calcular métricas. Enseña a pensar como una lingüista que trabaja con herramientas computacionales: con precisión técnica, prudencia interpretativa y atención al significado.

Referencias

- Banerjee, S. y Lavie, A. (2005). METEOR: An automatic metric for MT evaluation with improved correlation with human judgments. En *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization* (pp. 65-72). Association for Computational Linguistics. <https://aclanthology.org/W05-0909/>
- Mathur, N., Baldwin, T. y Cohn, T. (2020). Tangled up in BLEU: Reevaluating the evaluation of automatic machine translation evaluation metrics. En *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 4984-4997). Association for Computational Linguistics. <https://aclanthology.org/2020.acl-main.448/>

- Papineni, K., Roukos, S., Ward, T. y Zhu, W.-J. (2002). BLEU: A method for automatic evaluation of machine translation. En *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics* (pp. 311-318). Association for Computational Linguistics. <https://aclanthology.org/P02-1040/>
- Popović, M. (2015). chrF: Character n-gram F-score for automatic MT evaluation. En *Proceedings of the Tenth Workshop on Statistical Machine Translation* (pp. 392-395). Association for Computational Linguistics. <https://aclanthology.org/W15-3049/>
- Rei, R., Stewart, C., Farinha, A. C. y Lavie, A. (2020). COMET: A neural framework for MT evaluation. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing* (pp. 2685-2702). Association for Computational Linguistics. <https://aclanthology.org/2020.emnlp-main.213/>
- Sellam, T., Das, D. y Parikh, A. P. (2020). BLEURT: Learning robust metrics for text generation. En *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 7881-7892). Association for Computational Linguistics. <https://aclanthology.org/2020.acl-main.704/>
- Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q. y Artzi, Y. (2020). BERTScore: Evaluating text generation with BERT. En *International Conference on Learning Representations*. <https://openreview.net/forum?id=SkeHuCVFDr>