

Tema 6.

Análisis automático de sesgo léxico y discursivo

Práctica para construir un subcorpus temático, revisar KWIC y analizar coocurrencias

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

Veridia Text Lab, la consultora de auditoría lingüística de la unidad, ha recibido una fase práctica del encargo: pasar del minicorpus didáctico a un subcorpus real de Twitter y comprobar si el pipeline permite localizar indicios observables de sesgo léxico y discursivo.

El cliente no pide que el sistema dicte veredictos morales sobre los textos. Necesita una primera exploración transparente: términos objetivo, presencia temática, ejemplos en contexto, coocurrencias y diferencias entre etiquetas de sentimiento que puedan orientar una lectura humana posterior.

En esta práctica trabajarás con tuits etiquetados como positivos, negativos o neutros. La tarea consiste en construir un subcorpus temático, justificar las decisiones de limpieza y observar qué patrones aparecen sin confundir frecuencia con significado discursivo.

Tu papel

Actúa como lingüista computacional junior de Veridia Text Lab. Tu entrega debe mostrar un flujo reproducible y prudente: qué términos has elegido, cómo has filtrado el corpus, qué evidencias aportan KWIC y coocurrencias, y qué límites tiene el análisis automático cuando se trabaja con lenguaje socialmente situado.

Actividades de práctica

A continuación tienes una práctica para aplicar todo lo trabajado con el minicorpus y con el subcorpus real de Twitter de PLN6. La actividad está diseñada para que puedas replicar el pipeline, construir un subcorpus temático real y argumentar tus decisiones.

Práctica guiada (evaluación): construir y analizar un subcorpus temático en Twitter

En esta práctica vas a construir un subcorpus temático real a partir de tuits etiquetados (pos/neg/neu) y aplicar el mismo pipeline del cuaderno para:

- (a) filtrar,
- (b) tokenizar,
- (c) medir presencia temática,
- (d) explorar contexto (KWIC), y
- (e) obtener coocurrencias.

Fuente: <https://github.com/garnachod/TwitterSentimentDataset>

Datos de trabajo

- Construye el DataFrame `df_real` exactamente como en los apartados 11.1 y 11.2 del cuaderno principal de la unidad: con los tres ficheros del repositorio y tomando las primeras 800 líneas no vacías de cada uno (`N_POR_CLASE = 800`).

- tweets_pos_clean.txt → etiqueta pos (tuits positivos); tweets_neg_clean.txt → etiqueta neg (negativos); tweets_clean.txt → etiqueta neu (neutros).
- El código del cuaderno descarga los ficheros automáticamente. Si no puedes descargarlos así, están también en la web, en la sección de Prácticas del Tema 6 (botón «Descargar los tuits (3 ficheros)»).

Tema de trabajo y términos

El tema «género» es el ejemplo resuelto en clase: no lo uses. Elige uno de estos cinco temas y copia en tu código exactamente sus dos listas (terminos_objetivo y terminos_kwic):

Tema: educación

```
tema = "educación"
terminos_objetivo = [
    "alumno", "alumnos", "alumna", "alumnas",
    "estudiante", "estudiantes",
    "profesor", "profesores", "profesora", "profesoras",
    "clase", "clases", "aula",
    "examen", "exámenes",
    "nota", "notas", "evaluación", "evaluar"
]
terminos_kwic = ["alumno", "profesor", "examen", "nota"]
```

Tema: trabajo

```
tema = "trabajo"
terminos_objetivo = [
    "trabajo", "trabajar", "curro",
    "jefe", "jefes", "jefa", "jefas",
    "empresa", "oficina",
    "contrato", "sueldo", "salario",
    "paro", "desempleo",
    "horas", "turno", "turnos",
    "currículum", "entrevista"
]
terminos_kwic = ["trabajo", "jefe", "sueldo", "paro"]
```

Tema: migración

```
tema = "migración"
terminos_objetivo = [
    "inmigrante", "inmigrantes",
    "migrante", "migrantes",
    "refugiado", "refugiados", "refugiada", "refugiadas",
    "frontera", "fronteras",
    "asilo",
    "papeles",
    "deportación", "deportar",
    "ilegal", "ilegales",
    "racismo", "xenofobia"
]
terminos_kwic = ["inmigrante", "migrante", "frontera", "asilo"]
```

Tema: política

```
tema = "política"
terminos_objetivo = [
    "gobierno", "presidente", "presidenta",
    "ministro", "ministra", "diputado", "diputada",
```

```
"elección", "elecciones", "voto", "votar",  
"partido", "congreso", "senado",  
"izquierda", "derecha",  
"corrupción",  
"protesta", "manifestación", "huelga"  
]  
terminos_kwic = ["gobierno", "elecciones", "voto", "corrupción"]
```

Tema: emoción

```
tema = "emoción"  
terminos_objetivo = [  
    "feliz", "alegre", "contento", "contenta",  
    "triste", "deprimido", "deprimida",  
    "odio", "odiar", "amo", "amar",  
    "miedo", "ansiedad", "estres", "estrés",  
    "enfado", "enojado", "enojada",  
    "ilusión", "esperanza",  
    "llorar", "sonreír", "sonrisa"  
]  
terminos_kwic = ["feliz", "triste", "odio", "miedo"]
```

Si el subcorpus temático queda muy pequeño (menos de 30 tuits), amplía terminos_objetivo o usa el patrón «relajado» (sin \b) para capturar hashtags y variantes, y explica qué has cambiado.

Importante: el objetivo no es «tener razón», sino tomar decisiones metodológicas y justificar interpretaciones a partir de evidencia.

Guion para resolver el ejercicio

1. **Revisar el objetivo del ejercicio.** Identifica qué se quiere analizar: la presencia de determinados términos relacionados con el tema elegido y su relación con las etiquetas de sentimiento del corpus.
2. **Comprobar el corpus de trabajo.** Observa qué DataFrame se está utilizando, qué columna contiene los textos y qué columna contiene las etiquetas de sentimiento.
3. **Definir la lista de términos objetivo.** Selecciona las palabras que representan el tema de análisis. Conviene incluir variantes de género y número, por ejemplo formas en singular y plural.
4. **Crear una función de tokenización.** Prepara una función que convierta cada texto a minúsculas y extraiga únicamente palabras, evitando signos de puntuación, enlaces, emojis u otros símbolos.
5. **Contar los términos objetivo en cada tweet.** Aplica la función de tokenización a cada texto y calcula cuántas palabras de la lista objetivo aparecen en cada tweet.
6. **Crear una nueva columna con el recuento.** Guarda en el DataFrame el número de términos objetivo encontrados en cada texto.
7. **Filtrar el subcorpus temático.** Selecciona únicamente los tweets en los que aparece al menos un término objetivo.
8. **Comparar los resultados por sentimiento.** Agrupa los tweets por etiqueta de sentimiento y calcula medidas como la media o el número de textos por clase.
9. **Extraer ejemplos en contexto.** Busca algunos tweets donde aparezcan los términos objetivo para observar cómo se usan realmente dentro del texto.
10. **Analizar coocurrencias léxicas.** Calcula qué palabras aparecen cerca de los términos objetivo dentro de una ventana de contexto definida.
11. **Limpiar los resultados.** Elimina stopwords, términos demasiado cortos y palabras propias de Twitter que no aporten información relevante.

12. **Interpretar los resultados con cautela.** Diferencia entre frecuencia de aparición y significado discursivo. Recuerda que contar palabras no equivale automáticamente a medir actitud, ideología o sentimiento.
13. **Responder a las preguntas de reflexión** (en celdas de texto). Utiliza los datos obtenidos en las tablas y los ejemplos revisados para elaborar una interpretación razonada, mencionando también las limitaciones del método. Las preguntas son estas dos:

Reflexión 1: a partir de tu tabla resumen_tema, ¿qué significaría que neg tenga más n_objetivo que pos (o al revés)? ¿Mide esto «actitud/sentimiento» o mide más bien «presencia temática»? Justifica con evidencia (valores) y menciona al menos una limitación del método.

Reflexión 2: elige tres palabras de tu tabla de coocurrencias (cooc_df). Para cada una, explica por qué podría estar relacionada con el tema (o por qué crees que es «ruido»). Incluye al final una frase sobre limpieza: ¿qué stopwords añadirías para Twitter y qué podrías perder si limpias demasiado?

14. **Revisar la coherencia final.** Comprueba que las respuestas se basan en los resultados del ejercicio y no en impresiones generales no apoyadas por los datos.

Rúbrica de evaluación

Se valora la construcción reproducible del subcorpus, la calidad de las evidencias extraídas y la prudencia interpretativa ante datos reales de redes sociales.

Criterio	Excelente	Adecuado	En proceso
Definición del subcorpus	Formula un tema claro, selecciona términos objetivo pertinentes e incluye variantes justificadas.	Define un tema y una lista de términos funcionales, aunque con justificación limitada.	La selección temática es confusa o no permite construir un subcorpus coherente.
Preparación y tokenización	Limpia y tokeniza los tuits de forma consistente, explicando qué se conserva y qué se elimina.	Aplica una preparación básica correcta, aunque sin justificar todas las decisiones.	La preparación del corpus impide obtener resultados fiables o comparables.
Recuento y filtrado	Cuenta los términos objetivo por tuit, crea la columna de recuento y filtra correctamente el subcorpus.	Obtiene el subcorpus temático, aunque con algún problema menor de organización o comprobación.	No consigue filtrar de forma válida los textos relevantes.
Comparación por sentimiento	Compara etiquetas pos/neg/neu con medidas claras y evita interpretar la etiqueta como significado total.	Compara los grupos principales, aunque la lectura de las etiquetas resulta parcial.	No relaciona los resultados con las etiquetas de sentimiento del corpus.
KWIC y coocurrencias	Extrae ejemplos en contexto y coocurrencias limpias que ayudan a formular hipótesis lingüísticas.	Obtiene KWIC o coocurrencias, pero con ruido o interpretación poco desarrollada.	No utiliza el contexto para revisar el uso real de los términos objetivo.
Interpretación crítica	Distingue frecuencia, asociación y sesgo discursivo, y redacta conclusiones prudentes basadas en evidencia.	Interpreta los datos con cierta cautela, aunque faltan límites metodológicos concretos.	Presenta conclusiones generales no apoyadas por los resultados obtenidos.