

Unidad 7. Extracción automática de terminología

Cuando entregues tu cuaderno, debes nombrar el fichero (.ipynb) de la siguiente manera:

(3 últimos dígitos del alumno 1)_(3 últimos dígitos del alumno 2)_(UD+número)

Por ejemplo:

- Dos alumnos entregan las actividades evaluables de la Unidad 7
- Identificador alumno 1: 200800331
- Identificador alumno 2: 200800229

Nombre del fichero: `331_229_UD7.ipynb`

Normas generales de la actividad

-  **Está prohibido resolver los ejercicios, o apoyarse para ello, en ninguna herramienta de IA.** La única excepción son las actividades en las que se autorice expresamente el uso de una herramienta específica para el objetivo de esa actividad: solo se puede usar en ese momento concreto y únicamente la(s) herramienta(s) permitida(s).
-  **El código debe ser el enseñado en el aula.** Aunque muchas actividades pueden resolverse de distintas formas (hay muchas maneras de llegar a un resultado solicitado), el código que emplees para resolver cada una de las actividades solicitadas tiene que ser el mismo que hemos aprendido en clase.
-  **Las preguntas de reflexión** debes responderlas **con tus propias palabras, sin ayuda alguna.**
-  **Textos de la actividad:** los textos con los que tienes que trabajar no se reproducen en este documento: los encontrarás en ficheros de texto plano (`.txt`) en el paquete de materiales de la unidad. Ábrelos, copia el texto y pégalo en el código bajo la variable indicada en cada actividad. Ficheros: `corpus_especializado_texto1.txt` , `corpus_especializado_texto2.txt` , `corpus_especializado_texto3.txt` , `corpus_especializado_texto4.txt` , `corpus_especializado_texto5.txt` , `corpus_general_texto1.txt` , `corpus_general_texto2.txt` , `corpus_general_texto3.txt` , `corpus_general_texto4.txt` , `corpus_general_texto5.txt` .
-  **Cuaderno de entrega:** trabaja sobre la plantilla `Plantilla_Evaluable_PLN7.ipynb` (contiene solo los títulos de cada actividad y una celda vacía del tipo que necesitas: de código y/o de texto). Respeta esa estructura al entregar.



Actividades propuestas



Actividad 1 — Cambia el umbral de frecuencia

1. Con los mismos textos y el código original empleado en la parte práctica guiada del cuaderno principal de PLN7, cambia `min_freq=2` a `min_freq=3` para unigramas y bigramas.
2. Compara:
 - ¿qué términos desaparecen?
 - ¿cuáles se mantienen?

 **Entrega:** resuelve el ejercicio añadiendo todo el código e imprime por pantalla los listados con top-10 antes/después. Finalmente, añade una celda de markdown con un comentario elaborado por ti sobre la pregunta del punto 2 (150-200 palabras).

Actividad 2 — Sustituye los corpus por textos propios

1. Crea `corpus_especializado` como una lista con los 5 textos que encontrarás en los materiales de trabajo `corpus_especializado_texto1.txt` a `corpus_especializado_texto5.txt` (copia cada texto y pégalo en el código, dentro de la lista).
2. Crea `corpus_general` como una lista con los 5 textos que encontrarás en los materiales de trabajo `corpus_general_texto1.txt` a `corpus_general_texto5.txt` (copia cada texto y pégalo en el código, dentro de la lista).
3. Ejecuta el pipeline y genera el mini-glosario.

 **Entrega:**

- Top-15 términos candidatos (tabla)
- mini-glosario impreso (con KWIC)
- comentario elaborado por ti (150-200 palabras): ¿qué 5 términos te parecen más “válidos” y por qué?

Actividad 3 — Reflexión crítica (sin código)

Responde (80-100 palabras por pregunta):

1. ¿Qué gana un enfoque basado en frecuencias frente a uno “neuronal”?
2. ¿Qué problemas aparecen si el corpus general es muy pequeño o no representativo?
3. ¿Qué tipo de términos crees que este método detecta peor? (pistas: variantes, sinónimos, términos raros)
4. ¿Cómo mejorarías el método sin perder interpretabilidad?

 **Entrega:** texto en Markdown.

Rúbrica de evaluación

 **Peso de esta actividad en la nota final:** Actividad 1 **30 %** · Actividad 2 **30 %** · Actividad 3, reflexión crítica **40 %**

 **Cómo se evalúa:** se valora **el procedimiento, no solo el resultado**. Resuelve la actividad con el método trabajado en el cuaderno principal de la unidad. Organizar el código a tu manera, usar otros nombres de variables o resolverlo de forma más breve **no penaliza**, siempre que se reconozca ese

método. Lo que sí penaliza es sustituirlo por librerías o herramientas que no hemos trabajado y que no explicas.

Criterio	Excelente (9-10)	Notable (7-8)	Aprobado (5-6)	Insuficiente (0-4)
Pipeline completo	Reproducible, claro y justificado	Correcto con detalles	Funciona pero poco claro	No funciona
N-gramas + filtros	Bien aplicados y explicados	Correctos	Parcial	Incorrecto
Comparación (weirdness)	Implementación + interpretación	Implementa bien	Interpreta poco	Incorrecto
Mini-glosario (KWIC)	Ejemplos útiles y relevantes	Correcto	Pocos/ruidosos	No hay
Reflexión	Crítica y bien argumentada	Adecuada	Superficial	No responde
Presentación	Cuaderno limpio y legible	Bien	Algo desordenado	Caótico