🧪 Unidad 7. Extracción automática de terminología

Cuando entregues tu cuaderno, debes nombrar el fichero (.ipynb) de la siguiente manera:

(3 últimos dígitos del alumno 1)_(3 últimos dígitos del alumno 2)_(UD+número)

Por ejemplo:

- Dos alumnos entregan las actividades evaluables de la Unidad 7
- Identificador alumno 1: 200800331
- Identificador alumno 2: 200800229

Nombre del fichero: `331_229_UD7.ipynb`

🚫 AVISO IMPORTANTE: PROHIBIDO EL USO DE IA

Está prohibido usar cualquier herramienta de inteligencia artificial (ChatGPT, Gemini, Copilot, la ayuda de IA de Google Colab, etc.) **para resolver las actividades**. La única excepción son las partes de una actividad en las que se pida explícitamente su uso: en ese caso, solo puedes usarla en ese momento concreto y únicamente la herramienta indicada.

Las interpretaciones de resultados y las preguntas de reflexión deben resolverse siempre a partir de tu propio trabajo intelectual, sin ningún apoyo de una IA.

⚠️ Normas generales de la actividad

- 🧑‍🏫 **El código debe ser el enseñado en el aula.** Aunque muchas actividades pueden resolverse de distintas formas (hay muchas maneras de llegar a un resultado solicitado), el código que emplees para resolver cada una de las actividades solicitadas tiene que ser el mismo que hemos aprendido en clase.
- ✍️ **Las preguntas de reflexión** debes responderlas **con tus propias palabras, sin ayuda alguna**.
- 📎 **Textos de la actividad:** los textos con los que tienes que trabajar no se reproducen en este documento: los encontrarás en ficheros de texto plano (`.txt`) en el paquete de materiales de la unidad. Ábrelos, copia el texto y pégalo en el código bajo la variable indicada en cada actividad. Ficheros: `corpus_especializado_texto1.txt` , `corpus_especializado_texto2.txt` , `corpus_especializado_texto3.txt` , `corpus_especializado_texto4.txt` , `corpus_especializado_texto5.txt` , `corpus_general_texto1.txt` , `corpus_general_texto2.txt` , `corpus_general_texto3.txt` , `corpus_general_texto4.txt` , `corpus_general_texto5.txt` .

- 📄 **Cuaderno de entrega:** trabaja sobre la plantilla `Plantilla_Evaluable_PLN7.ipynb` (contiene solo los títulos de cada actividad y una celda vacía del tipo que necesitas: de código y/o de texto). Respeta esa estructura al entregar.

🧾 Actividades propuestas

🧩 Actividad 1 — Cambia el umbral de frecuencia

1. Con los mismos textos y el código original empleado en la parte práctica guiada del cuaderno principal de PLN7, cambia `min_freq=2` a `min_freq=3` para unigramas y bigramas.
2. Compara:
    - ¿qué términos desaparecen?
    - ¿cuáles se mantienen?

📩 **Entrega:** resuelve el ejercicio añadiendo todo el código e imprime por pantalla los listados con top-10 antes/después. Finalmente, añade una celda de markdown con un comentario elaborado por ti sobre la pregunta del punto 2 (150-200 palabras).

🧩 Actividad 2 — Sustituye los corpus por textos propios

1. Crea `corpus_especializado` como una lista con los 5 textos que encontrarás en los materiales de trabajo `corpus_especializado_texto1.txt` a `corpus_especializado_texto5.txt` (copia cada texto y pégalo en el código, dentro de la lista).

2. Crea `corpus_general` como una lista con los 5 textos que encontrarás en los materiales de trabajo `corpus_general_texto1.txt` a `corpus_general_texto5.txt` (copia cada texto y pégalo en el código, dentro de la lista).

3. Ejecuta el pipeline y genera el mini-glosario.

📩 **Entrega:**

- Top-15 términos candidatos (tabla)
- mini-glosario impreso (con KWIC)
- comentario elaborado por ti (150-200 palabras): ¿qué 5 términos te parecen más “válidos” y por qué?

🧠 Actividad 3 — Reflexión crítica (sin código)

Responde (80-100 palabras por pregunta):

1. ¿Qué gana un enfoque basado en frecuencias frente a uno “neuronal”?
2. ¿Qué problemas aparecen si el corpus general es muy pequeño o no representativo?
3. ¿Qué tipo de términos crees que este método detecta peor? (pistas: variantes, sinónimos, términos raros)
4. ¿Cómo mejorarías el método sin perder interpretabilidad?

📤 **Entrega:** texto en Markdown.

📋 Rúbrica de evaluación

⚖️ **Peso de esta actividad en la nota final:** Actividad 1 **30 %** · Actividad 2 **30 %** · Actividad 3, reflexión crítica **40 %**

🧭 **Cómo se evalúa:** se valora **el procedimiento, no solo el resultado**. Resuelve la actividad con el método trabajado en el cuaderno principal de la unidad. Organizar el código a tu manera, usar otros nombres de variables o resolverlo de forma más breve **no penaliza**, siempre que se reconozca ese método. Lo que sí penaliza es sustituirlo por librerías o herramientas que no hemos trabajado y que no explicas.

Criterio	Excelente (9-10)	Notable (7-8)	Aprobado (5-6)	Insuficiente (0-4)
Pipeline completo	Reproducible, claro y justificado	Correcto con detalles	Funciona pero poco claro	No funciona
N-gramas + filtros	Bien aplicados y explicados	Correctos	Parcial	Incorrecto
Comparación (weirdness)	Implementación + interpretación	Implementa bien	Interpreta poco	Incorrecto
Mini-glosario (KWIC)	Ejemplos útiles y relevantes	Correcto	Pocos/ruidosos	No hay
Reflexión	Crítica y bien argumentada	Adecuada	Superficial	No responde
Presentación	Cuaderno limpio y legible	Bien	Algo desordenado	Caótico