

## Tema 7.

# Extracción automática de terminología

*Práctica para detectar candidatos terminológicos, revisar KWIC y construir un miniglosario*

---

Prácticas | Programación para PLN | Universidad Pontificia Comillas

# Proyecto de práctica

---

## Encargo

LexiData Solutions, la empresa de traducción, localización y gestión terminológica de la unidad, necesita probar una primera capa automática para apoyar la creación de glosarios. El volumen de documentación especializada crece más rápido que la capacidad del equipo para leerlo todo desde cero.

El objetivo de esta práctica no es producir una base terminológica final. El encargo consiste en generar una lista priorizada de candidatos a término a partir de dos corpus: uno especializado y otro general. La comparación permitirá observar qué unidades parecen más propias del dominio.

Trabajarás con un pipeline transparente: tokenizar, eliminar stopwords, extraer n-gramas, filtrar por frecuencia mínima, calcular *weirdness*, revisar ejemplos KWIC y construir un miniglosario inicial. Cada resultado debe leerse como indicio para revisión humana, no como validación automática.

## Tu papel

---

Actúa como analista terminológica junior de LexiData Solutions. Tu tarea es preparar una salida útil para una persona experta: candidatos ordenados, decisiones de filtrado justificadas, contextos KWIC revisables y una reflexión clara sobre los límites del método.

## Actividades de práctica

---

### Práctica independiente: extracción de términos candidatos en un corpus especializado

Este documento contiene 10 ejercicios independientes para practicar la extracción de términos candidatos en un corpus especializado.

Las actividades reproducen las operaciones trabajadas en la unidad: tokenización, eliminación de stopwords, preprocesamiento, conteo de n-gramas, filtrado por frecuencia mínima, cálculo de *weirdness*, KWIC y construcción de miniglosarios.

## Corpus de trabajo

Los ejercicios sobre preprocesamiento, n-gramas, *weirdness*, KWIC y miniglosario trabajan con dos corpus breves: uno especializado en PLN y traducción automática, y otro general de contraste.

### Corpus especializado

**Texto 1.** La tokenización es un paso fundamental en el procesamiento del lenguaje natural. En PLN, la tokenización permite dividir el texto en unidades básicas llamadas tokens. Un modelo de lenguaje necesita una tokenización coherente para entrenarse correctamente.

**Texto 2.** Un modelo de lenguaje se entrena a partir de grandes corpus de texto. Los modelos de lenguaje actuales utilizan redes neuronales profundas. El entrenamiento de un modelo de lenguaje requiere muchos datos y recursos computacionales.

**Texto 3.** La traducción automática es una de las aplicaciones más importantes del PLN. La traducción automática neuronal ha mejorado la calidad de las traducciones. Los sistemas de traducción automática se evalúan mediante métricas automáticas.

**Texto 4.** En la traducción automática se utilizan corpus paralelos. Los corpus paralelos contienen textos alineados en dos lenguas. La calidad del corpus es clave para un sistema de traducción automática.

### Corpus general

**Texto 1.** La ciudad tiene muchos parques y espacios públicos. Las personas caminan por la ciudad durante el día. El transporte público permite llegar a diferentes barrios.

**Texto 2.** La educación es importante para el desarrollo de una sociedad. Los estudiantes aprenden en escuelas, universidades y centros de formación. La lectura y la escritura son habilidades fundamentales.

**Texto 3.** La economía de un país depende de muchos factores. Las empresas producen bienes y servicios para los consumidores. El trabajo y la inversión influyen en el crecimiento económico.

**Texto 4.** La salud pública requiere hospitales, profesionales y recursos. La prevención de enfermedades mejora la calidad de vida. Los sistemas sanitarios atienden a la población.

## Ejercicio 1. Tokenización de una frase especializada

Aplica la función `simple_tokenize` a la siguiente frase:

La tokenización en PLN: modelos, embeddings y n-gramas (2025).

Después, observa qué cambios ha realizado la función sobre el texto original.

## Ejercicio 2. Eliminación de palabras vacías

A partir de la misma frase del ejercicio anterior, aplica primero `simple_tokenize` y después `remove_stopwords`.

Compara el resultado con el del ejercicio 1.

## Ejercicio 3. Preprocesamiento completo del corpus especializado

Preprocesa el corpus especializado usando la función `preprocess_corpus`.

Después, muestra: (1) el número total de tokens; (2) los 20 primeros tokens del corpus especializado.

## Ejercicio 4. Conteo de unigramas, bigramas y trigramas

Cuenta los unigramas, bigramas y trigramas del corpus especializado.

Después, muestra los 10 bigramas más frecuentes.

## Ejercicio 5. Filtrado de candidatos por frecuencia mínima

Filtra los unigramas, bigramas y trigramas del corpus especializado para conservar solo aquellos que aparecen al menos dos veces.

Después, muestra cuántos candidatos quedan en cada grupo.

## Ejercicio 6. Cálculo de weirdness

Calcula la puntuación de *weirdness* para unigramas, bigramas y trigramas.

Después, muestra los 10 primeros bigramas ordenados por *weirdness*.

## Ejercicio 7. Ranking conjunto de candidatos

Une los resultados de unigramas, bigramas y trigramas en una única tabla.

Después, ordena todos los candidatos por *weirdness* y muestra los 20 primeros.

## Ejercicio 8. Análisis KWIC de un candidato terminológico

Busca ejemplos KWIC del término `modelo lenguaje`.

Usa una ventana de 4 palabras a la izquierda y a la derecha.

## Ejercicio 9. Construcción de un miniglosario

Construye un miniglosario con los 10 mejores candidatos del ranking general.

Después, imprímelo de forma legible.

## Ejercicio 10. Comparación con una frecuencia mínima más estricta

Repite el filtrado, pero ahora exige que los unigramas y bigramas aparezcan al menos 3 veces.

Después, extrae los 10 primeros términos de cada ranking.

### Actividad final de reflexión

1. ¿Qué diferencia hay entre un unigrama, un bigrama y un trigramas?
2. ¿Por qué eliminamos *stopwords* antes de contar n-gramas?
3. ¿Qué ventaja tiene usar *weirdness* frente a usar solo frecuencia absoluta?
4. ¿Por qué es útil observar ejemplos KWIC antes de aceptar un término candidato?
5. ¿Qué problema puede aparecer si la frecuencia mínima es demasiado alta?

## Rúbrica de evaluación

Se valora la construcción reproducible del flujo de extracción terminológica, la claridad del ranking de candidatos y la prudencia con la que se interpretan los resultados automáticos.

| Criterio                        | Excelente                                                                                                  | Adecuado                                                                                    | En proceso                                                                                           |
|---------------------------------|------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------|
| Tokenización y preprocesamiento | Aplica correctamente tokenización, limpieza y eliminación de stopwords, explicando su efecto lingüístico.  | Aplica el preprocesamiento básico, aunque la explicación de algunas decisiones es limitada. | No obtiene una representación limpia o no distingue los pasos del preprocesamiento.                  |
| Extracción y conteo de n-gramas | Distingue unigramas, bigramas y trigramas, y obtiene conteos claros para el corpus especializado.          | Cuenta n-gramas, aunque con alguna imprecisión en la comparación o presentación.            | No diferencia correctamente los tipos de n-grama o sus frecuencias.                                  |
| Filtrado y weirdness            | Filtra por frecuencia mínima y calcula <i>weirdness</i> interpretando la comparación entre corpus.         | Aplica el filtrado y la medida contrastiva, aunque la interpretación es parcial.            | No usa el corpus general de forma adecuada o interpreta <i>weirdness</i> como validación automática. |
| Ranking de candidatos           | Une candidatos de distinta longitud y ordena el ranking con criterios terminológicos y técnicos claros.    | Construye un ranking general, aunque con poca atención a ruido, longitud o estabilidad.     | No consigue producir una lista de candidatos comparable y legible.                                   |
| KWIC y miniglosario             | Usa KWIC para revisar candidatos y construye un miniglosario inicial con información útil para validación. | Incluye KWIC o miniglosario, pero con ejemplos limitados o poco comentados.                 | No utiliza contexto o presenta el miniglosario como si fuera una base terminológica final.           |
| Reflexión terminológica         | Distingue término, candidato y palabra frecuente, y explica límites de corpus, stopwords y umbrales.       | Reconoce algunos límites, aunque la reflexión es general o poco conectada con resultados.   | No justifica las decisiones ni diferencia indicio automático de validación terminológica.            |