



8. Clasificación temática de textos

Cuando entregues tu cuaderno, debes nombrar el fichero (.ipynb) de la siguiente manera:

(3 últimos dígitos del alumno 1)_(3 últimos dígitos del alumno 2)_(UD+número)

Por ejemplo:

- Dos alumnos entregan las actividades evaluables de la Unidad 8
- Identificador alumno 1: 200800331
- Identificador alumno 2: 200800229

Nombre del fichero: `331_229_UD8.ipynb`



Normas generales de la actividad

-  **Está prohibido resolver los ejercicios, o apoyarse para ello, en ninguna herramienta de IA.** La única excepción son las actividades en las que se autorice expresamente el uso de una herramienta específica para el objetivo de esa actividad: solo se puede usar en ese momento concreto y únicamente la(s) herramienta(s) permitida(s).
-  **El código debe ser el enseñado en el aula.** Aunque muchas actividades pueden resolverse de distintas formas (hay muchas maneras de llegar a un resultado solicitado), el código que emplees para resolver cada una de las actividades solicitadas tiene que ser el mismo que hemos aprendido en clase.
-  **Las preguntas de reflexión** debes responderlas **con tus propias palabras, sin ayuda alguna.**
-  **Cuaderno de entrega:** trabaja sobre la plantilla `Plantilla_Evaluable_PLN8.ipynb` (contiene solo los títulos de cada actividad y una celda vacía del tipo que necesitas: de código y/o de texto). Respeta esa estructura al entregar.



Actividad propuesta

Instrucciones

Clasificación temática explicable

Objetivo de la actividad

Aplicar el método de clasificación temática explicable desarrollado en el cuaderno para:

- clasificar textos reales,
- justificar las decisiones del sistema,
- reflexionar sobre las ventajas y límites del enfoque.

Esta actividad pone el foco no solo en el resultado, sino en la argumentación lingüística detrás de cada decisión.



Descripción de la tarea

1 Preparación de los datos

Cada estudiante (o grupo) deberá:

- Seleccionar **8–10 textos muy breves** —una o dos frases cada uno—, de forma que **entre todos** sumen 100–200 palabras (es decir, unas 10–25 palabras por texto, no 100–200 cada uno), repartidos entre al menos **3 temáticas** distintas, por ejemplo:
 - jurídico
 - técnico
 - divulgativo
 - literario
 - (u otras, si se justifican)

Los textos pueden proceder de:

- fragmentos de leyes o contratos,
- manuales o instrucciones técnicas,
- artículos divulgativos,
- textos narrativos o literarios breves.



Importante: los textos deben ser auténticos (no inventados) y citar su procedencia.

2 Ejecución del sistema

Usando el cuaderno:

- Sustituye `texts_to_classify` por tu propio conjunto de textos.
- Ejecuta el pipeline completo:
 - preprocesamiento con spaCy,
 - vectorización TF,
 - similitud coseno,
 - clasificación por prototipos temáticos.
 - informe final

Obtén para cada texto:

- la **clase predicha**,
 - las **similitudes con cada temática**,
 - las **evidencias léxicas** (lemas compartidos).
-

3 Análisis y justificación

Para al menos 4 textos, describe brevemente:

- por qué el sistema los ha clasificado en esa temática,
- qué palabras o lemas han sido determinantes,
- si estás de acuerdo con la decisión o no.

👉 Aquí es clave usar el vocabulario del curso: *frecuencia*, *palabras clave*, *similitud léxica*, *prototipo*, *evidencia*.

Entrega final al cliente

La entrega deberá incluir:

1. Tabla de resultados, con:
 - texto (o identificador),
 - clase predicha,
 - similitudes por clase. Esta tabla es la correspondiente al paso en el que ejecutas la variable para generar `df_resultados` (como vimos en la parte práctica explicativa del cuaderno).
2. Comentario justificativo de al menos 4 textos (65-85 palabras cada uno).
3. Preguntas de reflexión (75-90 palabras cada una):
 - ¿En qué situaciones crees que este sistema explicable es preferible a un clasificador automático más complejo (por ejemplo, basado en redes neuronales), aunque sea menos preciso? Justifica tu respuesta con ejemplos del cuaderno.
 - ¿Cómo influyen las palabras clave elegidas en los resultados del sistema? ¿Qué ocurre si una temática está mal representada o si dos temáticas comparten vocabulario? Relaciónalo con el concepto de sesgo del modelo.
 - ¿Qué tipos de textos o situaciones crees que este método clasifica peor? Piensa, por ejemplo, en textos híbridos, irónicos, muy breves o muy especializados, y explica por qué el método basado en frecuencia y similitud puede fallar.

0. Textos (auténticos) y fuentes

Los textos son **fragmentos muy breves**: una o dos frases cada uno. La cifra de ~100–200 palabras es la suma **de los 8–10 fragmentos juntos**, no la de cada uno.

Jurídico

- Constitución Española, art. 14 (BOE):
<https://www.boe.es/buscar/act.php?id=BOE-A-1978-31229>
- Código Civil, art. 1089 (Iberley):
<https://www.iberley.es/legislacion/articulo-1089-codigo-civil>

Técnico

- “Universal Serial Bus (USB)” (Wikipedia ES):
https://es.wikipedia.org/wiki/Universal_Serial_Bus
- “Actualizar controladores en Windows” (Microsoft Support ES):
<https://support.microsoft.com/es-es/windows/actualizar-controladores-a-trav%C3%A9s-de->

administrador-de-dispositivos-en-windows-ec62f46c-ff14-c91d-eead-d7126dc1f7b6

- “USB” (DLE-RAE):
<https://dle.rae.es/usb>

Divulgativo

- “Cambio climático” (Wikipedia ES):
https://es.wikipedia.org/wiki/Cambio_clim%C3%A1tico
- “Energía solar” (Wikipedia ES):
https://es.wikipedia.org/wiki/Energ%C3%ADa_solar

Literario

- *Don Quijote de la Mancha* (CVC):
<https://cvc.cervantes.es/literatura/clasicos/quijote/edicion/parte1/cap01/default.htm>
- Bécquer, Rima LIII (UNED Poemas):
<https://poemas.uned.es/poema/rima-liii-gustavo-adolfo-becquer/>

1. Instalación y modelo spaCy

2. Importaciones

3. Carga de SpaCy

4. Preparación de datos

5. Preprocesamiento con SpaCy

6. Vectorización

7. Similitud coseno

8. Prototipos temáticos

9. Clasificación + evidencias

10. Informe final



Entrega 1 — Tabla de resultados



Entrega 2 — Comentario justificativo (4 textos)



Entrega 3 — Reflexión final



Rúbrica de evaluación



Peso de esta actividad en la nota final: tabla de resultados **20 %** · comentario justificativo **40 %** · reflexión final **40 %**



Cómo se evalúa: se valora **el procedimiento, no solo el resultado**. Resuelve la actividad con el método trabajado en el cuaderno principal de la unidad. Organizar el código a tu manera, usar otros nombres de variables o resolverlo de forma más breve **no penaliza**, siempre que se reconozca ese método. Lo que sí penaliza es sustituirlo por librerías o herramientas que no hemos trabajado y que no explicas.

Criterio	Excelente (9-10)	Notable (7-8)	Aprobado (5-6)	Insuficiente (0-4)
Preprocesamiento	Correcto y justificado	Correcto con detalles	Funciona pero poco claro	Incorrecto
Vectorización TF	Implementación clara	Correcta	Parcial	Incorrecta
Similitud coseno	Bien implementada + interpretación	Implementa	Interpreta poco	No funciona
Clasificación	Regla clara y coherente	Correcta	Inestable	Errónea
Explicabilidad	Evidencias bien presentadas	Evidencias básicas	Pocas evidencias	No hay
Reflexión crítica	Propone mejoras razonables	Buena	Superficial	Nula
Presentación	Cuaderno limpio y legible	Bien	Desordenado	Caótico