🧪 8. Clasificación temática de textos

Cuando entregues tu cuaderno, debes nombrar el fichero (.ipynb) de la siguiente manera:

(3 últimos dígitos del alumno 1)_(3 últimos dígitos del alumno 2)_(UD+número)

Por ejemplo:

- Dos alumnos entregan las actividades evaluables de la Unidad 8
- Identificador alumno 1: 200800331
- Identificador alumno 2: 200800229

Nombre del fichero: `331_229_UD8.ipynb`

🚫 AVISO IMPORTANTE: PROHIBIDO EL USO DE IA

Está prohibido usar cualquier herramienta de inteligencia artificial (ChatGPT, Gemini, Copilot, la ayuda de IA de Google Colab, etc.) **para resolver las actividades**. La única excepción son las partes de una actividad en las que se pida explícitamente su uso: en ese caso, solo puedes usarla en ese momento concreto y únicamente la herramienta indicada.

Las interpretaciones de resultados y las preguntas de reflexión deben resolverse siempre a partir de tu propio trabajo intelectual, sin ningún apoyo de una IA.

⚠️ Normas generales de la actividad

- 🧑‍🏫 **El código debe ser el enseñado en el aula.** Aunque muchas actividades pueden resolverse de distintas formas (hay muchas maneras de llegar a un resultado solicitado), el código que emplees para resolver cada una de las actividades solicitadas tiene que ser el mismo que hemos aprendido en clase.
- ✍️ **Las preguntas de reflexión** debes responderlas **con tus propias palabras, sin ayuda alguna**.
- 📄 **Cuaderno de entrega:** trabaja sobre la plantilla `Plantilla_Evaluable_PLN8.ipynb` (contiene solo los títulos de cada actividad y una celda vacía del tipo que necesitas: de código y/o de texto). Respeta esa estructura al entregar.

🧪 Actividad propuesta

Instrucciones

Clasificación temática explicable

🎯 Objetivo de la actividad

Aplicar el método de clasificación temática explicable desarrollado en el cuaderno para:

- clasificar textos reales,
- justificar las decisiones del sistema,
- reflexionar sobre las ventajas y límites del enfoque.

Esta actividad pone el foco no solo en el resultado, sino en la argumentación lingüística detrás de cada decisión.

📝 Descripción de la tarea

1️⃣ Preparación de los datos

Cada estudiante (o grupo) deberá:

- Seleccionar **8–10 textos muy breves** —una o dos frases cada uno—, de forma que **entre todos** sumen 100–200 palabras (es decir, unas 10–25 palabras por texto, no 100–200 cada uno), repartidos entre al menos **3 temáticas** distintas, por ejemplo:
  - jurídico
  - técnico
  - divulgativo
  - literario
  - (u otras, si se justifican)

Los textos pueden proceder de:

- fragmentos de leyes o contratos,
- manuales o instrucciones técnicas,
- artículos divulgativos,
- textos narrativos o literarios breves.

📌 **Importante**: los textos deben ser auténticos (no inventados) y citar su procedencia.

2️⃣ Ejecución del sistema

Usando el cuaderno:

- Sustituye `texts_to_classify` por tu propio conjunto de textos.
- Ejecuta el pipeline completo:
  - preprocesamiento con spaCy,
  - vectorización TF,
  - similitud coseno,
  - clasificación por prototipos temáticos.
  - informe final

Obtén para cada texto:

- la **clase predicha**,
- las **similitudes con cada temática**,
- las **evidencias léxicas** (lemas compartidos).

🔑 Palabras clave: qué tienes que hacer

Las palabras clave del cuaderno (`class_keywords`) están pensadas para los 4 textos de ejemplo del cuaderno y **no bastan para tus textos**. En la sección 8:

- Puedes conservar, quitar o cambiar las palabras del cuaderno.
- Cada temática que uses debe tener **al menos 5 palabras clave propias**, es decir, elegidas por ti y no copiadas del cuaderno.
- Debajo del código, escribe una **justificación breve** (3–4 líneas por temática): qué palabras conservas, cuáles añades y por qué son típicas de esa temática.
- Comprueba cómo spaCy lematiza tus palabras (por ejemplo, `preprocess("controladores")`) y qué palabras comparten dos temáticas.
- Si ajustas las listas después de ver los resultados, indícalo en la justificación (qué has cambiado y por qué).
- Si un texto no comparte ninguna palabra clave con ninguna temática, el sistema lo marca como `sin_clasificar` . Es un resultado válido: coméntalo. Si decides ampliar las listas por ello, indícalo.

3️⃣ Análisis y justificación

Para al menos 4 textos, describe brevemente:

- por qué el sistema los ha clasificado en esa temática,
- qué palabras o lemas han sido determinantes,
- si estás de acuerdo con la decisión o no.

👉 Aquí es clave usar el vocabulario del curso: *frecuencia*, *palabras clave*, *similitud léxica*, *prototipo*, *evidencia*.

📤 Entrega final al cliente

La entrega deberá incluir:

1. Tabla de resultados, con:
    - texto (o identificador),
    - clase predicha,
    - similitudes por clase. Esta tabla es la correspondiente al paso en el que ejecutas la variable para generar la tabla de similitudes (`df_scores` en el cuaderno principal; si tu variable se llama de otra forma, no importa). Si algún texto queda como `sin_clasificar` , debe aparecer así en la tabla. Esta entrega incluye también la **justificación de las palabras clave** de la sección 8.
2. Comentario justificativo de al menos 4 textos (65-85 palabras cada uno).

3. Preguntas de reflexión (75-90 palabras cada una):
    - ¿En qué situaciones crees que este sistema explicable es preferible a un clasificador automático más complejo (por ejemplo, basado en redes neuronales), aunque sea menos preciso? Justifica tu respuesta con ejemplos del cuaderno.
    - ¿Cómo influyen las palabras clave elegidas en los resultados del sistema? ¿Qué ocurre si una temática está mal representada o si dos temáticas comparten vocabulario? Relaciónalo con el concepto de sesgo del modelo. Menciona las palabras clave que añadiste y qué efecto tuvieron.
    - ¿Qué tipos de textos o situaciones crees que este método clasifica peor? Piensa, por ejemplo, en textos híbridos, irónicos, muy breves o muy especializados, y explica por qué el método basado en frecuencia y similitud puede fallar.

0. Textos (auténticos) y fuentes

Los textos son **fragmentos muy breves**: una o dos frases cada uno. La cifra de ~100–200 palabras es la suma **de los 8–10 fragmentos juntos**, no la de cada uno.

Ejemplos de fragmentos válidos (una o dos frases, auténticos y con su fuente). Sirven de modelo del tipo de texto que se pide para cada temática; no tienes que usar estos concretos. Si recortas un fragmento, marca con (…) lo omitido.

Temática	Fragmento de ejemplo	Fuente	Palabras clave que podrías añadir a la temática
Jurídico	«Los españoles son iguales ante la ley, sin que pueda prevalecer discriminación alguna (…)»	Constitución Española, art. 14 (BOE)	*derecho, norma, obligación, responsabilidad, sanción*
Técnico	«Aprende a actualizar o reinstalar controladores en Windows con el Administrador de dispositivos.»	Microsoft Support ES	*software, conexión, protocolo, configuración, cable*
Divulgativo	«Un cambio climático se define como la variación en el estado del sistema climático terrestre (…) que perdura durante periodos de tiempo suficientemente largos.»	Wikipedia ES, «Cambio climático»	*definir, explicar, concepto, energía, científico*
Literario	«Volverán las oscuras golondrinas / en tu balcón sus nidos a colgar (…)»	Bécquer, Rima LIII	*poema, verso, noche, memoria, silencio*

La última columna no son palabras de esos fragmentos, sino palabras que **suelen aparecer en textos de esa temática**: así las listas sirven también para otros textos y no solo para los tuyos.

Fuentes donde puedes buscar textos:

Jurídico

- Constitución Española, art. 14 (BOE): https://www.boe.es/buscar/act.php?id=BOE-A-1978-31229
- Código Civil, art. 1089 (Iberley): https://www.iberley.es/legislacion/articulo-1089-codigo-civil

Técnico

- “Universal Serial Bus (USB)” (Wikipedia ES): https://es.wikipedia.org/wiki/Universal_Serial_Bus
- “Actualizar controladores en Windows” (Microsoft Support ES): https://support.microsoft.com/es-es/windows/actualizar-controladores-a-trav%C3%A9s-de-administrador-de-dispositivos-en-windows-ec62f46c-ff14-c91d-eead-d7126dc1f7b6
- “USB” (DLE-RAE): https://dle.rae.es/usb

Divulgativo

- “Cambio climático” (Wikipedia ES): https://es.wikipedia.org/wiki/Cambio_clim%C3%A1tico
- “Energía solar” (Wikipedia ES): https://es.wikipedia.org/wiki/Energ%C3%ADa_solar

Literario

- *Don Quijote de la Mancha* (CVC): https://cvc.cervantes.es/literatura/clasicos/quijote/edicion/parte1/cap01/default.htm
- Bécquer, Rima LIII (UNED Poemas): https://poemas.uned.es/poema/rima-liii-gustavo-adolfo-becquer/

1. Instalación y modelo spaCy

2. Importaciones

3. Carga de SpaCy

4. Preparación de datos

5. Preprocesamiento con SpaCy

6. Vectorización

7. Similitud coseno

8. Prototipos temáticos

Justificación de las palabras clave

9. Clasificación + evidencias

10. Informe final

📤 Entrega 1 — Tabla de resultados

📤 Entrega 2 — Comentario justificativo (4 textos)

📤 Entrega 3 — Reflexión final

📋 Rúbrica de evaluación

⚖️ **Peso de esta actividad en la nota final:** tabla de resultados **20 %** · comentario justificativo **40 %** · reflexión final **40 %**

🧭 **Cómo se evalúa:** se valora **el procedimiento, no solo el resultado**. Resuelve la actividad con el método trabajado en el cuaderno principal de la unidad. Organizar el código a tu manera, usar otros nombres de variables o resolverlo de forma más breve **no penaliza**, siempre que se reconozca ese método. Lo que sí penaliza es sustituirlo por librerías o herramientas que no hemos trabajado y que no explicas.

Criterio	Excelente (9-10)	Notable (7-8)	Aprobado (5-6)	Insuficiente (0-4)
Preprocesamiento	Correcto y justificado	Correcto con detalles	Funciona pero poco claro	Incorrecto
Vectorización TF	Implementación clara	Correcta	Parcial	Incorrecta
Similitud coseno	Bien implementada + interpretación	Implementa	Interpreta poco	No funciona
Clasificación	Regla clara y coherente	Correcta	Inestable	Errónea
Palabras clave	Ampliadas (≥ 5 propias por temática), justificadas y coherentes con la temática	Ampliadas con justificación básica	Ampliadas sin justificar	Solo las del cuaderno
Explicabilidad	Evidencias bien presentadas	Evidencias básicas	Pocas evidencias	No hay
Reflexión crítica	Propone mejoras razonables	Buena	Superficial	Nula
Presentación	Cuaderno limpio y legible	Bien	Desordenado	Caótico