

Tema 8.

Clasificación automática de textos

Práctica II. Clasificación multiclase de noticias

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

LexiData Solutions necesita prototipar un clasificador que organice noticias en categorías temáticas. A diferencia de la práctica anterior, el problema no se reduce a dos clases: cada texto debe asignarse a una de varias categorías posibles.

El encargo consiste en construir un flujo completo de clasificación multiclase sobre AG News, interpretar el rendimiento por categoría y analizar por qué algunos temas pueden confundirse entre sí.

Tu papel

Actúa como analista de PLN responsable de preparar un sistema de clasificación temática para una redacción digital.

Tu trabajo debe mostrar que comprendes tanto la parte técnica del pipeline como la lectura lingüística de los errores: las noticias pueden compartir vocabulario, entidades y marcos temáticos aunque pertenezcan a categorías distintas.

Actividades de práctica

Práctica II: clasificación de noticias AG News

Este documento contiene 10 ejercicios independientes y acumulativos para practicar la clasificación supervisada de textos con un flujo completo de aprendizaje automático aplicado a PLN.

Las actividades reproducen las operaciones trabajadas en la unidad: carga del corpus, análisis exploratorio, preprocesamiento, división entrenamiento-prueba, vectorización TF-IDF, entrenamiento, evaluación, prueba con textos nuevos e interpretación prudente de las predicciones.

Corpus de trabajo

El corpus de trabajo es AG News Topic Classification Dataset, una selección usada como benchmark de clasificación de noticias.

Las clases son World, Sports, Business y Sci/Tech. La práctica se centra en observar cómo cambia la evaluación cuando el modelo debe elegir entre cuatro categorías.

Ejercicio 1. Carga del corpus AG News

Importa el dataset AG News desde Hugging Face con la librería datasets y une sus partes de entrenamiento y prueba en una única tabla de trabajo con textos y etiquetas:

```
!pip -q install datasets
from datasets import load_dataset
import pandas as pd
ds = load_dataset("ag_news")
data = pd.concat([ds["train"].to_pandas(), ds["test"].to_pandas()], ignore_index=True)
```

Incluye en el cuaderno la correspondencia entre las clases numéricas y sus categorías: World, Sports, Business y Sci/Tech.

Ejercicio 2. Inspección de ejemplos

Muestra varios titulares o textos breves de cada clase y comprueba que el contenido coincide razonablemente con su etiqueta.

Describe qué señales léxicas o temáticas parecen diferenciar unas categorías de otras.

Ejercicio 3. Análisis exploratorio de datos

Comprueba valores ausentes, tamaño total del dataset y distribución de clases.

Representa la proporción de cada categoría y comenta si la evaluación se ve afectada por equilibrio o desbalance.

Ejercicio 4. Preprocesamiento textual

Aplica una limpieza básica del texto: normalización, eliminación de caracteres no alfabéticos, tokenización, stopwords y lematización.

Muestra ejemplos antes y después para comprobar que el proceso no elimina información temática relevante.

Ejercicio 5. División entrenamiento-prueba

Divide el dataset en entrenamiento y prueba con una proporción 80/20 y estratificación por clase.

Indica el número de noticias por partición y verifica que las cuatro categorías siguen representadas.

Ejercicio 6. Representación TF-IDF

Vectoriza las noticias mediante TF-IDF con unigramas y bigramas.

Justifica por qué los bigramas pueden ser útiles en noticias, por ejemplo para expresiones de deporte, economía, tecnología o política internacional.

Ejercicio 7. Entrenamiento multiclase

Entrena un clasificador lineal para predecir una de las cuatro categorías.

Explica en qué se diferencia este problema multiclase de la clasificación binaria de spam/ham.

Ejercicio 8. Evaluación por clase

Calcula el informe de clasificación y la matriz de confusión.

Interpreta qué categorías se confunden más entre sí y formula una hipótesis lingüística o temática para esos errores.

Ejercicio 9. Prueba con una noticia nueva

Redacta tú una noticia breve, en inglés (el modelo se ha entrenado con noticias en inglés) y que no esté incluida en el corpus, y predice su categoría.

Muestra la etiqueta numérica y su nombre legible. Comenta si la clase asignada coincide con tu intuición.

Ejercicio 10. Explicación de una predicción

Analiza las palabras o n-gramas con mayor peso para la clase predicha en la noticia nueva.

Relaciona esos términos con la categoría correspondiente sin asumir que el modelo comprende el acontecimiento de forma semántica completa.

Actividad final de reflexión

1. ¿Qué cambia al pasar de una clasificación binaria a una clasificación multiclase?
2. ¿Por qué conviene interpretar métricas por clase y no solo una media global?
3. ¿Qué categorías de AG News esperarías que se confundieran más y por qué?
4. ¿Qué información aportan los bigramas en textos periodísticos?
5. ¿Qué precauciones hay que tomar al explicar una predicción mediante términos influyentes?

Rúbrica de evaluación

Se valora la construcción reproducible del flujo de clasificación textual, la interpretación crítica de las métricas y la capacidad para explicar predicciones sin convertir el modelo en una caja negra absoluta.

Criterio	Excelente	Adecuado	En proceso
Carga y análisis del dataset	Carga correctamente el corpus, identifica variables, tamaño, clases, valores ausentes y distribución de etiquetas, y comenta sus implicaciones.	Carga el corpus y revisa los aspectos principales, aunque la interpretación es parcial o poco conectada con el problema.	No consigue preparar el dataset o no distingue claramente textos, etiquetas y distribución de clases.
Preprocesamiento textual	Aplica una limpieza reproducible y justifica las decisiones de normalización, tokenización, stopwords y lematización.	Aplica un preprocesamiento básico, aunque con alguna decisión poco explicada o con resultados presentados de forma incompleta.	No obtiene una representación textual limpia o aplica pasos sin comprender su efecto.
Extracción de características y entrenamiento	Construye una representación TF-IDF adecuada, entrena el clasificador y explica la función de cada componente del pipeline.	Entrena un modelo funcional, aunque la explicación de TF-IDF, n-gramas o clasificador es limitada.	No logra entrenar un modelo coherente o confunde representación textual y clasificación.
Evaluación e interpretación	Evalúa con métricas pertinentes, interpreta precisión, recall, f1-score y matriz de confusión, y detecta errores relevantes.	Presenta métricas básicas, aunque la lectura de los errores o de las clases es incompleta.	Se limita a mostrar resultados sin interpretarlos o interpreta incorrectamente las métricas.
Prueba y explicación de predicciones	Prueba textos nuevos, razona la predicción y analiza términos influyentes con prudencia, sin confundir correlación con explicación causal.	Prueba textos nuevos y ofrece una explicación general, aunque poco apoyada en evidencias del modelo.	No verifica el modelo con textos nuevos o atribuye las predicciones a causas no observables.
Claridad y reproducibilidad	Entrega un cuaderno ordenado,	Entrega un trabajo	El trabajo no es reproducible o

	ejecutable y comentado, con resultados visibles y conclusiones breves.	comprensible, aunque con pequeños problemas de orden, ejecución o presentación.	carece de una secuencia clara de ejecución.
--	--	---	---