

Tema 8.

Clasificación automática de textos

Práctica III. Clasificación binaria de sentimiento

Prácticas | Programación para PLN | Universidad Pontificia Comillas

Proyecto de práctica

Encargo

LexiData Solutions quiere explorar un sistema de análisis de sentimiento para reseñas cinematográficas. El objetivo es distinguir automáticamente reseñas positivas y negativas, pero también reconocer los límites de un clasificador basado en palabras y n-gramas.

El encargo consiste en preparar un pipeline de clasificación de sentimiento sobre reseñas de IMDB: cargar el dataset, revisar el equilibrio de clases, preprocesar texto, entrenar con TF-IDF y un clasificador lineal, evaluar métricas y analizar ejemplos nuevos.

Tu papel

Actúa como analista de PLN especializado en opinión y sentimiento.

Tu tarea es construir un cuaderno claro y reproducible, y explicar los resultados con especial atención a la ambigüedad del lenguaje valorativo: negación, ironía, intensificadores y expresiones que cambian de sentido según el contexto.

Actividades de práctica

Práctica III: clasificación de sentimiento en IMDB

Este documento contiene 10 ejercicios independientes y acumulativos para practicar la clasificación supervisada de textos con un flujo completo de aprendizaje automático aplicado a PLN.

Las actividades reproducen las operaciones trabajadas en la unidad: carga del corpus, análisis exploratorio, preprocesamiento, división entrenamiento-prueba, vectorización TF-IDF, entrenamiento, evaluación, prueba con textos nuevos e interpretación prudente de las predicciones.

Corpus de trabajo

El corpus de trabajo es IMDB Movie Reviews, con 50.000 reseñas de películas en inglés etiquetadas como positive o negative.

La práctica trabaja con textos más largos que los SMS y con señales valorativas más complejas. Esto permite discutir tanto el rendimiento del modelo como sus límites interpretativos.

Ejercicio 1. Carga del dataset IMDB Movie Reviews

Carga el archivo IMDB Dataset.csv y crea una tabla con las columnas de reseña y sentimiento.

Comprueba que las etiquetas representan una clasificación binaria de polaridad: positive y negative.

Ejercicio 2. Revisión de ejemplos reales

Muestra varias reseñas positivas y negativas, preferiblemente con longitudes distintas.

Observa qué rasgos lingüísticos pueden complicar la clasificación, como ironía, negación o vocabulario ambiguo.

Ejercicio 3. Análisis exploratorio de datos

Comprueba valores ausentes, tamaño total del dataset y distribución de etiquetas.

Representa la proporción de reseñas positivas y negativas y comenta si el corpus está equilibrado.

Ejercicio 4. Preprocesamiento de reseñas

Aplica una limpieza textual que normalice el contenido de las reseñas: caracteres alfabéticos, minúsculas, tokenización, stopwords y lematización.

Compara ejemplos antes y después, y reflexiona sobre el riesgo de eliminar palabras útiles para el sentimiento, especialmente negaciones.

Ejercicio 5. División entrenamiento-prueba

Divide los textos en entrenamiento y prueba con una proporción 80/20 y estratificación por sentimiento.

Indica el tamaño de cada partición y verifica que ambas clases quedan equilibradas.

Ejercicio 6. Vectorización TF-IDF para sentimiento

Representa las reseñas mediante TF-IDF con unigramas y bigramas.

Explica por qué los bigramas pueden capturar expresiones valorativas mejor que las palabras aisladas.

Ejercicio 7. Entrenamiento del modelo

Entrena un clasificador lineal para distinguir reseñas positivas y negativas.

Organiza la vectorización y el modelo dentro de un pipeline reproducible.

Ejercicio 8. Evaluación del clasificador

Calcula el informe de clasificación y la matriz de confusión sobre el conjunto de prueba.

Interpreta precision, recall y f1-score para positive y negative. Comenta qué tipo de error sería más problemático según el uso del sistema.

Ejercicio 9. Predicción de reseñas nuevas

Escribe una reseña claramente positiva y otra claramente negativa, y obtén la predicción del modelo para cada una.

Comenta si la salida coincide con tu intuición y qué expresiones del texto podrían haber influido.

Ejercicio 10. Interpretación de términos influyentes

Analiza los términos o n-gramas que más contribuyen a la predicción de una reseña negativa.

Explica por qué algunas palabras aparentemente positivas pueden aparecer asociadas a reseñas negativas por el contexto de uso del corpus.

Actividad final de reflexión

1. ¿Qué dificultades específicas plantea la clasificación de sentimiento frente a la detección de spam?
2. ¿Por qué las negaciones pueden ser problemáticas para una bolsa de palabras?
3. ¿Qué aportan los bigramas en reseñas de opinión?
4. ¿Cómo interpretarías una matriz de confusión equilibrada en un corpus con 50 % de reseñas positivas y 50 % negativas?
5. ¿Por qué una palabra aparentemente positiva puede contribuir a una predicción negativa?

Rúbrica de evaluación

Se valora la construcción reproducible del flujo de clasificación textual, la interpretación crítica de las métricas y la capacidad para explicar predicciones sin convertir el modelo en una caja negra absoluta.

Criterio	Excelente	Adecuado	En proceso
Carga y análisis del dataset	Carga correctamente el corpus, identifica variables, tamaño, clases, valores ausentes y distribución de etiquetas, y comenta sus implicaciones.	Carga el corpus y revisa los aspectos principales, aunque la interpretación es parcial o poco conectada con el problema.	No consigue preparar el dataset o no distingue claramente textos, etiquetas y distribución de clases.
Preprocesamiento textual	Aplica una limpieza reproducible y justifica las decisiones de normalización, tokenización, stopwords y lematización.	Aplica un preprocesamiento básico, aunque con alguna decisión poco explicada o con resultados presentados de forma incompleta.	No obtiene una representación textual limpia o aplica pasos sin comprender su efecto.
Extracción de características y entrenamiento	Construye una representación TF-IDF adecuada, entrena el clasificador y explica la función de cada componente del pipeline.	Entrena un modelo funcional, aunque la explicación de TF-IDF, n-gramas o clasificador es limitada.	No logra entrenar un modelo coherente o confunde representación textual y clasificación.
Evaluación e interpretación	Evalúa con métricas pertinentes, interpreta precisión, recall, f1-score y matriz de confusión, y detecta errores relevantes.	Presenta métricas básicas, aunque la lectura de los errores o de las clases es incompleta.	Se limita a mostrar resultados sin interpretarlos o interpreta incorrectamente las métricas.
Prueba y explicación de predicciones	Prueba textos nuevos, razona la predicción y analiza términos influyentes con prudencia, sin confundir correlación con explicación causal.	Prueba textos nuevos y ofrece una explicación general, aunque poco apoyada en evidencias del modelo.	No verifica el modelo con textos nuevos o atribuye las predicciones a causas no observables.
Claridad y reproducibilidad	Entrega un cuaderno ordenado, ejecutable y comentado, con resultados visibles y conclusiones breves.	Entrega un trabajo comprensible, aunque con pequeños problemas de orden, ejecución o presentación.	El trabajo no es reproducible o carece de una secuencia clara de ejecución.